ĐẠI HỌC QUỐC GIA HÀ NỘI

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA TOÁN - CƠ - TIN HỌC

CHUYÊN ĐỀ: MÔ HÌNH HỒI QUY TUYẾN TÍNH BAYES VÀ ỨNG DỤNG

BÀI TẬP GIỮA KỲ

Đề tài: Ước lượng (học) mô hình hồi quy tuyến tính Bayes và sự phụ thuộc vào đặc điểm của mẫu dữ liệu học

---



Học viên thực hiện:

Bùi Quang Huy (25007877)

Ngày 20 tháng 10 năm 2026

Tóm tắt

Ước lượng mô hình hồi quy tuyến tính Bayes là xác định phân phối hậu nghiệm của các hệ số và phương sai nhiễu từ dữ liệu và phân phối tiên nghiệm. Bài viết trình bày quy trình gồm bảy bước: chuẩn bị dữ liệu, đặc tả hàm hợp lý, chọn tiên nghiệm, tính hậu nghiệm, chẩn đoán hội tụ, kiểm tra mô hình, suy luận và dự đoán. Trọng tâm là phân tích mối liên hệ giữa đặc điểm của mẫu và quá trình ước lượng. Trong mô hình sai số chuẩn đang xét, dữ liệu ảnh hưởng đến hậu nghiệm thông qua n, $X^\top X$, $X^\top y$ và $y^\top y$. Các công thức và mô phỏng được sử dụng để minh hoạ vai trò của cỡ mẫu, mức nhiễu, phạm vi và mức độ phân tán của biến giải thích, đa cộng tuyến, thang đo và ngoại lai. Phần ứng dụng đối chiếu quy trình với kết quả phân tích 93 mẫu xe năm 1993 trong bài cuối kỳ của nhóm.

Mục lục

Tóm tắt **1**

I Bài toán học mô hình hồi quy tuyến tính Bayes **4**

1.1 Mô hình . . . 4

1.2 Hàm hợp lý và các thống kê đủ . . . 4

II Các bước ước lượng mô hình **5**

2.1 Bước 1: Chuẩn bị dữ liệu . . . 5

2.2 Bước 2: Đặc tả hàm hợp lý . . . 5

2.3 Bước 3: Chọn phân phối tiên nghiệm . . . 5

2.4 Bước 4: Tính phân phối hậu nghiệm . . . 6

2.4.1 Trường hợp σ^2 đã biết . . . 6

2.4.2 Trường hợp liên hợp NIG . . . 6

2.4.3 Lấy mẫu Gibbs với phân phối tiên nghiệm bán liên hợp . . . 6

2.4.4 MCMC tổng quát: Metropolis–Hastings và NUTS . . . 7

2.4.5 Xấp xỉ . . . 7

2.5 Bước 5: Chẩn đoán hội tụ . . . 7

2.6 Bước 6: Kiểm tra và so sánh mô hình 7
2.7 Bước 7: Suy diễn và dự đoán 8

III Quá trình học phụ thuộc vào đặc điểm nào của mẫu **9**
3.1 Cỡ mẫu 9
3.2 Mức nhiễu của dữ liệu 10
3.3 Mức độ phân tán và phạm vi của biến giải thích 11
3.4 Tương quan giữa các biến giải thích 11
3.5 Thang đo của biến 12
3.6 Ngoại lai và đuôi dày 13
3.7 Dạng quan hệ và phân phối sai số 13
3.8 Tổng hợp 14

IV Minh hoạ trên dữ liệu thực tế **15**

V Kết luận **17**

A Dẫn xuất hậu nghiệm khi σ^2 đã biết **18**

Tài liệu tham khảo **19**

Danh sách hình vẽ

3.1 Cập nhật tuần tự: hậu nghiệm của hệ số góc β_1 khi cỡ mẫu tăng (trái), và trung bình hậu nghiệm cùng khoảng 95% theo n trên thang logarit (phải). Phân phối tiên nghiệm $\mathcal{N}(0, 2^2)$, $\sigma = 1$. . . 10

3.2 Ảnh hưởng của tiên nghiệm và cỡ mẫu đến hậu nghiệm: trung bình hậu nghiệm của β_1 theo cỡ mẫu với bốn mức độ tập trung của tiên nghiệm $\mathcal{N}(0, \tau^2)$ (trái), và trọng số của dữ liệu w theo (3.1) (phải). 10

3.3 Độ lệch chuẩn hậu nghiệm của hệ số góc theo cỡ mẫu, với ba mức nhiễu σ (trái) và ba mức mức độ phân tán của biến giải thích s_x (phải); hai trục theo thang logarit. 11

3.4 Khoảng tin cậy hậu nghiệm 95% của trung bình và khoảng dự đoán 95%, với 20 quan sát có x trong $[0, 1]$; ngoài vùng có dữ liệu, bất định về tham số chiếm ưu thế. 12

3.5 Hậu nghiệm đồng thời của (β_1, β_2) với ba mức tương quan giữa hai biến giải thích; elip là vùng 95%, dấu chéo là giá trị thật. 12

3.6 Một điểm ngoại lai: đường hồi quy theo trung bình hậu nghiệm (trái) và hậu nghiệm của hệ số góc (phải), với hàm hợp lý chuẩn và Student-t. Hậu nghiệm tính trên lưới (β_0, β_1), $\sigma = 0{,}6$ cố định. 13

Danh sách bảng

3.1 Đặc điểm của mẫu học và nơi chúng tác động trong quá trình ước lượng. 14

I. Bài toán học mô hình hồi quy tuyến tính Bayes

1.1 Mô hình

Cho mẫu học $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$, với $x_i \in \mathbb{R}^p$ là vector biến giải thích (phần tử đầu bằng 1 ứng với hệ số chặn) và $y_i \in \mathbb{R}$ là biến phản hồi. Ghép thành ma trận thiết kế $X \in \mathbb{R}^{n\times p}$ và vector $y \in \mathbb{R}^n$, mô hình hồi quy tuyến tính chuẩn là

$$y \mid X, \beta, \sigma^2 \sim \mathcal{N}\big(X\beta,\ \sigma^2 I_n\big). \tag{1.1}$$

Cách tiếp cận Bayes coi $\theta = (\beta, \sigma^2)$ là biến ngẫu nhiên với phân phối tiên nghiệm $p(\theta)$. *Học* mô hình nghĩa là tính phân phối hậu nghiệm

$$p(\beta, \sigma^2 \mid y, X) = \frac{p(y \mid X, \beta, \sigma^2)\, p(\beta, \sigma^2)}{\int p(y \mid X, \beta, \sigma^2)\, p(\beta, \sigma^2)\, d\beta\, d\sigma^2}. \tag{1.2}$$

Kết quả hồi quy thông thường được tóm tắt bằng ước lượng điểm $\hat\beta$ cùng sai số chuẩn và khoảng tin cậy. Kết quả ước lượng Bayes được biểu diễn bằng phân phối hậu nghiệm trên không gian tham số. Mẫu số của (1.2), gọi là bằng chứng (evidence) hay hàm hợp lý biên, là một tích phân nhiều chiều; việc tính tích phân này là một khó khăn chính trong suy luận Bayes [1].

1.2 Hàm hợp lý và các thống kê đủ

Lấy logarit hàm hợp lý của (1.1) và khai triển,

$$\log p(y \mid X, \beta, \sigma^2) = -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\Big(y^\top y - 2\beta^\top X^\top y + \beta^\top X^\top X\beta\Big). \tag{1.3}$$

Hàm hợp lý chỉ phụ thuộc vào dữ liệu qua bốn đại lượng: n, $X^\top X$, $X^\top y$ và $y^\top y$. Đó là các *thống kê đủ* của mô hình. Trong mô hình (1.1), với tiên nghiệm cố định, ảnh hưởng của dữ liệu đến hậu nghiệm được thể hiện thông qua bốn đại lượng này. Chương III lần lượt chỉ ra mỗi đặc điểm của mẫu làm thay đổi đại lượng nào.

II. Các bước ước lượng mô hình

Quá trình học được chia thành bảy bước. Thứ tự này cũng là quy trình nhóm dùng trong bài cuối kỳ.

2.1 Bước 1: Chuẩn bị dữ liệu

Làm sạch (giá trị thiếu, lỗi nhập liệu, đơn vị), chọn biến, biến đổi để quan hệ gần tuyến tính và sai số gần chuẩn (chẳng hạn lấy logarit biến phản hồi lệch phải), và chuẩn hoá các biến giải thích về trung bình 0, độ lệch chuẩn 1. Chuẩn hoá không làm thay đổi mô hình, nhưng làm cho phân phối tiên nghiệm có cùng ý nghĩa với mọi hệ số và giúp bước 4 hội tụ nhanh hơn, như mục 3.5 giải thích.

2.2 Bước 2: Đặc tả hàm hợp lý

Chọn phân phối của sai số. Mặc định là chuẩn như (1.1); nếu dữ liệu có ngoại lai thì thay bằng Student-t, $y_i \sim t_\nu(x_i^\top \beta, \sigma)$, với ν được ước lượng từ dữ liệu. Phương sai thay đổi theo nhóm, sai số tương quan theo thời gian hay cấu trúc phân cấp cũng được đưa vào ở bước này.

2.3 Bước 3: Chọn phân phối tiên nghiệm

Ba lựa chọn thường dùng được trình bày dưới đây.

- **Phân phối tiên nghiệm liên hợp** Normal–Inverse-Gamma (NIG): $\beta \mid \sigma^2 \sim \mathcal{N}(m_0, \sigma^2 V_0)$, $\sigma^2 \sim \text{IG}(a_0, b_0)$. Hậu nghiệm cùng họ, có công thức đóng.
- **Phân phối tiên nghiệm bán liên hợp**: $\beta \sim \mathcal{N}(m_0, V_0)$ độc lập với $\sigma^2 \sim \text{IG}(a_0, b_0)$. Không có dạng đóng cho hậu nghiệm đồng thời, nhưng các phân phối điều kiện có dạng đóng, nên dùng được Gibbs.
- **Phân phối tiên nghiệm tuỳ ý** như $\sigma \sim \text{Half-Normal}(1)$ hay $\beta_j \sim t_3(0, 2{,}5)$, cần MCMC tổng quát như NUTS.

Về mức thông tin, phân phối tiên nghiệm có thể phẳng, yếu thông tin hoặc tập trung. *Kiểm tra dự đoán tiên nghiệm (prior predictive check)* được thực hiện bằng cách sinh dữ liệu mô phỏng từ phân phối tiên nghiệm và

mô hình, sau đó đánh giá mức độ hợp lý của dữ liệu mô phỏng trước khi sử dụng dữ liệu quan sát để cập nhật hậu nghiệm.

2.4 Bước 4: Tính phân phối hậu nghiệm

2.4.1 Trường hợp σ^2 đã biết

Với phân phối tiên nghiệm $\beta \sim \mathcal{N}(m_0, V_0)$, tích của hàm hợp lý (1.3) và phân phối tiên nghiệm là hàm mũ của một dạng toàn phương theo β. Hoàn thành bình phương (phụ lục A) cho hậu nghiệm chuẩn $\beta \mid y \sim \mathcal{N}(m_n, V_n)$ với

$$V_n = \Big(V_0^{-1} + \tfrac{1}{\sigma^2} X^\top X\Big)^{-1}, \qquad m_n = V_n\Big(V_0^{-1} m_0 + \tfrac{1}{\sigma^2} X^\top y\Big). \tag{2.1}$$

Ma trận độ chính xác hậu nghiệm V_n^{-1} là tổng của ma trận độ chính xác tiên nghiệm V_0^{-1} và thành phần thông tin do dữ liệu cung cấp $X^\top X/\sigma^2$; trung bình hậu nghiệm là trung bình có trọng số của m_0 và ước lượng OLS $\hat\beta = (X^\top X)^{-1} X^\top y$, vì $X^\top y = X^\top X\,\hat\beta$:

$$m_n = V_n\Big(V_0^{-1} m_0 + \tfrac{1}{\sigma^2} X^\top X\,\hat\beta\Big). \tag{2.2}$$

2.4.2 Trường hợp liên hợp NIG

Khi σ^2 cũng chưa biết và phân phối tiên nghiệm là NIG, hậu nghiệm vẫn là NIG với

$$\begin{aligned} V_n &= \big(V_0^{-1} + X^\top X\big)^{-1}, \quad m_n = V_n\big(V_0^{-1} m_0 + X^\top y\big), \\ a_n &= a_0 + \tfrac{n}{2}, \qquad\qquad\quad b_n = b_0 + \tfrac{1}{2}\big(y^\top y + m_0^\top V_0^{-1} m_0 - m_n^\top V_n^{-1} m_n\big). \end{aligned} \tag{2.3}$$

Lấy tích phân theo σ^2, phân phối biên của β là phân phối t đa biến với $2a_n$ bậc tự do, tâm m_n và ma trận tỉ lệ $(b_n/a_n)V_n$ [2]. Số hạng b_n chứa tổng bình phương phần dư: dữ liệu càng nhiễu thì b_n càng lớn, hậu nghiệm của σ^2 dịch về phía các giá trị lớn hơn và hậu nghiệm của β rộng ra.

2.4.3 Lấy mẫu Gibbs với phân phối tiên nghiệm bán liên hợp

Với phân phối tiên nghiệm bán liên hợp, hậu nghiệm đồng thời không có dạng đóng, nhưng hai phân phối điều kiện đầy đủ thì có:

$$\begin{aligned} &\beta \mid \sigma^2, y \sim \mathcal{N}(m_n, V_n) \quad \text{với } m_n, V_n \text{ như (2.1)}, \\ &\sigma^2 \mid \beta, y \sim \mathrm{IG}\Big(a_0 + \tfrac{n}{2},\ b_0 + \tfrac{1}{2}\|y - X\beta\|_2^2\Big). \end{aligned} \tag{2.4}$$

Thuật toán Gibbs [3] lần lượt lấy mẫu β và σ^2 từ hai phân phối điều kiện này. Sau giai đoạn khởi động, các mẫu thu được dùng để xấp xỉ phân phối hậu nghiệm.

2.4.4 MCMC tổng quát: Metropolis–Hastings và NUTS

Khi khó tính mẫu số của (1.2), có thể sử dụng mật độ hậu nghiệm chưa chuẩn hoá $\tilde{p}(\theta) = p(y \mid \theta)\, p(\theta)$. Mật độ này được xác định đến một hằng số nhân. Thuật toán Metropolis–Hastings [4] đề xuất $\theta' \sim q(\theta' \mid \theta)$ rồi chấp nhận với xác suất

$$\alpha = \min\Big(1,\ \frac{\tilde{p}(\theta')\, q(\theta \mid \theta')}{\tilde{p}(\theta)\, q(\theta' \mid \theta)}\Big), \tag{2.5}$$

trong đó hằng số chưa biết triệt tiêu ở tỉ số. Bước đề xuất ngẫu nhiên khiến chuỗi di chuyển chậm và tự tương quan cao khi tham số tương quan với nhau. NUTS [5], một biến thể của Hamiltonian Monte Carlo, dùng gradient của $\log \tilde{p}$ để xác định hướng và độ dài bước di chuyển phù hợp với hình dạng của hậu nghiệm, và là thuật toán mặc định trong Stan và PyMC.

2.4.5 Xấp xỉ

Khi dữ liệu rất lớn, có thể xấp xỉ hậu nghiệm bằng phân phối chuẩn quanh điểm cực đại (xấp xỉ Laplace) hoặc bằng suy diễn biến phân, nhằm giảm thời gian tính toán, đồng thời có thể làm giảm độ chính xác của xấp xỉ [6].

2.5 Bước 5: Chẩn đoán hội tụ

Cần đánh giá hội tụ trước khi sử dụng kết quả MCMC để suy luận. Các tiêu chí thường dùng là $\widehat{R}$ dựa trên phép chuẩn hoá thứ hạng dưới $1{,}01$ [7], cỡ mẫu hiệu dụng (ESS) bulk và tail đủ lớn (thường trên 400), không phát hiện hiện tượng phân kỳ khi lấy mẫu (divergence) với NUTS. Cần xem thêm biểu đồ vết và biểu đồ thứ hạng để đánh giá tính ổn định và mức độ nhất quán giữa các chuỗi. Với lời giải dạng đóng thì không cần bước này, và đó là một lý do để đối chiếu MCMC với dạng đóng khi có thể.

2.6 Bước 6: Kiểm tra và so sánh mô hình

Kiểm tra dự đoán hậu nghiệm (posterior predictive check) sử dụng dữ liệu mô phỏng từ phân phối dự đoán hậu nghiệm để so sánh với dữ liệu quan sát, theo mật độ hay theo các thống kê như giá trị lớn nhất, nhỏ nhất.

So sánh các mô hình ứng viên dùng ELPD ước lượng qua PSIS-LOO hoặc WAIC [8]; tham số Pareto k của PSIS-LOO còn chỉ ra các quan sát có ảnh hưởng lớn tới hậu nghiệm.

2.7 Bước 7: Suy diễn và dự đoán

Từ hậu nghiệm, mọi đại lượng quan tâm được tính trực tiếp: trung bình, khoảng tin cậy hậu nghiệm (HDI), xác suất $P(\beta_j > 0 \mid y)$. Dự đoán tại điểm mới x^* dùng phân phối dự đoán hậu nghiệm; với σ^2 đã biết,

$$y^* \mid x^*, y \sim \mathcal{N}\big(x^{*\top} m_n,\ \sigma^2 + x^{*\top} V_n\, x^*\big). \tag{2.6}$$

III. Quá trình học phụ thuộc vào đặc điểm nào của mẫu

Trong mô hình sai số chuẩn ở mục 1.2, với tiên nghiệm cố định, dữ liệu ảnh hưởng đến hậu nghiệm thông qua n, $X^\top X$, $X^\top y$ và $y^\top y$. Các đại lượng này phản ánh cỡ mẫu, mức độ phân tán và tương quan của các biến giải thích, cũng như mối liên hệ của chúng với biến phản hồi. Các mục dưới đây phân tích vai trò của từng đặc điểm đối với quá trình ước lượng và dự đoán. Trừ khi có ghi chú khác, các mô phỏng sử dụng mô hình sinh dữ liệu $y = 1 + 2x + \varepsilon$ và lời giải dạng đóng (2.1); mã nguồn tại `bai-giua-ky/make_figures.py`.

3.1 Cỡ mẫu

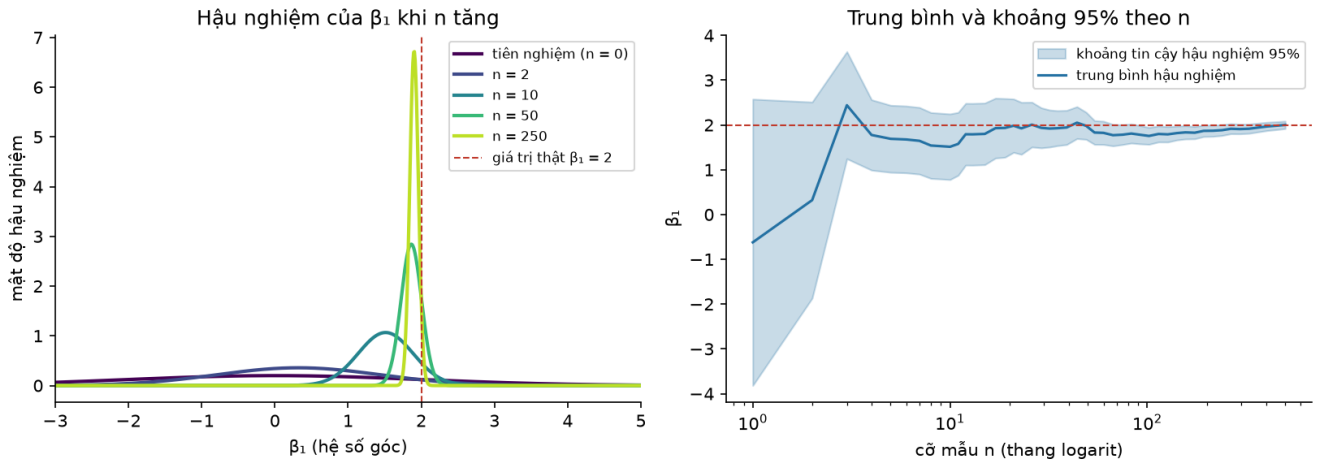
$X^\top X$ là tổng của n ma trận $x_i x_i^\top$, nên lớn lên tỉ lệ với n. Theo (2.1), phương sai hậu nghiệm giảm theo $1/n$, độ lệch chuẩn theo $1/\sqrt{n}$, còn phần đóng góp của phân phối tiên nghiệm V_0^{-1} không đổi và nhỏ dần tương đối. Hình 3.1 cho thấy hậu nghiệm của hệ số góc từ một phân phối tiên nghiệm rộng thu hẹp dần về giá trị thật khi n tăng từ 2 lên 250. Khi n rất lớn, hậu nghiệm xấp xỉ $\mathcal{N}\big(\hat\beta, \sigma^2 (X^\top X)^{-1}\big)$, tức trùng với kết quả của hồi quy thông thường; đây là nội dung của định lý Bernstein–von Mises [1].

Cỡ mẫu còn quyết định cách tổ chức việc học. Vì hậu nghiệm sau n quan sát là phân phối tiên nghiệm cho quan sát thứ $n+1$, có thể học tuần tự: cập nhật V_n và m_n bằng (2.1) mỗi khi có lô dữ liệu mới, và với cùng mô hình và tiên nghiệm ban đầu, kết quả tương đương với ước lượng trên toàn bộ dữ liệu.

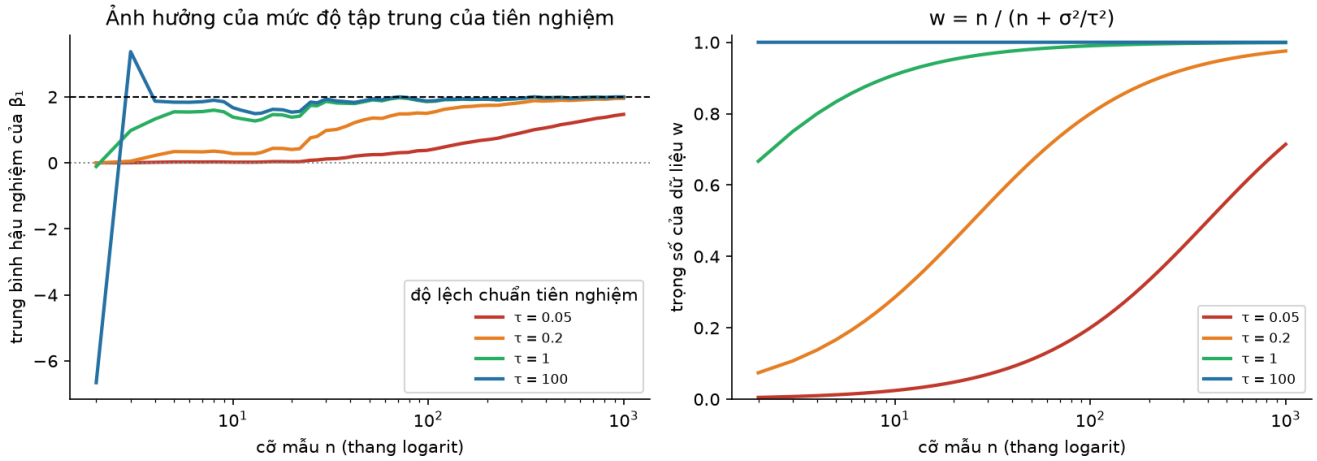
Ở bước 3, cỡ mẫu ảnh hưởng đến vai trò tương đối của tiên nghiệm. Với một biến giải thích đã chuẩn hoá và phân phối tiên nghiệm $\mathcal{N}(0, \tau^2)$, trung bình hậu nghiệm của hệ số góc là $w\,\hat\beta$ với

$$w = \frac{n}{n + \sigma^2/\tau^2}. \tag{3.1}$$

Tỉ số σ^2/τ^2 đóng vai trò "số quan sát tương đương" của phân phối tiên nghiệm. Hình 3.2 cho thấy với tiên nghiệm tập trung $\tau = 0{,}05$ (tương đương 400 quan sát), sau $1\,000$ điểm dữ liệu trung bình hậu nghiệm vẫn chỉ đạt khoảng 70% giá trị thật; còn với phân phối tiên nghiệm gần phẳng $\tau = 100$, trung bình hậu nghiệm dao động mạnh ở vài điểm đầu, vì khi đó gần như chỉ có dữ liệu quyết định. Mẫu càng nhỏ thì bước chọn phân phối tiên nghiệm và phân tích độ nhạy càng quan trọng.



Hình 3.1: Cập nhật tuần tự: hậu nghiệm của hệ số góc β_1 khi cỡ mẫu tăng (trái), và trung bình hậu nghiệm cùng khoảng 95% theo n trên thang logarit (phải). Phân phối tiên nghiệm $\mathcal{N}(0, 2^2)$, $\sigma = 1$.



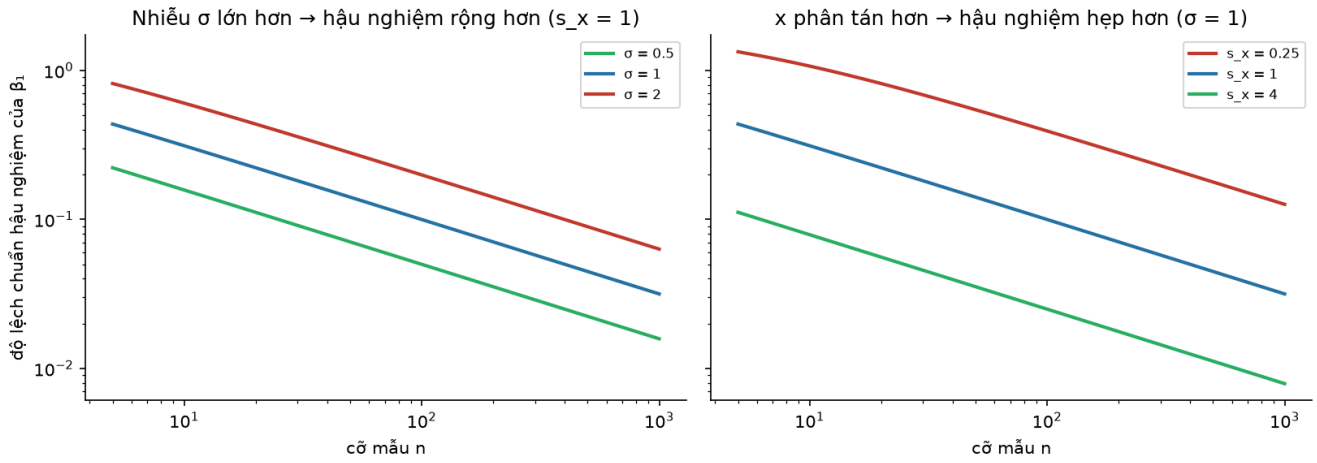
Hình 3.2: Ảnh hưởng của tiên nghiệm và cỡ mẫu đến hậu nghiệm: trung bình hậu nghiệm của β_1 theo cỡ mẫu với bốn mức độ tập trung của tiên nghiệm $\mathcal{N}(0, \tau^2)$ (trái), và trọng số của dữ liệu w theo (3.1) (phải).

3.2 Mức nhiễu của dữ liệu

Trong (2.1), dữ liệu đi vào dưới dạng $X^\top X/\sigma^2$: độ lệch chuẩn nhiễu tăng gấp đôi thì mỗi quan sát chỉ mang một phần tư lượng thông tin. Độ lệch chuẩn hậu nghiệm của hệ số góc với một biến giải thích là xấp xỉ

$$\mathrm{sd}(\beta_1 \mid y) \approx \left(\frac{n\, s_x^2}{\sigma^2} + \frac{1}{\tau^2}\right)^{-1/2} \approx \frac{\sigma}{\sqrt{n}\, s_x}, \tag{3.2}$$

với s_x là độ lệch chuẩn mẫu của x. Muốn giữ nguyên độ chính xác khi σ tăng gấp đôi thì cần gấp bốn lần dữ liệu (hình 3.3, trái). Khi σ^2 chưa biết, mức nhiễu cũng được ước lượng từ mẫu qua b_n trong (2.3) hay qua bước lấy mẫu σ^2 trong (2.4): tổng bình phương phần dư lớn thì hậu nghiệm của σ^2 dịch về phía các giá trị lớn hơn, kéo theo hậu nghiệm của β rộng ra.



Hình 3.3: Độ lệch chuẩn hậu nghiệm của hệ số góc theo cỡ mẫu, với ba mức nhiễu σ (trái) và ba mức mức độ phân tán của biến giải thích s_x (phải); hai trục theo thang logarit.

3.3 Mức độ phân tán và phạm vi của biến giải thích

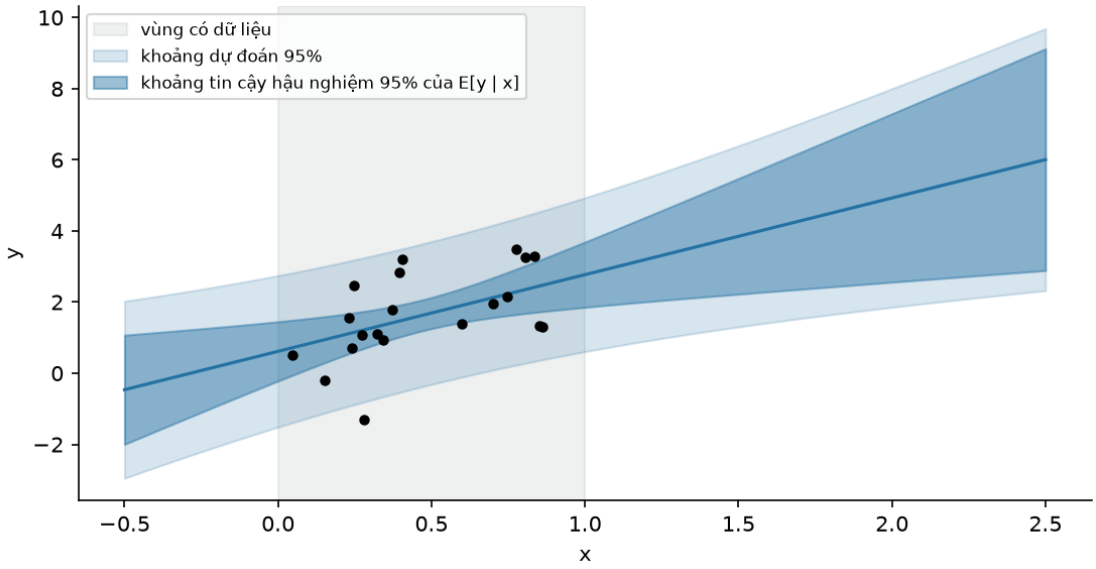
Công thức (3.2) cho thấy mức độ phân tán của x cũng ảnh hưởng đến độ chính xác của ước lượng: s_x gấp bốn lần thì độ lệch chuẩn hậu nghiệm giảm bốn lần, tương đương gấp 16 lần dữ liệu (hình 3.3, phải). Dữ liệu tập trung trong một khoảng hẹp của x cho rất ít thông tin về hệ số góc, dù n lớn. Điều này ứng với $X^\top X$ có các trị riêng nhỏ.

Phạm vi mà mẫu bao phủ quyết định chất lượng dự đoán. Theo (2.6), phần bất định do tham số $x^{*\top} V_n x^*$ tăng theo bình phương khoảng cách từ x^* tới tâm dữ liệu. Ngoài vùng có dữ liệu, khoảng tin cậy hậu nghiệm của trung bình mở rộng nhanh và chiếm phần lớn khoảng dự đoán (hình 3.4). Khoảng dự đoán có thể mở rộng khi ngoại suy, phản ánh bất định về tham số trong mô hình đã chọn. Tuy nhiên, khoảng này không phản ánh đầy đủ bất định về việc quan hệ tuyến tính có còn phù hợp ngoài phạm vi dữ liệu hay không.

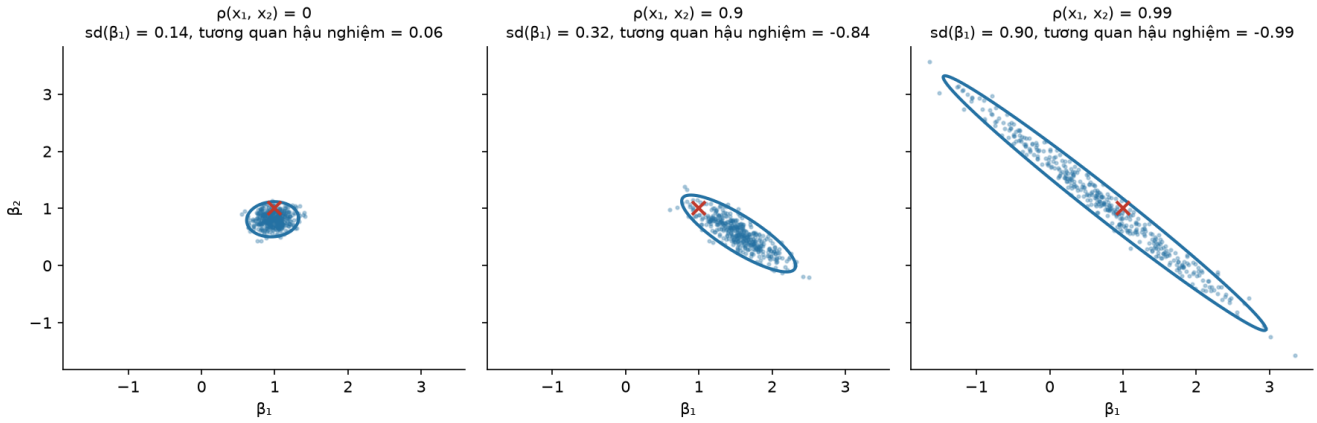
3.4 Tương quan giữa các biến giải thích

Khi các biến giải thích tương quan mạnh, $X^\top X$ gần suy biến: có những tổ hợp tuyến tính của hệ số mà dữ liệu gần như không phân biệt được. Hậu nghiệm vì thế dài ra theo hướng đó, các hệ số tương quan âm với nhau trong hậu nghiệm, và phương sai biên của từng hệ số tăng lên, dù tổng của chúng vẫn được xác định tốt. Trong mô phỏng ở hình 3.5 với $n = 50$, khi tương quan giữa x_1 và x_2 tăng từ 0 lên $0{,}99$, độ lệch chuẩn hậu nghiệm của β_1 tăng từ $0{,}14$ lên $0{,}90$ và tương quan hậu nghiệm giữa β_1 và β_2 từ $0{,}06$ xuống $-0{,}99$.

Đặc điểm này tác động tới ba bước. Ở bước 3, phân phối tiên nghiệm thêm V_0^{-1} vào $X^\top X$ nên làm ma trận khả nghịch và ổn định hệ số, đúng cơ chế của hồi quy Ridge. Ở bước 4, hình dạng kéo dài và hẹp của phân phối hậu



Hình 3.4: Khoảng tin cậy hậu nghiệm 95% của trung bình và khoảng dự đoán 95%, với 20 quan sát có x trong $[0, 1]$; ngoài vùng có dữ liệu, bất định về tham số chiếm ưu thế.

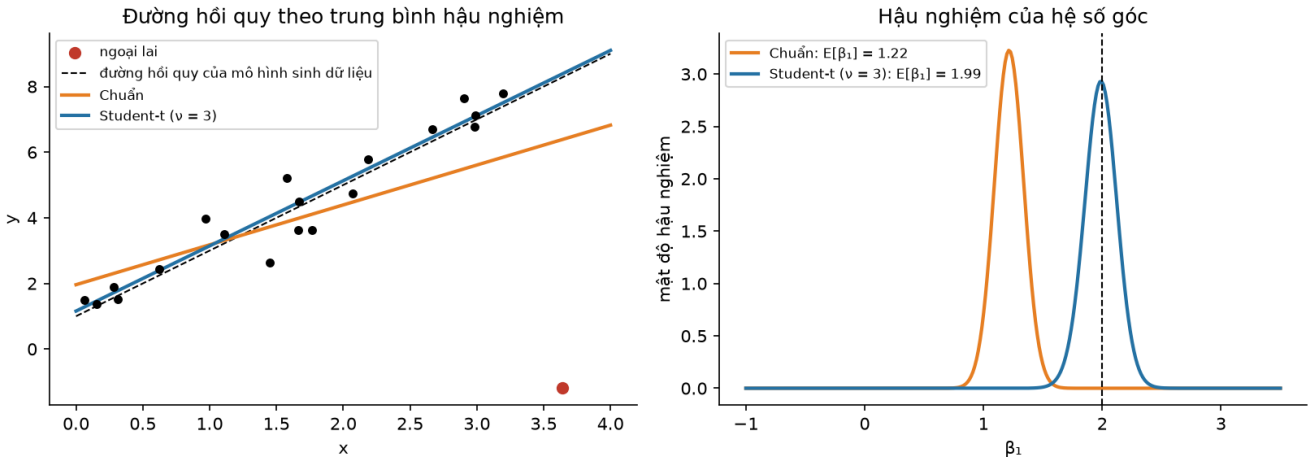


Hình 3.5: Hậu nghiệm đồng thời của (β_1, β_2) với ba mức tương quan giữa hai biến giải thích; elip là vùng 95%, dấu chéo là giá trị thật.

nghiệm có thể làm giảm hiệu quả lấy mẫu của Gibbs và Metropolis–Hastings. NUTS có thể hạn chế khó khăn này nhờ cơ chế điều chỉnh ma trận khối lượng, và có thể giảm khó khăn tính toán bằng chuẩn hoá hoặc phân rã QR của X. Ở bước 7, hệ số riêng lẻ khó diễn giải, trong khi dự đoán trong phạm vi dữ liệu vẫn có thể ổn định.

3.5 Thang đo của biến

OLS bất biến với thang đo: đổi đơn vị của x từ kg sang tấn chỉ nhân hệ số với $1\,000$. Nếu giữ nguyên tiên nghiệm khi đổi đơn vị, kết quả Bayes có thể thay đổi, vì phân phối tiên nghiệm $\beta_j \sim \mathcal{N}(0, \tau^2)$ mang ý nghĩa khác hẳn khi đơn vị thay đổi: một phân phối tiên nghiệm yếu thông tin theo kg trở thành tiên nghiệm tập trung hơn nhiều theo tấn. Thang đo còn ảnh hưởng tới bước 4, vì các tham số có độ lớn rất khác nhau làm các chiều



Hình 3.6: Một điểm ngoại lai: đường hồi quy theo trung bình hậu nghiệm (trái) và hậu nghiệm của hệ số góc (phải), với hàm hợp lý chuẩn và Student-t. Hậu nghiệm tính trên lưới (β_0, β_1), $\sigma = 0{,}6$ cố định.

của phân phối hậu nghiệm có thang đo khác nhau, khiến thuật toán lấy mẫu có thể phải giảm kích thước bước. Chuẩn hoá các biến giải thích ở bước 1 giúp hạn chế hai vấn đề này: mọi hệ số cùng một thang, nên có thể dùng chung một phân phối tiên nghiệm và thuật toán lấy mẫu có thể hội tụ nhanh hơn.

3.6 Ngoại lai và đuôi dày

Với hàm hợp lý chuẩn, mỗi quan sát đóng góp $-(y_i - x_i^\top \beta)^2/2\sigma^2$ vào log-hậu nghiệm; độ lớn của mức phạt tăng theo bình phương phần dư. Một điểm ngoại lai duy nhất có thể kéo cả đường hồi quy về phía nó, trong khi hậu nghiệm vẫn hẹp. Khi đó, kết quả có thể sai lệch với mức bất định bị đánh giá thấp. Trong hình 3.6, một lỗi lớn ở điểm có x lớn nhất kéo trung bình hậu nghiệm của hệ số góc từ 2 xuống $1{,}22$. Thay hàm hợp lý chuẩn bằng Student-t với $\nu = 3$, mức phạt chỉ tăng theo logarit của phần dư khi phần dư lớn, nên điểm ngoại lai bị giảm trọng số tự động và trung bình hậu nghiệm trở về $1{,}99$.

Ngoại lai tác động tới bước 2 (chọn hàm hợp lý), bước 4 (với Student-t không còn dạng đóng, phải dùng MCMC) và bước 6, nơi Pareto k lớn của PSIS-LOO và các thống kê cực trị trong kiểm tra dự đoán hậu nghiệm chỉ ra những quan sát mô hình không giải thích được.

3.7 Dạng quan hệ và phân phối sai số

Hàm hợp lý (1.1) giả định quan hệ tuyến tính, phương sai không đổi và sai số độc lập. Mẫu học vi phạm các giả định này thì hậu nghiệm vẫn tính được, nhưng là hậu nghiệm của một mô hình sai. Các vi phạm thường gặp và cách xử lý:

Bảng 3.1: Đặc điểm của mẫu học và nơi chúng tác động trong quá trình ước lượng.

Đặc điểm	Đại lượng liên quan	Bước	Biểu hiện và cách xử lý
Cỡ mẫu n	$X^\top X$ tỉ lệ với n; trọng số w của dữ liệu	3, 4	Độ lệch chuẩn hậu nghiệm giảm theo $1/\sqrt{n}$; mẫu nhỏ thì phân phối tiên nghiệm quan trọng, cần phân tích độ nhạy
Mức nhiễu σ	$X^\top X/\sigma^2$; tổng bình phương phần dư trong b_n	4	Độ lệch chuẩn nhiễu tăng gấp đôi cần cỡ mẫu gấp bốn lần; σ^2 được ước lượng đồng thời với β
Mức độ phân tán s_x	Trị riêng của $X^\top X$	1, 4	Độ lệch chuẩn hệ số tỉ lệ với $1/s_x$; dữ liệu tập trung cho ít thông tin
Phạm vi của x	${x^*}^\top V_n x^*$ trong dự đoán	7	Khoảng dự đoán rộng nhanh khi ngoại suy
Đa cộng tuyến	$X^\top X$ gần suy biến	3, 4, 7	Hậu nghiệm có dạng kéo dài, các hệ số tương quan; điều chuẩn bằng tiên nghiệm, chuẩn hoá, QR
Thang đo	Ý nghĩa của phân phối tiên nghiệm; hình dạng hậu nghiệm	1, 3, 4	Chuẩn hoá trước khi đặt phân phối tiên nghiệm
Ngoại lai	Phần dư bình phương trong hàm hợp lý chuẩn	2, 4, 6	Kéo lệch hệ số; dùng Student-t, kiểm tra Pareto k
Dạng quan hệ, sai số	Giả định của (1.1)	1, 2, 6	Biến đổi biến, mô hình phương sai, tự tương quan; kiểm tra bằng PPC

- **Quan hệ cong hoặc biến phản hồi lệch phải**: biến đổi ở bước 1, như lấy logarit, hoặc thêm số hạng bậc hai.
- **Phương sai thay đổi** theo nhóm hay theo mức của x: cho σ phụ thuộc nhóm ở bước 2.
- **Sai số phụ thuộc**, như dữ liệu chuỗi thời gian hay dữ liệu lặp lại trên cùng một đối tượng: khi đó n quan sát mang ít thông tin hơn n quan sát độc lập, và hậu nghiệm từ (1.1) hẹp hơn thực tế. Cần thêm cấu trúc tự tương quan hoặc hiệu ứng ngẫu nhiên ở bước 2.
- **Dữ liệu thiếu**: có thể loại bỏ các quan sát có giá trị thiếu khi tỉ lệ thiếu nhỏ và cơ chế thiếu dữ liệu phù hợp. Một lựa chọn khác là xây dựng mô hình cho các giá trị thiếu và ước lượng đồng thời với các tham số của mô hình.

3.8 Tổng hợp

Bảng 3.1 tóm tắt mối liên hệ giữa các đặc điểm của mẫu và các đại lượng trong mô hình, các bước chịu ảnh hưởng và cách xử lý tương ứng.

IV. Minh hoạ trên dữ liệu thực tế

Bài cuối kỳ của nhóm áp dụng đúng quy trình trên cho 93 mẫu xe mới tại Mỹ năm 1993, với biến phản hồi là hiệu suất nhiên liệu trong thành phố (City, MPG). Một số kết quả cho thấy các cơ chế ở chương III trên dữ liệu thực tế.

Biến đổi và chuẩn hoá (bước 1). Quan hệ giữa City và công suất có dạng cong. Lấy logarit City làm logarit hàm hợp lý trên thang City tăng từ $-264{,}0$ lên $-246{,}0$, và phần dư không còn dạng cong. Các biến giải thích được chuẩn hoá để dùng chung phân phối tiên nghiệm $\beta_j \sim \mathcal{N}(0, 2{,}5^2)$.

Cỡ mẫu và phân phối tiên nghiệm (bước 3). Với $n = 93$, phân phối tiên nghiệm phẳng và phân phối tiên nghiệm yếu thông tin cho hậu nghiệm gần như trùng nhau, trung bình lệch nhau tối đa $0{,}04$ độ lệch chuẩn hậu nghiệm. Tiên nghiệm tập trung $\mathcal{N}(0, 0{,}5^2)$ kéo các hệ số về 0 tối đa $0{,}42$ độ lệch chuẩn, rõ nhất ở số hạng tương tác vốn được ít dữ liệu hỗ trợ nhất, đúng như (3.1) dự báo cho hệ số được ước lượng kém chính xác nếu chỉ dựa vào dữ liệu.

Đối chiếu lời giải dạng đóng với MCMC (bước 4, 5). Hậu nghiệm dạng đóng NIG của hệ số công suất có trung bình $-0{,}7101$, còn NUTS với cùng phân phối tiên nghiệm cho $-0{,}7099$. Thuật toán Metropolis–Hastings do nhóm tự triển khai cho cùng kết quả nhưng chỉ đạt cỡ mẫu hiệu dụng khoảng $1\,700$ từ $20\,000$ mẫu, so với khoảng $12\,000$ từ $8\,000$ mẫu của NUTS.

Tương quan giữa biến giải thích. Trọng lượng tương quan $0{,}74$ với công suất. Khi thêm trọng lượng vào mô hình, hệ số chuẩn hoá của công suất thay đổi từ khoảng $-0{,}71$ thành $-0{,}15$. Kết quả này cho thấy mối liên hệ giữa công suất và hiệu suất nhiên liệu phụ thuộc đáng kể vào việc có đưa trọng lượng vào mô hình hay không; không thể từ đó kết luận về quan hệ nhân quả.

Ngoại lai (bước 2, 6). Ba xe cỡ nhỏ có hiệu suất nhiên liệu cao so với phần còn lại của mẫu. Kiểm tra dự đoán hậu nghiệm cho thấy mô hình sai số chuẩn chưa tái tạo tốt giá trị lớn nhất. Chuyển sang hàm hợp lý Student-t, độ lệch chuẩn nhiễu hậu nghiệm giảm từ $0{,}47$ xuống $0{,}38$, Pareto k lớn nhất giảm từ $0{,}54$ xuống $0{,}46$, và mô hình này có ELPD ước lượng cao nhất theo PSIS-LOO.

Phạm vi dữ liệu (bước 7). Mức công suất 300 hp cần dự đoán trùng với giá trị lớn nhất trong mẫu. Khoảng dự đoán 95% cho một xe Mỹ 300 hp là 13,4 đến 20,6 MPG, chứa các giá trị quan sát của ba xe có công suất gần 300 hp; mô hình chỉ dùng công suất ngoại suy theo đường thẳng và dự đoán thấp hơn thực tế.

V. Kết luận

Ước lượng mô hình hồi quy tuyến tính Bayes gồm các bước chuẩn bị dữ liệu, đặc tả hàm hợp lý, chọn tiên nghiệm, tính hậu nghiệm, chẩn đoán hội tụ, kiểm tra mô hình, suy luận và dự đoán. Trong mô hình sai số chuẩn đang xét, với tiên nghiệm cố định, dữ liệu ảnh hưởng đến hậu nghiệm thông qua n, $X^\top X$, $X^\top y$ và $y^\top y$.

Cỡ mẫu ảnh hưởng đến vai trò tương đối của tiên nghiệm. Mức nhiễu, mức độ phân tán và tương quan của biến giải thích ảnh hưởng đến độ chính xác của ước lượng. Phạm vi dữ liệu giới hạn khả năng đánh giá dự đoán khi ngoại suy, còn thang đo ảnh hưởng đến cách lựa chọn tiên nghiệm và hiệu quả lấy mẫu. Ngoại lai và vi phạm giả định có thể dẫn đến kết quả sai lệch với mức bất định bị đánh giá thấp.

Các đặc điểm này cần được xem xét xuyên suốt quy trình: chuẩn hoá và biến đổi dữ liệu ở bước 1, lựa chọn hàm hợp lý ở bước 2, đặc tả tiên nghiệm và phân tích độ nhạy ở bước 3, lựa chọn thuật toán ở bước 4, và đánh giá kết quả qua các bước chẩn đoán, kiểm tra mô hình. Các mô phỏng và ví dụ trên dữ liệu xe minh hoạ mối liên hệ giữa đặc điểm của mẫu với những lựa chọn này.

A. Dẫn xuất hậu nghiệm khi σ^2 đã biết

Với phân phối tiên nghiệm $\beta \sim \mathcal{N}(m_0, V_0)$ và hàm hợp lý (1.1), bỏ các số hạng không chứa β,

$$\log p(\beta \mid y) = -\frac{1}{2\sigma^2}\|y - X\beta\|_2^2 - \frac{1}{2}(\beta - m_0)^\top V_0^{-1}(\beta - m_0) + \text{const.} \tag{A.1}$$

Khai triển và gom các số hạng bậc hai và bậc nhất theo β,

$$\log p(\beta \mid y) = -\frac{1}{2}\beta^\top \Big(V_0^{-1} + \tfrac{1}{\sigma^2}X^\top X\Big)\beta + \beta^\top \Big(V_0^{-1}m_0 + \tfrac{1}{\sigma^2}X^\top y\Big) + \text{const.} \tag{A.2}$$

Một phân phối chuẩn $\mathcal{N}(m_n, V_n)$ có log-mật độ $-\frac{1}{2}\beta^\top V_n^{-1}\beta + \beta^\top V_n^{-1}m_n + \text{const}$. Đồng nhất hệ số của hai biểu thức cho $V_n^{-1} = V_0^{-1} + X^\top X/\sigma^2$ và $V_n^{-1}m_n = V_0^{-1}m_0 + X^\top y/\sigma^2$, tức công thức (2.1). Vì (A.2) là dạng toàn phương xác định âm theo β, hậu nghiệm đúng là phân phối chuẩn, không chỉ xấp xỉ.

Phân phối điều kiện của σ^2 trong (2.4) có được theo cách tương tự: với β cố định, tích của hàm hợp lý và phân phối tiên nghiệm $\mathrm{IG}(a_0, b_0)$ tỉ lệ với $(\sigma^2)^{-(a_0+n/2)-1}\exp\big(-(b_0 + \frac{1}{2}\|y - X\beta\|_2^2)/\sigma^2\big)$, chính là mật độ của $\mathrm{IG}\big(a_0 + \frac{n}{2},\ b_0 + \frac{1}{2}\|y - X\beta\|_2^2\big)$.

Tài liệu tham khảo

[1] Andrew Gelman et al. *Bayesian Data Analysis*. 3rd ed. CRC Press, 2013.

[2] Peter D. Hoff. *A First Course in Bayesian Statistical Methods*. Springer, 2009.

[3] Stuart Geman and Donald Geman. "Stochastic Relaxation, Gibbs Distributions, and the Bayesian Restoration of Images". In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 6.6 (1984), pp. 721–741.

[4] W. K. Hastings. "Monte Carlo Sampling Methods Using Markov Chains and Their Applications". In: *Biometrika* 57.1 (1970), pp. 97–109.

[5] Matthew D. Hoffman and Andrew Gelman. "The No-U-Turn Sampler: Adaptively Setting Path Lengths in Hamiltonian Monte Carlo". In: *Journal of Machine Learning Research* 15 (2014), pp. 1593–1623.

[6] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.

[7] Aki Vehtari et al. "Rank-Normalization, Folding, and Localization: An Improved $\widehat{R}$ for Assessing Convergence of MCMC". In: *Bayesian Analysis* 16.2 (2021), pp. 667–718.

[8] Aki Vehtari, Andrew Gelman, and Jonah Gabry. "Practical Bayesian Model Evaluation Using Leave-One-Out Cross-Validation and WAIC". In: *Statistics and Computing* 27 (2017), pp. 1413–1432.