Báo cáo cuối kỳ: Hồi quy tuyến tính Bayes – Xe mới tại Mỹ năm 1993

Oct 10, 2026

1. Tổng quan đề tài

Nhóm dùng hồi quy tuyến tính Bayes để giải thích và dự đoán hiệu suất nhiên liệu trong thành phố (biến `City`) của 93 mẫu xe năm 1993 từ công suất, khối lượng và xuất xứ. Báo cáo gồm 6 chương, 4 chương lõi khớp đúng 4 yêu cầu (i)–(iv) của đề, và trả lời trực tiếp 4 câu hỏi trong tài liệu đính kèm.

#	Câu hỏi của đề	Cách trả lời bằng hồi quy Bayes	Mục
Q1	Quan hệ giữa các biến, so sánh các scatterplot	Ma trận scatterplot + hệ số hậu nghiệm và khoảng tin cậy hậu nghiệm (HDI 95%)	2.6, 5.3
Q2	Khác biệt giữa xe Mỹ và xe nước ngoài	Biến giả `USA` và tương tác `HP × USA`; tính P(β_USA > 0 | dữ liệu)	3.4, 5.4
Q3	Các điểm ngoại lai và lời giải thích	Posterior predictive check, phần dư chuẩn hoá, Pareto-k của PSIS-LOO, so sánh với likelihood Student-t	5.5
Q4	Chọn biến giải thích/phản hồi; dự đoán xe 300 hp	Phân phối dự đoán hậu nghiệm tại HP = 300, so với 3 xe thực tế gần 300 hp	5.6

2. Outline chi tiết báo cáo

Biến phản hồi chính là `City`, biến giải thích chính là `Horsepower`; `Weight` và `USA` được thêm dần qua 5 mô hình ứng viên. Các con số dưới đây lấy trực tiếp từ file CSV.

Chương 1. Giới thiệu (1–1,5 trang)

1. Bối cảnh thị trường xe Mỹ thập niên 1990: nhu cầu xe lớn hơn, xe thể thao, xe van và SUV.
2. Mục tiêu và 4 câu hỏi nghiên cứu (bảng ở mục 1).
3. Vì sao chọn cách tiếp cận Bayes: định lượng bất định bằng phân phối hậu nghiệm, đưa tri thức tiên nghiệm vào, dự đoán có khoảng tin cậy tự nhiên.

Chương 2. Dữ liệu sử dụng — yêu cầu (i)

1. Nguồn và cách lấy mẫu: mẫu ngẫu nhiên 93 xe từ *Consumer Reports 1993 Annual Auto Issue* và *PACE New Car & Truck 1993 Buying Guide*.

2. Từ điển biến: 25 cột, gồm biến liên tục (giá, nhiên liệu, kích thước, động cơ) và biến mã hoá (`Type` 1–6, `Airbag` 0–2, `Drive train` 0–2, `USA` 0/1).
3. Làm sạch dữ liệu:
   - Dấu `*` → NA: `luggage capacity` thiếu 11 dòng (9 xe van + Chevrolet Corvette, Mazda RX-7), `rear seat room` thiếu 2 dòng (Corvette, RX-7), `Cylinders` thiếu 1 dòng (RX-7, động cơ rotary).
   - Hai cột RPM lưu dạng chuỗi có dấu phẩy ("6,300") → chuyển sang số.
   - Các biến dùng trong mô hình chính (City, HP, Weight, USA) không thiếu dữ liệu, nên không cần loại dòng nào.
4. Đơn vị nhiên liệu — cần thống nhất trước khi viết: tiêu đề cột ghi "km/100L", PDF ghi "litres per 100km", nhưng giá trị 15–46 và Geo Metro = 46 cho thấy nhiều khả năng đây là dặm/gallon (MPG, càng cao càng tiết kiệm). Nhóm ghi rõ giả định; nếu muốn đổi sang L/100km thì dùng L/100km = 235,2 / MPG.
5. Thống kê mô tả: 48 xe Mỹ, 45 xe nước ngoài; HP từ 55 đến 300 (trung vị 140); City từ 15 đến 46 (trung vị 21); tương quan HP–City là −0,67, City–Open Road là 0,94.
6. EDA: ma trận scatterplot (City, Open Road, HP, Weight, Engine Size, Price) tô màu theo Mỹ/nước ngoài; boxplot City theo `Type`; đánh dấu sơ bộ các điểm lạ.

Chương 3. Quá trình mô hình hoá — yêu cầu (ii)

1. Cơ sở lý thuyết hồi quy tuyến tính: giả định của mô hình, biến giả và số hạng tương tác, đa cộng tuyến; khác biệt giữa ước lượng OLS (một giá trị) và Bayes (cả phân phối).
2. Chọn biến: City là biến phản hồi; HP là biến giải thích chính (đúng câu hỏi Q4). Weight và Engine Size tương quan mạnh với HP → kiểm tra đa cộng tuyến (tương quan, VIF) trước khi đưa cùng vào.
3. Biến đổi: so sánh City với log(City) vì quan hệ với HP có dạng cong; chuẩn hoá các biến giải thích để prior dễ đặt và MCMC hội tụ tốt.
4. Năm mô hình ứng viên:
   - M1: City ~ HP
   - M2: City ~ HP + USA
   - M3: City ~ HP + USA + HP × USA
   - M4: City ~ HP + Weight + USA
   - M5: mô hình tốt nhất trong M1–M4 với likelihood Student-t (kháng ngoại lai)
5. Đặc tả đầy đủ cho M3 (các mô hình khác bỏ bớt số hạng):

$$
\begin{aligned}
y_i &\sim \mathrm{N}\left(\mu_i,\ \sigma^2\right) \\
\mu_i &= \beta_0 + \beta_1\,\mathrm{HP}_i + \beta_2\,\mathrm{USA}_i + \beta_3\,\mathrm{HP}_i\,\mathrm{USA}_i \\
\beta_j &\sim \mathrm{N}\left(0,\ 2.5^2\right) \quad (\text{trên thang đã chuẩn hoá}) \\
\sigma &\sim \text{Half-Normal}(1)
\end{aligned}
$$

6. Cơ sở lý thuyết và biện luận tiên nghiệm: prior phẳng, yếu thông tin (weakly informative) và chặt; prior liên hợp và không liên hợp; kiểm tra bằng prior predictive check (dữ liệu sinh ra từ prior phải nằm trong miền hợp lý, ví dụ City không âm, không quá 80).
7. Phân tích độ nhạy: chạy lại với 2–3 bộ prior (phẳng, yếu thông tin, chặt) và so sánh hậu nghiệm.

Chương 4. Quá trình ước lượng Bayes — yêu cầu (iii)

1. Nền tảng: định lý Bayes, hậu nghiệm $\propto$ likelihood × tiên nghiệm. Trình bày lời giải dạng đóng cho M1 với prior liên hợp Normal–Inverse-Gamma để đối chiếu với MCMC.
2. Lấy mẫu MCMC bằng NUTS (PyMC hoặc brms/Stan): 4 chuỗi × 2000 vòng, 1000 vòng warm-up, seed cố định.
3. Chẩn đoán hội tụ: R-hat < 1,01, ESS bulk/tail > 400, trace plot, rank plot, số divergence = 0.
4. Bảng tóm tắt hậu nghiệm cho từng mô hình: mean, sd, HDI 95%; đồ thị phân phối hậu nghiệm của các hệ số.

Chương 5. Đánh giá kết quả và trả lời câu hỏi — yêu cầu (iv)

1. Posterior predictive check: so mật độ dữ liệu thật với dữ liệu tái tạo từ hậu nghiệm.
2. So sánh mô hình: PSIS-LOO (ELPD) và WAIC; chọn mô hình cuối, có giải thích.
3. Trả lời Q1: diễn giải β_{HP} (mỗi 10 hp tăng thêm làm City thay đổi bao nhiêu, kèm HDI); so các scatterplot.
4. Trả lời Q2: hậu nghiệm của β_{USA} và $\beta_{HP \times USA}$; $P(\beta_{USA} > 0 \mid \text{dữ liệu})$; hai đường hồi quy kèm dải HDI cho xe Mỹ và nước ngoài.
5. Trả lời Q3: ứng viên ngoại lai để kiểm tra — Geo Metro (City 46), Honda Civic (42), Suzuki Swift (39) tiết kiệm bất thường; Mazda RX-7 (1,3 L nhưng 255 hp, động cơ rotary); nhóm xe van nặng, City thấp; Mercedes-Benz 300E (giá tối đa 80). Lý giải từng xe và so kết quả M3 với M5 (Student-t).
6. Trả lời Q4: phân phối dự đoán hậu nghiệm tại HP = 300, báo khoảng dự đoán 95%; đối chiếu với 3 xe thực tế ≥ 295 hp: Cadillac Seville (295 hp, City 16), Chevrolet Corvette (300, 17), Dodge Stealth (300, 18). Lưu ý 300 hp là giá trị lớn nhất trong mẫu nên dự đoán nằm ở rìa dữ liệu.
7. Hạn chế: mẫu nhỏ (93), dữ liệu năm 1993, quan hệ tương quan không phải nhân quả, ngoại suy ngoài khoảng 55–300 hp không đáng tin.

Chương 6. Kết luận (0,5–1 trang)

Tóm tắt câu trả lời cho Q1–Q4 bằng số liệu hậu nghiệm và gợi ý hướng mở rộng (mô hình phân cấp theo `Type`, thêm biến).

Phụ lục

Code đầy đủ (notebook), bảng dữ liệu đã làm sạch, bảng hậu nghiệm của mọi mô hình, tài

Code đầy đủ (notebook), bảng dữ liệu đã làm sạch, bảng hậu nghiệm của mọi mô hình, tài liệu tham khảo.

3. Phân công công việc

Mỗi thành viên làm đủ ba việc: tìm hiểu và viết một phần lý thuyết, lập trình một module trong notebook chung, và viết phần phân tích kèm câu hỏi tương ứng. Phần lý thuyết nằm ngay trong chương dùng đến nó, nên báo cáo không cần một chương lý thuyết riêng. Thay "TV1–TV5" bằng tên thật khi nhóm chốt.

Thành viên	Lý thuyết tìm hiểu và viết	Lập trình (module trong notebook chung)	Viết mục và trả lời câu hỏi	Review chéo cho
TV1 (nhóm trưởng)	Định lý Bayes; prior, likelihood, posterior; prior liên hợp Normal-Inverse-Gamma (mục 4.1)	`01_conjugate`: tính hậu nghiệm dạng đóng cho M1 bằng NumPy/SciPy, đối chiếu với kết quả MCMC	Ch.1, mục 4.1, Ch.6; ghép và định dạng báo cáo; slide	TV4
TV2	Hồi quy tuyến tính: giả định, biến giả, tương tác, đa cộng tuyến; so sánh OLS và Bayes (mục 3.1)	`02_data_eda`: làm sạch dữ liệu, thống kê mô tả, ma trận scatterplot, VIF, hồi quy OLS làm mốc so sánh	Ch.2; trả lời Q1	TV3
TV3	Chọn tiên nghiệm (phẳng, yếu thông tin, chặt), prior predictive check, likelihood Student-t (mục 3.6–3.7)	`03_models`: viết M1–M5 trong PyMC, chạy prior predictive check và phân tích độ nhạy	Ch.3; trả lời Q2	TV5
TV4	MCMC: Metropolis-Hastings, HMC/NUTS, R-hat, ESS (mục 4.2–4.3)	`04_sampling`: chạy NUTS và chẩn đoán hội tụ; tự cài Metropolis-Hastings cho M1 để minh hoạ	Mục 4.2–4.4	TV1
TV5	Posterior predictive, PSIS-LOO, WAIC, Pareto-k, khoảng dự đoán (mục 5.1–5.2)	`05_evaluation`: PPC, so sánh mô hình bằng `az.compare`, phát hiện ngoại lai, dự đoán tại 300 hp	Mục 5.1–5.2, 5.7; trả lời Q3, Q4	TV2

Điểm giao giữa các thành viên cần lưu ý:

- TV2 bàn giao `data_clean.csv` trước khi các module khác chạy; mọi người dùng chung file này.
- Mỗi module lưu kết quả ra file (ví dụ `idata_M3.nc`) cho module sau dùng; TV4 ghép 5

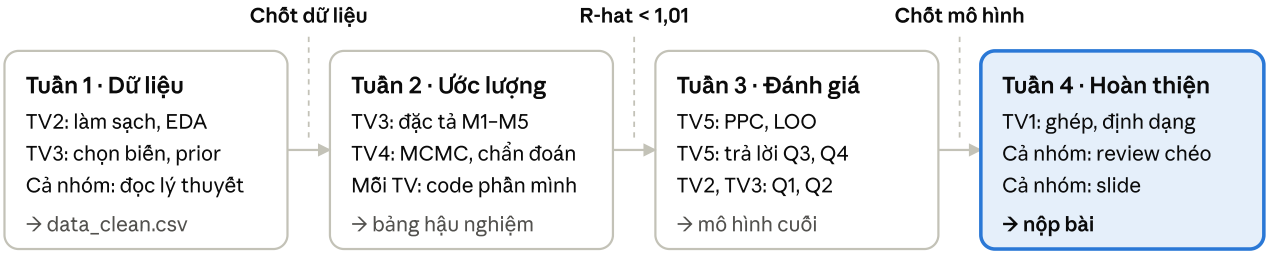
module thành một notebook chạy được từ đầu đến cuối.

- TV3 viết code mô hình, TV4 chạy và chẩn đoán; hai bạn cùng kiểm tra code khớp với đặc tả.
- TV1 đối chiếu hậu nghiệm dạng đóng với kết quả MCMC của TV4; hai kết quả phải gần nhau, nếu lệch là dấu hiệu code sai.
- Cuối tuần 1, mỗi người trình bày phần lý thuyết của mình cho cả nhóm (khoảng 10 phút), để ai cũng nắm toàn bộ quy trình khi vấn đáp.
- Câu trả lời Q1, Q2 (TV2, TV3) dùng mô hình cuối do TV5 chọn.

4. Lịch trình, quy ước chung và checklist

Kế hoạch chia 4 tuần, mỗi tuần khoá một mốc để tuần sau không phải làm lại. Nhóm cần điền hạn nộp chính thức để gắn ngày cụ thể vào từng tuần.

Mỗi tuần kết thúc bằng một mốc chốt trước khi sang giai đoạn sau



Không qua mốc thì không sang tuần sau: dữ liệu chưa chốt thì chưa chạy mô hình, chuỗi MCMC chưa hội tụ thì chưa diễn giải hệ số.

Quy ước chung

- Công cụ: Python (PyMC + ArviZ) hoặc R (brms + loo); cả nhóm dùng một công cụ và một notebook chung do TV4 quản lý.
- Seed cố định (ví dụ 2026) để mọi người ra cùng kết quả.
- Hình đặt tên theo mục (`fig_2_6_scatter.png`), có tiêu đề, nhãn trục và đơn vị.
- Thuật ngữ thống nhất: tiên nghiệm (prior), hậu nghiệm (posterior), khoảng tin cậy hậu nghiệm (HDI 95%), phân phối dự đoán hậu nghiệm.
- Ghi rõ giả định đơn vị của `City` (MPG) ngay trong mục 2.4 và dùng nhất quán.

Checklist trước khi nộp

- [ ] Mô tả dữ liệu đầy đủ: nguồn, biến, dữ liệu thiếu, đơn vị (i)
- [ ] Đặc tả mô hình có công thức, prior được biện luận, prior predictive check (ii)
- [ ] Chẩn đoán hội tụ đạt chuẩn cho mọi mô hình được báo cáo (iii)
- [ ] So sánh mô hình bằng LOO/WAIC và posterior predictive check (iv)