ĐẠI HỌC QUỐC GIA HÀ NỘI

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA TOÁN - CƠ - TIN HỌC



BÁO CÁO CUỐI KỲ

MÔ HÌNH HỒI QUY TUYẾN TÍNH BAYES VÀ ỨNG DỤNG

ĐỀ TÀI:

HỒI QUY TUYẾN TÍNH BAYES CHO HIỆU SUẤT NHIÊN LIỆU CỦA XE MỚI TẠI MỸ NĂM 1993

Nhóm 10 thực hiện:	Nguyễn Thục Anh	25007949
	Bùi Quang Huy	25007877
	Nguyễn Thị Bích Ngọc	25007937
	Nguyễn Thu Ngân	25007865
	Nguyễn Hồng Phúc	25007860

Hà Nội, tháng 10 năm 2026

Tóm tắt

Báo cáo này áp dụng hồi quy tuyến tính Bayes để phân tích hiệu suất nhiên liệu trong thành phố (biến City, đơn vị MPG) của 93 mẫu xe mới bán tại Mỹ năm 1993, với các biến giải thích là công suất, trọng lượng và xuất xứ. Nhóm xây dựng năm mô hình và ước lượng bằng thuật toán NUTS trong PyMC. Sau khi kiểm tra hội tụ, các mô hình được so sánh bằng PSIS-LOO và WAIC. Riêng mô hình đơn giản nhất còn được đối chiếu với nghiệm giải tích từ tiên nghiệm liên hợp Normal–Inverse-Gamma.

Trọng lượng là biến có liên hệ chặt nhất với City. Khi đưa trọng lượng vào mô hình, hệ số của công suất gần như bằng 0, trong khi mỗi $100\,\text{kg}$ tăng thêm ứng với City giảm khoảng 6,2%. Chênh lệch giữa xe Mỹ và xe nước ngoài cũng thu hẹp đáng kể. Mô hình cuối cùng dùng hàm hợp lý Student-t nhằm hạn chế ảnh hưởng của một số xe cỡ nhỏ tiết kiệm nhiên liệu bất thường. Với một xe Mỹ 300 hp nặng $1\,681\,\text{kg}$, trung vị dự đoán của City vào khoảng 16,6 MPG, khoảng dự đoán 95% từ 13,4 đến 20,6 MPG. Giá trị thực tế của ba xe gần 300 hp trong mẫu đều rơi vào khoảng này.

Mục lục

Tóm tắt **1**

I Giới thiệu **5**

1.1 Bối cảnh 5

1.2 Mục tiêu và câu hỏi nghiên cứu 5

1.3 Vì sao chọn cách tiếp cận Bayes 5

II Dữ liệu sử dụng **7**

2.1 Nguồn và cách lấy mẫu 7

2.2 Danh sách biến 7

2.3 Làm sạch dữ liệu 7

2.4 Đơn vị nhiên liệu 7

2.5 Thống kê mô tả 8

2.6 Phân tích khám phá 9

III Quá trình mô hình hoá **11**

3.1 Cơ sở lý thuyết hồi quy tuyến tính . . . 11
3.2 Chọn biến . . . 11
3.3 Biến đổi biến . . . 11
3.4 Năm mô hình ứng viên . . . 13
3.5 Đặc tả đầy đủ cho M3 . . . 13
3.6 Chọn tiên nghiệm và kiểm tra dự đoán tiên nghiệm . . . 13
3.7 Ảnh hưởng của tiên nghiệm đến kết quả . . . 14

IV Quá trình ước lượng Bayes **16**

4.1 Công thức hậu nghiệm cho M1 . . . 16
4.2 Lấy mẫu MCMC . . . 16
4.3 Chẩn đoán hội tụ . . . 17
4.4 Bảng tóm tắt hậu nghiệm . . . 18

V Đánh giá kết quả và trả lời câu hỏi **21**

5.1 Kiểm tra dự đoán hậu nghiệm . . . 21
5.2 So sánh mô hình . . . 21
5.3 Trả lời Q1: quan hệ giữa các biến . . . 21
5.4 Trả lời Q2: xe Mỹ và xe nước ngoài . . . 23
5.5 Trả lời Q3: các điểm ngoại lai . . . 24
5.6 Trả lời Q4: dự đoán cho xe 300 hp . . . 26
5.7 Hạn chế . . . 27

VI Kết luận **28**

A Code và dữ liệu **29**

B Khai báo sử dụng AI **31**

Tài liệu tham khảo **32**

Danh sách hình vẽ

2.1 Ma trận biểu đồ phân tán các biến chính, tô màu theo xuất xứ. 9
2.2 City theo loại xe; điểm tô màu theo xuất xứ. 10

3.1 Phần dư OLS theo giá trị khớp, với City và log(City) làm biến phản hồi; đường cam là đường làm trơn LOWESS. 12
3.2 Phân phối City mô phỏng từ tiên nghiệm của M3 với ba tiên nghiệm, so với dữ liệu thật; trục hoành theo thang logarit, đường đứt đỏ ở 80 MPG. 14
3.3 Hậu nghiệm của M3 với ba tiên nghiệm, trung bình và HDI 95%. 15

4.1 Hậu nghiệm của M1: mật độ t tính bằng công thức (đen), NUTS với cùng tiên nghiệm NIG (xanh) và NUTS với tiên nghiệm của M1 (đỏ). 17
4.2 Biểu đồ vết của Metropolis–Hastings tự viết cho M1, bốn chuỗi. 18
4.3 Biểu đồ vết của M5: mật độ hậu nghiệm theo chuỗi (trái) và giá trị qua các vòng lặp (phải). . . 19
4.4 Hệ số hậu nghiệm của M1–M5 trên thang chuẩn hoá, trung bình và HDI 95%. 20

5.1 Kiểm tra dự đoán hậu nghiệm: mật độ dữ liệu thật (đen) và 100 bộ dữ liệu sinh từ hậu nghiệm (xanh). 22
5.2 ELPD-LOO của năm mô hình, kèm sai số chuẩn và sai số chuẩn của chênh lệch so với mô hình tốt nhất. 22
5.3 M1: City theo HP, với HDI 95% của trung vị có điều kiện (xanh đậm) và khoảng dự đoán 95% (xanh nhạt). 23
5.4 Đường hồi quy và HDI 95% cho xe Mỹ và xe nước ngoài: M3 với tương tác (trái) và M5 với Weight cố định ở mức trung bình (phải). 24
5.5 Phần dư chuẩn hoá theo giá trị dự đoán của M4 (trái) và Pareto k của từng quan sát với M4 và M5 (phải). 25
5.6 Phân phối dự đoán hậu nghiệm cho một xe Mỹ 300 hp theo M1 và M5; đường đỏ là City của ba xe thật gần 300 hp. 27

Danh sách bảng

1.1 Bốn câu hỏi của đề và cách trả lời bằng hồi quy Bayes. 6

2.1 Các nhóm biến trong bộ dữ liệu gốc. 8
2.2 Thống kê mô tả các biến chính, $n = 93$. 8

3.1 Hệ số phóng đại phương sai của hai bộ biến giải thích. 12
3.2 So sánh hai thang của biến phản hồi trong hồi quy OLS theo HP; logarit hàm hợp lý và AIC tính trên thang City. 12
3.3 Năm mô hình ứng viên; biến phản hồi luôn là $\log(\text{City})$ đã chuẩn hoá. 13
3.4 Kiểm tra dự đoán tiên nghiệm cho M3 với ba tiên nghiệm, mỗi tiên nghiệm $1\,000$ lần mô phỏng. 14

4.1 Hậu nghiệm của β_{HP} trong M1, thang chuẩn hoá: công thức so với MCMC. 17
4.2 Chẩn đoán hội tụ của năm mô hình; giá trị xấu nhất trên mọi tham số. 18
4.3 Trung bình hậu nghiệm và HDI 95% của các hệ số, thang chuẩn hoá. Cột σ là độ lệch chuẩn sai số với M1–M4 và tham số thang đo Student-t với M5. 19

5.1 So sánh mô hình bằng PSIS-LOO và WAIC; chênh lệch tính so với M5. 22
5.2 Hệ số của USA trong ba mô hình; chênh lệch City đổi ra phần trăm. 24
5.3 Các xe được xét là ngoại lai, theo M4. 25
5.4 Dự đoán City cho một xe 300 hp, $1\,681$ kg nếu mô hình có Weight. 26
5.5 Dự đoán của M5 cho ba xe thật có từ 295 hp trở lên. 26

A.1 Các module trong notebook chung. 30

I. Giới thiệu

1.1 Bối cảnh

Đầu thập niên 1990, thị trường ô tô Mỹ phát triển mạnh. Thu nhập tăng khiến người mua ưa chuộng các dòng xe lớn và mạnh như xe thể thao, sedan cỡ lớn, xe van và SUV. Những xe này thường tiêu tốn nhiều nhiên liệu hơn, vì vậy công suất và trọng lượng ảnh hưởng thế nào đến mức tiêu hao nhiên liệu là vấn đề được cả người tiêu dùng lẫn nhà sản xuất quan tâm. Bộ dữ liệu của đề bài, gồm một mẫu ngẫu nhiên các xe bán ra năm 1993, cho phép xem xét vấn đề này một cách định lượng.

1.2 Mục tiêu và câu hỏi nghiên cứu

Báo cáo lấy City làm biến phản hồi và Horsepower làm biến giải thích chính. Hai biến Weight và USA lần lượt được bổ sung qua năm mô hình. Các chương từ chương II đến chương V tương ứng với bốn yêu cầu (i)–(iv) của đề. Bốn câu hỏi trong tài liệu đính kèm và cách nhóm trả lời được tóm tắt ở bảng 1.1.

1.3 Vì sao chọn cách tiếp cận Bayes

Điểm mạnh của cách tiếp cận Bayes là mỗi hệ số được mô tả bằng cả một phân phối hậu nghiệm thay vì một giá trị ước lượng duy nhất. Nhờ đó, những câu hỏi như "xe Mỹ có kém tiết kiệm nhiên liệu hơn không" có thể trả lời trực tiếp bằng một xác suất. Tiên nghiệm ít thông tin giúp loại bỏ các giá trị phi thực tế (chẳng hạn City âm hoặc vượt 80 MPG) mà không lấn át thông tin từ dữ liệu. Ngoài ra, phân phối dự đoán hậu nghiệm phản ánh đồng thời độ bất định của tham số và sai số của từng quan sát. Điều này đặc biệt quan trọng với câu hỏi Q4, khi điểm cần dự đoán nằm ở biên của dữ liệu. Phần lý thuyết trong báo cáo chủ yếu tham khảo [1, 2].

Bảng 1.1: Bốn câu hỏi của đề và cách trả lời bằng hồi quy Bayes.

#	Câu hỏi của đề	Cách trả lời	Mục
Q1	Quan hệ giữa các biến, so sánh các biểu đồ phân tán	Ma trận biểu đồ phân tán, hệ số hậu nghiệm và HDI 95%	2.6, 5.3
Q2	Khác biệt giữa xe Mỹ và xe nước ngoài	Biến giả USA, tương tác HP $\times$ USA, xác suất $P(\beta_{\text{USA}} > 0 \mid y)$	3.4, 5.4
Q3	Các điểm ngoại lai và lời giải thích	Kiểm tra dự đoán hậu nghiệm, phần dư chuẩn hoá, Pareto k của PSIS-LOO, hàm hợp lý Student-t	5.5
Q4	Chọn biến giải thích và phản hồi; dự đoán xe 300 hp	Phân phối dự đoán hậu nghiệm tại HP $= 300$, so với ba xe thật gần 300 hp	5.6

II. Dữ liệu sử dụng

2.1 Nguồn và cách lấy mẫu

Bộ dữ liệu gồm 93 mẫu xe mới bán tại Mỹ năm 1993, mỗi dòng ứng với một mẫu xe. Các xe được chọn ngẫu nhiên từ *The 1993 Cars – Annual Auto Issue* của Consumer Reports [3] và *PACE New Car & Truck 1993 Buying Guide* [4].

2.2 Danh sách biến

File dữ liệu có 25 cột, gồm tên xe, 20 biến liên tục và 4 biến mã hoá (bảng 2.1). Bốn biến được dùng trong mô hình được in đậm.

2.3 Làm sạch dữ liệu

Các ô đánh dấu $*$ trong file gốc được chuyển thành giá trị thiếu. Biến Luggage capacity thiếu 11 dòng (9 xe van, Chevrolet Corvette và Mazda RX-7), Rear seat room thiếu 2 dòng (Corvette và RX-7), còn Cylinders thiếu 1 dòng ở RX-7 do xe này dùng động cơ rotary, không có xi-lanh theo nghĩa thông thường. Hai cột RPM được lưu dưới dạng chuỗi có dấu phẩy phân cách hàng nghìn (ví dụ "6,300") nên cần chuyển sang dạng số. Do bốn biến dùng trong mô hình (City, Horsepower, Weight và USA) không thiếu giá trị nào, toàn bộ 93 dòng được giữ lại và lưu vào `data_clean.csv`.

2.4 Đơn vị nhiên liệu

Tiêu đề cột ghi đơn vị "km/100L", còn tài liệu đi kèm lại ghi "litres per 100km", hai cách ghi mang ý nghĩa ngược nhau. Tuy nhiên, cả hai đều không khớp với dữ liệu. Các giá trị chỉ dao động từ 15 đến 46, và Geo Metro, xe nhỏ nhẹ nhất mẫu (55 hp, 769 kg), lại có giá trị cao nhất. Để xác định đúng đơn vị, nhóm đối chiếu từng dòng với bộ dữ liệu `Cars93` trong gói R `MASS` [5, 6], vốn có cùng 93 mẫu xe theo đúng thứ tự. Kết quả đối chiếu như sau.

- City khớp hoàn toàn với `MPG.city` ở cả 93 dòng, Open Road khớp với `MPG.highway`. Theo tài liệu của

Bảng 2.1: Các nhóm biến trong bộ dữ liệu gốc.

Nhóm	Biến
Giá (nghìn USD)	Min Price, Mid Price, Max Price
Nhiên liệu (MPG)	**City**, Open Road
Động cơ	**Horsepower** (hp), Engine Size (L), Cylinders, RPM tại công suất cực đại, RPM khi chạy đều, Fuel Tank (L)
Kích thước	**Weight** (kg), Length, Wheelbase, Width (cm), U-turn (m), Rear seat (cm), Luggage (m^3), Passengers
Mã hoá	Type 1–6 (Small, Midsize, Large, Compact, Sporty, Van); Airbag 0–2; Drive train 0–2; Manual 0/1; **USA** 0/1 (1 là xe Mỹ)

Bảng 2.2: Thống kê mô tả các biến chính, $n = 93$.

Biến	Trung bình	Độ lệch chuẩn	Nhỏ nhất	Trung vị	Lớn nhất
City (MPG)	22,4	5,6	15	21	46
Open Road (MPG)	29,1	5,3	20	28	50
Horsepower (hp)	143,8	52,4	55	140	300
Weight (kg)	1 394	268	769	1 379	1 862
Engine Size (L)	2,7	1,0	1,0	2,4	5,7
Mid Price (nghìn USD)	19,5	9,7	7,4	17,7	61,9

`MASS`, hai biến này có đơn vị dặm trên gallon Mỹ theo xếp hạng của EPA.

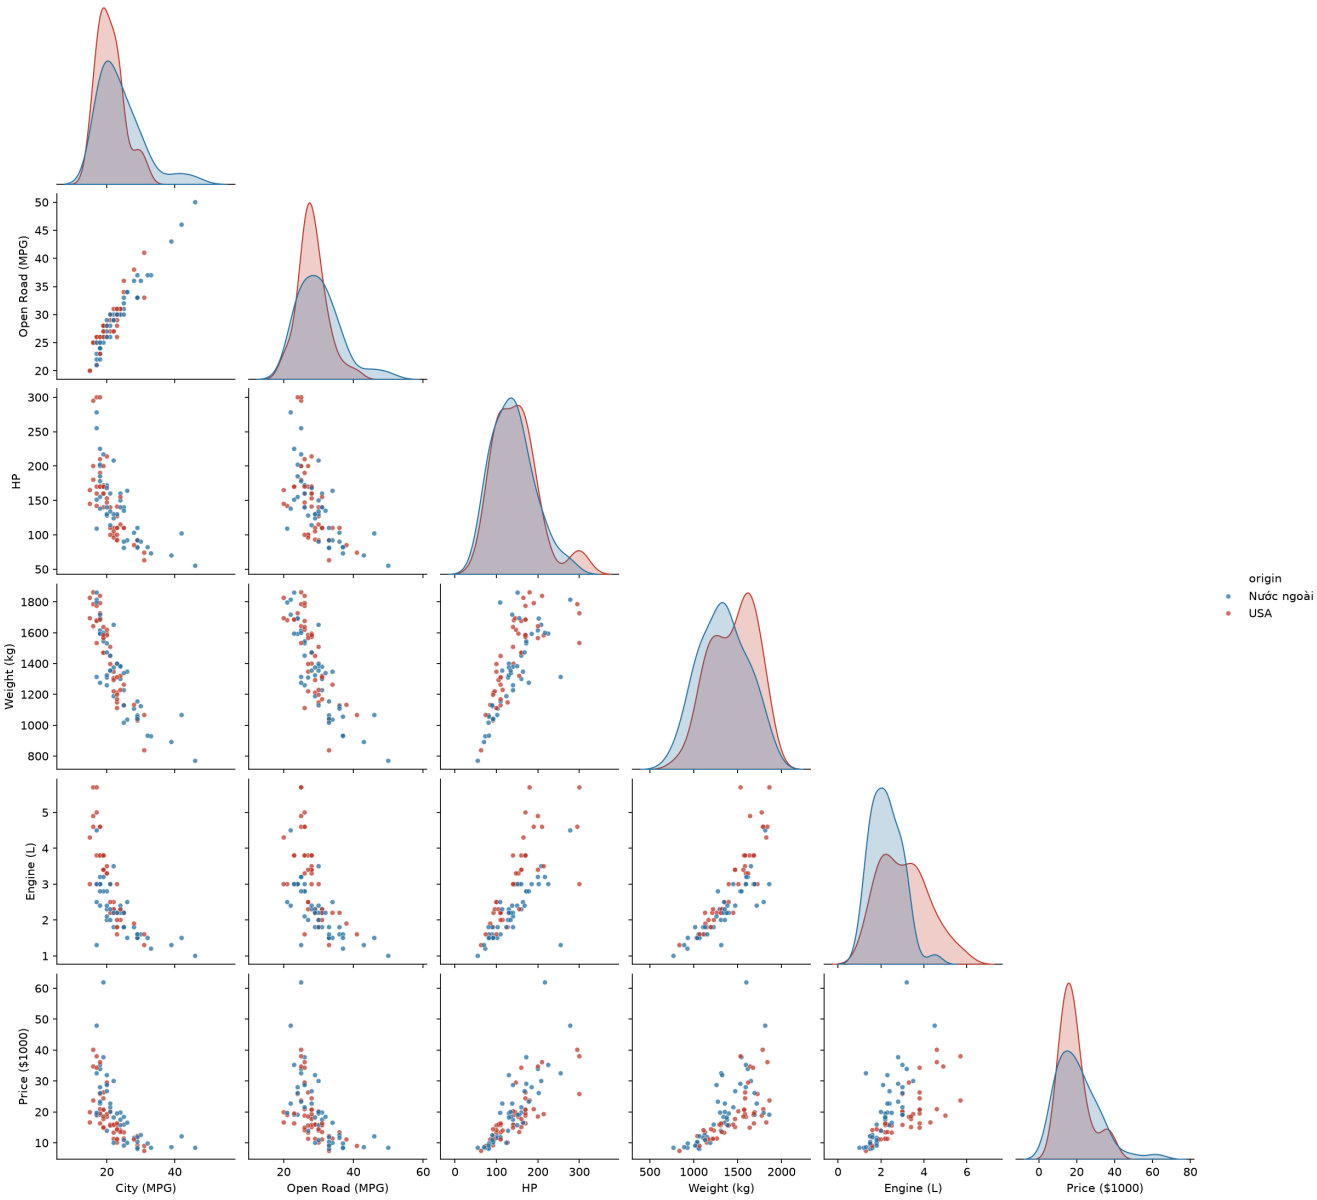
- Horsepower cũng khớp ở cả 93 dòng, còn Weight bằng `Weight` (pound) nhân với $0{,}4536$, sai lệch không quá $0{,}5$ kg do làm tròn. Chẳng hạn, Acura Integra có City 25, Open Road 31, 140 hp và 1 227 kg, so với 25, 31, 140 hp và 2705 lb trong `Cars93`.

Như vậy, bộ Q_10 thực chất là `Cars93` với một số cột đã đổi sang hệ mét, riêng hai cột nhiên liệu vẫn giữ nguyên giá trị nhưng bị ghi sai đơn vị. Từ đây trở đi, báo cáo dùng đơn vị MPG (dặm trên gallon, giá trị càng cao thì xe càng tiết kiệm). Có thể quy đổi sang lít trên 100 km theo công thức $\text{L/100km} = 235{,}2/\text{MPG}$.

2.5 Thống kê mô tả

Mẫu gồm 48 xe Mỹ và 45 xe nước ngoài. Công suất dao động từ 55 đến 300 hp (trung vị 140), City từ 15 đến 46 MPG (trung vị 21), chi tiết ở bảng 2.2. HP và City có hệ số tương quan $-0{,}67$, còn City và Open Road tương quan tới $0{,}94$.

So với xe nước ngoài, xe Mỹ trung bình nặng hơn (1 449 kg so với 1 335 kg), dung tích động cơ lớn hơn (3,1 L so với 2,2 L) và kém tiết kiệm nhiên liệu hơn (City 21,0 so với 23,9 MPG), dù công suất trung bình của hai nhóm khá gần nhau (147,5 so với 139,9 hp). Điều này gợi ý rằng chênh lệch City giữa hai nhóm có thể đến từ trọng lượng nhiều hơn là từ công suất. Giả thuyết này được kiểm tra ở mục 5.4.

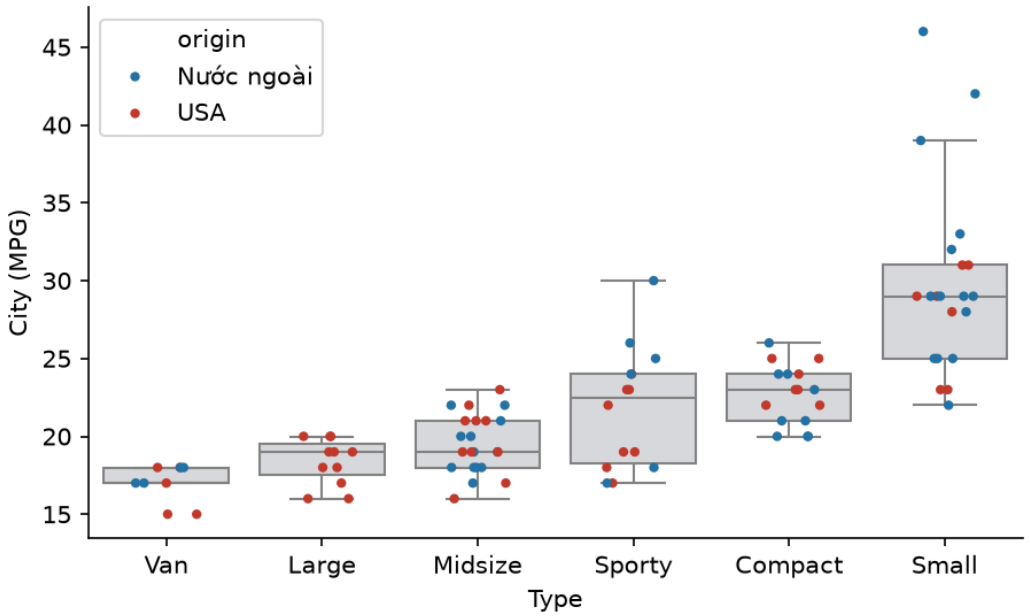


Hình 2.1: Ma trận biểu đồ phân tán các biến chính, tô màu theo xuất xứ.

2.6 Phân tích khám phá

Ma trận biểu đồ phân tán (hình 2.1) cho thấy City giảm khi HP, Weight và Engine Size tăng, nhưng không theo đường thẳng. Mức giảm nhanh ở nhóm xe nhỏ rồi chậm dần ở nhóm xe lớn. Xe nước ngoài tập trung ở vùng xe nhẹ, động cơ nhỏ và City cao, trong khi xe Mỹ thường nặng hơn và có động cơ lớn hơn. Các điểm của City và Open Road gần như nằm trên một đường thẳng, nên hai biến này nhiều khả năng biến động theo cùng một xu hướng. Vì vậy, báo cáo chỉ xây dựng mô hình cho City.

Xét theo loại xe (hình 2.2), nhóm Small tiết kiệm nhiên liệu nhất, còn Van và Large tốn nhiên liệu nhất. Khi chạy thử hồi quy OLS $\log(\text{City}) \sim \text{HP}$, có năm xe có phần dư studentised vượt ngưỡng ± 2, gồm Honda Civic $(+3{,}6)$, Geo Metro $(+3{,}2)$, Suzuki Swift $(+2{,}4)$, Ford Aerostar $(-2{,}4)$ và Volkswagen Eurovan $(-2{,}3)$. Các xe



Hình 2.2: City theo loại xe; điểm tô màu theo xuất xứ.

này sẽ được xem xét lại với mô hình đầy đủ ở mục 5.5.

III. Quá trình mô hình hoá

3.1 Cơ sở lý thuyết hồi quy tuyến tính

Hồi quy tuyến tính mô tả biến phản hồi như một hàm tuyến tính của các biến giải thích cộng với một sai số ngẫu nhiên:

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i, \qquad \varepsilon_i \sim \mathcal{N}(0, \sigma^2). \tag{3.1}$$

Mô hình dựa trên các giả định: quan hệ tuyến tính (có thể sau khi biến đổi biến), các sai số độc lập, có phương sai không đổi và tuân theo phân phối chuẩn. Biến giả USA nhận giá trị 1 với xe Mỹ và 0 với xe nước ngoài, do đó hệ số của nó chính là chênh lệch hệ số chặn giữa hai nhóm. Số hạng tương tác HP $\times$ USA cho phép độ dốc theo HP khác nhau giữa hai nhóm. Khi các biến giải thích tương quan mạnh với nhau, ước lượng hệ số trở nên kém ổn định và khó diễn giải riêng lẻ. Hiện tượng này gọi là đa cộng tuyến và thường được đo bằng hệ số phóng đại phương sai (VIF).

Phương pháp bình phương tối thiểu (OLS) cho ra một ước lượng điểm kèm khoảng tin cậy theo quan điểm tần suất. Trong khi đó, cách tiếp cận Bayes cho ra toàn bộ phân phối hậu nghiệm của từng hệ số. Khi dùng tiên nghiệm ít thông tin, trung bình hậu nghiệm thường rất gần ước lượng OLS. Ví dụ, hệ số β_{HP} của M3 bằng $-0{,}860$ theo OLS và $-0{,}859$ theo Bayes.

3.2 Chọn biến

City được chọn làm biến phản hồi và HP làm biến giải thích chính, đúng như yêu cầu của câu hỏi Q4. Weight và Engine Size đều tương quan mạnh với HP (lần lượt $0{,}74$ và $0{,}73$) và với nhau ($0{,}85$), vì vậy nhóm tính VIF trước khi đưa cả ba biến vào mô hình (bảng 3.1). Tuy tất cả VIF đều nhỏ hơn 5, Engine Size gần như không bổ sung thêm thông tin so với Weight nên chỉ Weight được giữ lại. Với bộ biến của M4, VIF lớn nhất chỉ là $2{,}34$.

3.3 Biến đổi biến

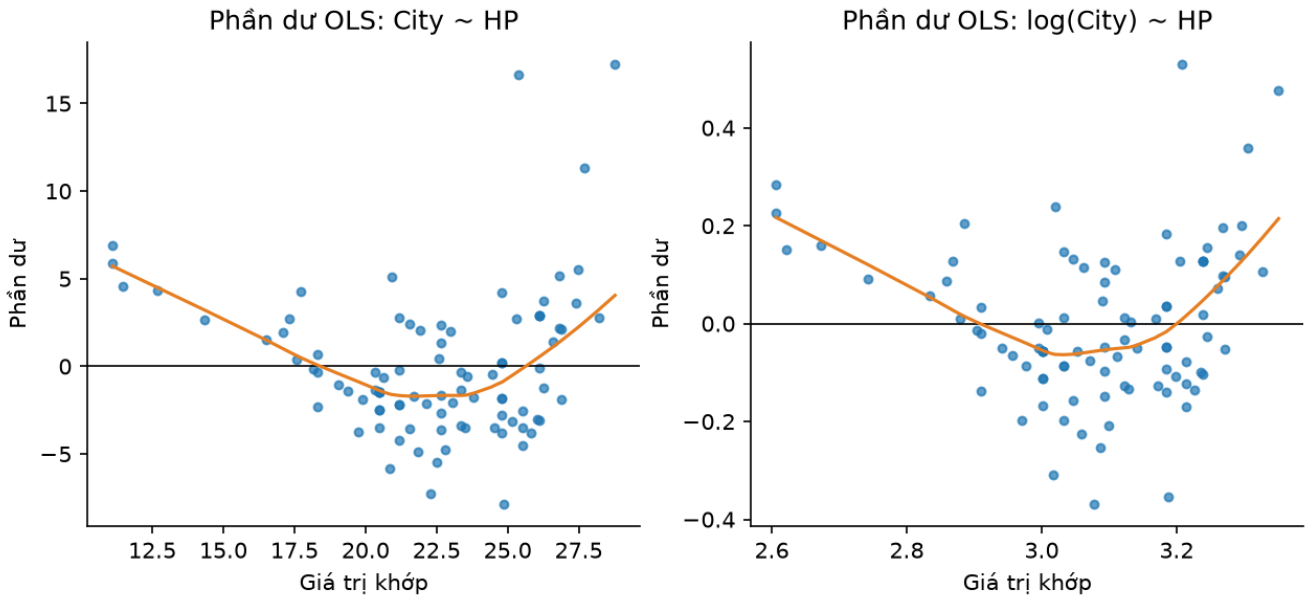
Do quan hệ giữa City và HP có dạng cong, nhóm so sánh hai phương án: hồi quy OLS của City theo HP và của $\log(\text{City})$ theo HP. Để hai mô hình so sánh được với nhau, logarit hàm hợp lý của mô hình logarit được quy về thang City bằng cách cộng thêm số hạng Jacobian $-\sum_i \log \text{City}_i$. Kết quả ở bảng 3.2 cho thấy $\log(\text{City})$ khớp

Bảng 3.1: Hệ số phóng đại phương sai của hai bộ biến giải thích.

Biến	HP + Weight + Engine Size	M4: HP + Weight + USA
HP	2,42	2,24
Weight	3,93	2,34
Engine Size	3,84	–
USA	–	1,07

Bảng 3.2: So sánh hai thang của biến phản hồi trong hồi quy OLS theo HP; logarit hàm hợp lý và AIC tính trên thang City.

Biến phản hồi	R^2	Logarit hàm hợp lý	AIC
City	0,452	−264,0	534,0
log(City)	0,506	−246,0	498,0



Hình 3.1: Phần dư OLS theo giá trị khớp, với City và log(City) làm biến phản hồi; đường cam là đường làm trơn LOWESS.

dữ liệu tốt hơn hẳn, với AIC thấp hơn 36 đơn vị. Đường làm trơn phần dư ở hình 3.1 cũng không còn dạng cong.

Do đó, tất cả các mô hình đều dùng biến phản hồi $y = \log(\text{City})$ đã chuẩn hoá. HP và Weight cũng được chuẩn hoá (trừ trung bình, chia độ lệch chuẩn mẫu), còn USA giữ nguyên dạng 0/1. Việc chuẩn hoá đưa các hệ số về cùng một thang, giúp đặt tiên nghiệm thuận tiện hơn và cải thiện khả năng hội tụ của MCMC. Kết quả cuối cùng được chuyển ngược về MPG theo công thức $\text{City} = \exp(\bar{\ell} + s_\ell\, y)$, với $\bar{\ell}$ và s_ℓ là trung bình và độ lệch chuẩn mẫu của $\log(\text{City})$.

Bảng 3.3: Năm mô hình ứng viên; biến phản hồi luôn là $\log(\text{City})$ đã chuẩn hoá.

Mô hình	Công thức	Hàm hợp lý
M1	City $\sim$ HP	Chuẩn
M2	City $\sim$ HP + USA	Chuẩn
M3	City $\sim$ HP + USA + HP $\times$ USA	Chuẩn
M4	City $\sim$ HP + Weight + USA	Chuẩn
M5	City $\sim$ HP + Weight + USA	Student-t

3.4 Năm mô hình ứng viên

Năm mô hình ứng viên (bảng 3.3) được xây dựng bằng cách bổ sung dần các biến giải thích. M4 là mô hình tốt nhất trong nhóm M1–M4 theo PSIS-LOO. M5 giữ nguyên bộ biến của M4 nhưng thay hàm hợp lý chuẩn bằng phân phối Student-t để giảm ảnh hưởng của các điểm ngoại lai.

3.5 Đặc tả đầy đủ cho M3

Trên thang đã chuẩn hoá, M3 có dạng

$$\begin{aligned} y_i &\sim \mathcal{N}(\mu_i, \sigma^2), \\ \mu_i &= \beta_0 + \beta_1 \text{HP}_i + \beta_2 \text{USA}_i + \beta_3 \text{HP}_i \text{USA}_i, \\ \beta_j &\sim \mathcal{N}(0, 2{,}5^2), \qquad j = 0, \ldots, 3, \\ \sigma &\sim \text{Half-Normal}(1). \end{aligned} \tag{3.2}$$

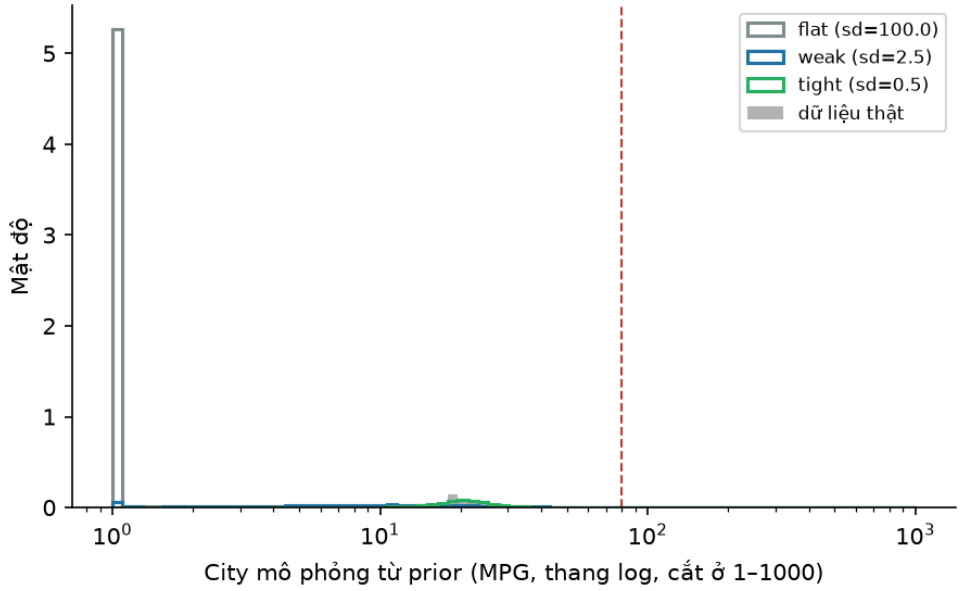
Các mô hình còn lại được suy ra bằng cách bớt hoặc thay đổi các số hạng trong μ_i. Riêng M5 dùng hàm hợp lý $y_i \sim t_\nu(\mu_i, \sigma)$ với $\nu \sim \text{Gamma}(2;\, 0{,}1)$, cho phép phân phối có đuôi dày hơn để thích ứng với các điểm ngoại lai. Tiên nghiệm Gamma này có trung bình bằng 20, song vẫn dành xác suất đáng kể cho các giá trị ν nhỏ.

3.6 Chọn tiên nghiệm và kiểm tra dự đoán tiên nghiệm

Nhóm thử ba lựa chọn tiên nghiệm cho các hệ số: tiên nghiệm phẳng $\mathcal{N}(0, 100^2)$, tiên nghiệm ít thông tin $\mathcal{N}(0, 2{,}5^2)$ và tiên nghiệm hẹp $\mathcal{N}(0, 0{,}5^2)$. Tiên nghiệm liên hợp Normal–Inverse-Gamma cho phép tính hậu nghiệm dưới dạng đóng (mục 4.1), nhưng các tiên nghiệm độc lập trong (3.2) không có tính liên hợp nên cần dùng MCMC. Để đánh giá từng tiên nghiệm, nhóm sinh $1\,000$ bộ dữ liệu từ phân phối tiên nghiệm của M3 rồi tính tỉ lệ giá trị City nằm trong miền hợp lý. Vì mô hình được xây dựng trên thang logarit nên City luôn dương,

Bảng 3.4: Kiểm tra dự đoán tiên nghiệm cho M3 với ba tiên nghiệm, mỗi tiên nghiệm 1 000 lần mô phỏng.

Tiên nghiệm	City $\leq$ 80 MPG	City trong 5–80 MPG	Trung vị (MPG)
Phẳng, sd $= 100$	53,3%	3,4%	5,4
Ít thông tin, sd $= 2{,}5$	92,1%	86,2%	21,0
Hẹp, sd $= 0{,}5$	99,9%	99,9%	21,6



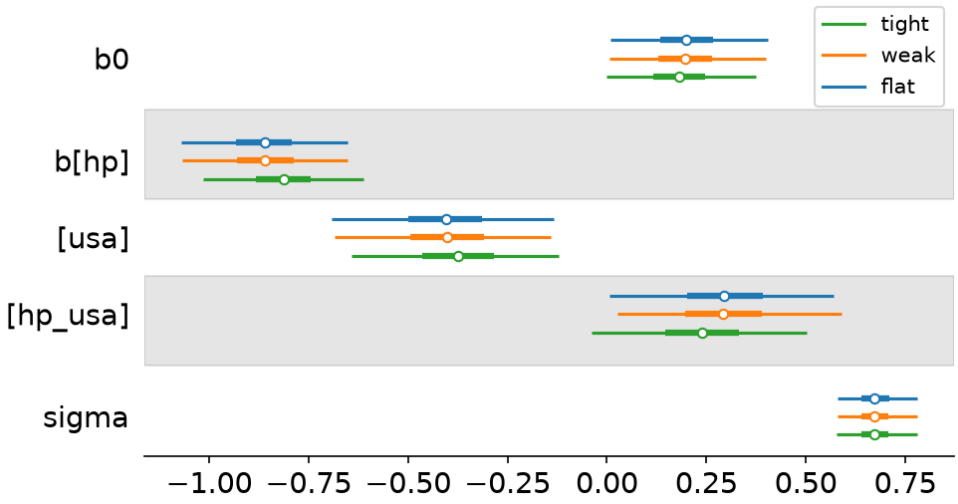
Hình 3.2: Phân phối City mô phỏng từ tiên nghiệm của M3 với ba tiên nghiệm, so với dữ liệu thật; trục hoành theo thang logarit, đường đứt đỏ ở 80 MPG.

chỉ cần kiểm tra thêm điều kiện City không vượt quá 80 MPG.

Bảng 3.4 và hình 3.2 cho thấy tiên nghiệm phẳng sinh ra phần lớn các giá trị phi thực tế, chỉ 3,4% số lần mô phỏng cho City trong khoảng 5–80 MPG. Với tiên nghiệm ít thông tin, tỉ lệ này là 86%, trong khi tiên nghiệm vẫn đủ rộng để không áp đặt kết quả. Đây là tiên nghiệm được chọn cho các mô hình chính. Tiên nghiệm hẹp cũng cho giá trị hợp lý nhưng có nguy cơ kéo các hệ số về 0, vấn đề này được xem xét ở mục 3.7.

3.7 Ảnh hưởng của tiên nghiệm đến kết quả

Để đánh giá độ nhạy, M3 được ước lượng lại với cả ba tiên nghiệm. Hậu nghiệm dưới tiên nghiệm phẳng và tiên nghiệm ít thông tin gần như trùng nhau, trung bình chênh lệch tối đa $0{,}04$ độ lệch chuẩn hậu nghiệm, nghĩa là kết quả hầu như chỉ phụ thuộc vào dữ liệu. Tiên nghiệm hẹp kéo các hệ số về 0, mạnh nhất tới $0{,}42$ độ lệch chuẩn hậu nghiệm. Ảnh hưởng này thấy rõ nhất ở hệ số tương tác HP $\times$ USA, giảm từ $0{,}294$ xuống $0{,}239$, và HDI 95% lúc này đã chứa 0 (hình 3.3). Do đó, kết luận về tương tác ở mục 5.4 cần được diễn giải thận trọng.



Hình 3.3: Hậu nghiệm của M3 với ba tiên nghiệm, trung bình và HDI 95%.

IV. Quá trình ước lượng Bayes

4.1 Công thức hậu nghiệm cho M1

Theo định lý Bayes, phân phối hậu nghiệm tỉ lệ với tích của hàm hợp lý và tiên nghiệm:

$$p(\beta, \sigma^2 \mid y) \propto p(y \mid \beta, \sigma^2)\, p(\beta, \sigma^2). \tag{4.1}$$

Với tiên nghiệm liên hợp Normal–Inverse-Gamma $\beta \mid \sigma^2 \sim \mathcal{N}(m_0, \sigma^2 V_0)$ và $\sigma^2 \sim \mathrm{IG}(a_0, b_0)$, hậu nghiệm có cùng dạng với các tham số

$$\begin{aligned} V_n &= \left(V_0^{-1} + X^\top X\right)^{-1}, \quad m_n = V_n\left(V_0^{-1} m_0 + X^\top y\right), \\ a_n &= a_0 + \tfrac{n}{2}, \qquad\qquad b_n = b_0 + \tfrac{1}{2}\left(y^\top y + m_0^\top V_0^{-1} m_0 - m_n^\top V_n^{-1} m_n\right). \end{aligned} \tag{4.2}$$

Lấy tích phân theo σ^2, phân phối biên của β là phân phối t nhiều chiều với $2a_n$ bậc tự do, tâm m_n và ma trận tỉ lệ $(b_n/a_n)V_n$ [1]. Với lựa chọn $m_0 = 0$, $V_0 = 2{,}5^2 I$, $a_0 = 2$ và $b_0 = 1$, ta tính được $a_n = 48{,}5$ và $b_n = 23{,}76$.

Để kiểm chứng phần cài đặt, nhóm khai báo lại đúng tiên nghiệm này trong PyMC và lấy mẫu bằng NUTS. Như bảng 4.1 cho thấy, hai cách tính cho kết quả trùng nhau đến chữ số thập phân thứ ba. Dòng cuối của bảng dùng tiên nghiệm ít thông tin độc lập của M1 thay cho tiên nghiệm liên hợp. Dù vậy, hậu nghiệm gần như không đổi, do cả hai tiên nghiệm đều rộng và 93 quan sát đã đủ để dữ liệu chi phối kết quả (hình 4.1).

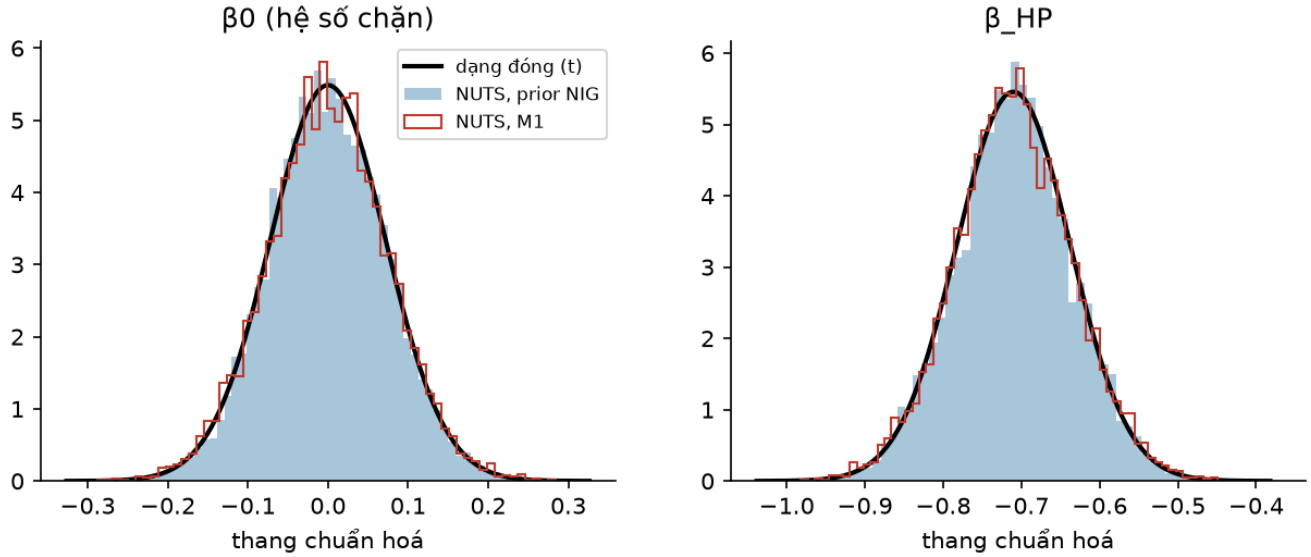
4.2 Lấy mẫu MCMC

Với M2–M5, hậu nghiệm không có dạng đóng nên được lấy mẫu bằng NUTS [7] trong PyMC 5.28 [8]. Mỗi mô hình chạy 4 chuỗi, mỗi chuỗi $2\,000$ vòng lặp sau $1\,000$ vòng khởi động, với seed cố định là 2026. NUTS là một biến thể của Hamiltonian Monte Carlo. Thuật toán dùng gradient của logarit hậu nghiệm để đề xuất những bước di chuyển xa nhưng vẫn giữ xác suất chấp nhận cao, đồng thời tự điều chỉnh độ dài quỹ đạo thay vì để người dùng tinh chỉnh thủ công.

Để so sánh, nhóm tự cài đặt thuật toán Metropolis–Hastings bước ngẫu nhiên cho M1. Thuật toán lấy mẫu trên không gian $(\beta_0, \beta_1, \log\sigma)$, có cộng Jacobian $\log\sigma$ vào logarit hậu nghiệm, với bước đề xuất phân phối chuẩn có độ lệch chuẩn $0{,}08$. Nhóm chạy 4 chuỗi, mỗi chuỗi $6\,000$ vòng và bỏ $1\,000$ vòng đầu, tỉ lệ chấp nhận đạt từ $0{,}41$ đến $0{,}43$. Metropolis–Hastings cho hậu nghiệm giống NUTS ($\beta_{\mathrm{HP}} = -0{,}708$ so với $-0{,}710$) nhưng kém

Bảng 4.1: Hậu nghiệm của β_{HP} trong M1, thang chuẩn hoá: công thức so với MCMC.

Cách tính	Trung bình	Độ lệch chuẩn	Khoảng 95%
Công thức (NIG)	$-0{,}710\,1$	$0{,}073\,7$	$[-0{,}855; -0{,}565]$
NUTS, cùng tiên nghiệm NIG	$-0{,}709\,9$	$0{,}074\,2$	$[-0{,}857; -0{,}564]$
NUTS, tiên nghiệm ít thông tin M1	$-0{,}710\,3$	$0{,}075\,4$	$[-0{,}862; -0{,}560]$

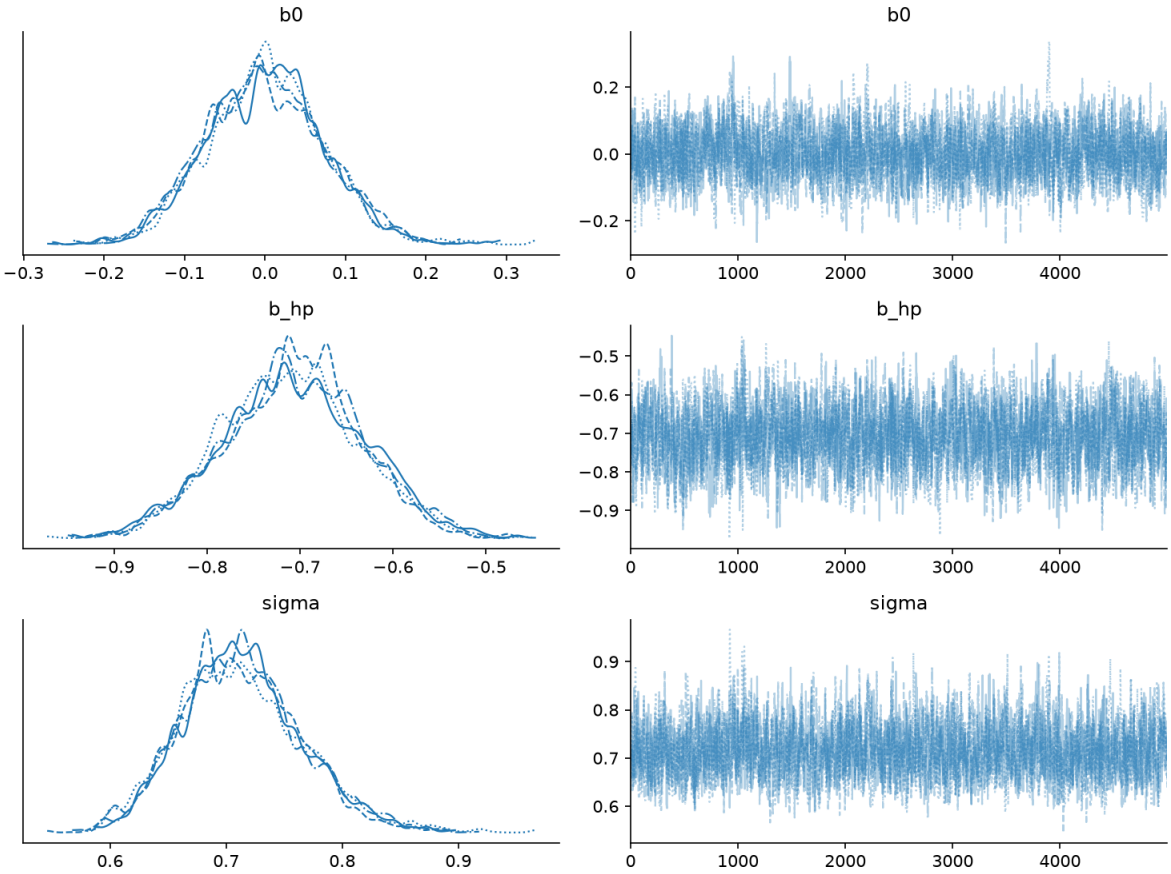


Hình 4.1: Hậu nghiệm của M1: mật độ t tính bằng công thức (đen), NUTS với cùng tiên nghiệm NIG (xanh) và NUTS với tiên nghiệm của M1 (đỏ).

hiệu quả hơn nhiều. Từ $20\,000$ mẫu, thuật toán chỉ thu được cỡ mẫu hiệu dụng khoảng $1\,700$, trong khi NUTS đạt khoảng $12\,000$ từ $8\,000$ mẫu. Nguyên nhân là mỗi bước Metropolis–Hastings chỉ di chuyển một quãng ngắn, khiến các mẫu liên tiếp tự tương quan mạnh (hình 4.2).

4.3 Chẩn đoán hội tụ

Sự hội tụ được đánh giá theo bốn tiêu chí: $\widehat{R}$ (phiên bản dựa trên thứ hạng [9]) nhỏ hơn $1{,}01$, cỡ mẫu hiệu dụng (ESS) bulk và tail đều lớn hơn 400, không có bước phân kỳ (divergence), và biểu đồ vết cũng như biểu đồ thứ hạng không có dấu hiệu bất thường. Cả năm mô hình đều thoả mãn các tiêu chí này (bảng 4.2). Biểu đồ vết của mô hình cuối (hình 4.3) cho thấy bốn chuỗi trộn đều vào nhau. Code được thiết lập để dừng lại nếu có mô hình không đạt, vì vậy mọi hệ số trong báo cáo đều được tính từ các chuỗi đã hội tụ.



Hình 4.2: Biểu đồ vết của Metropolis–Hastings tự viết cho M1, bốn chuỗi.

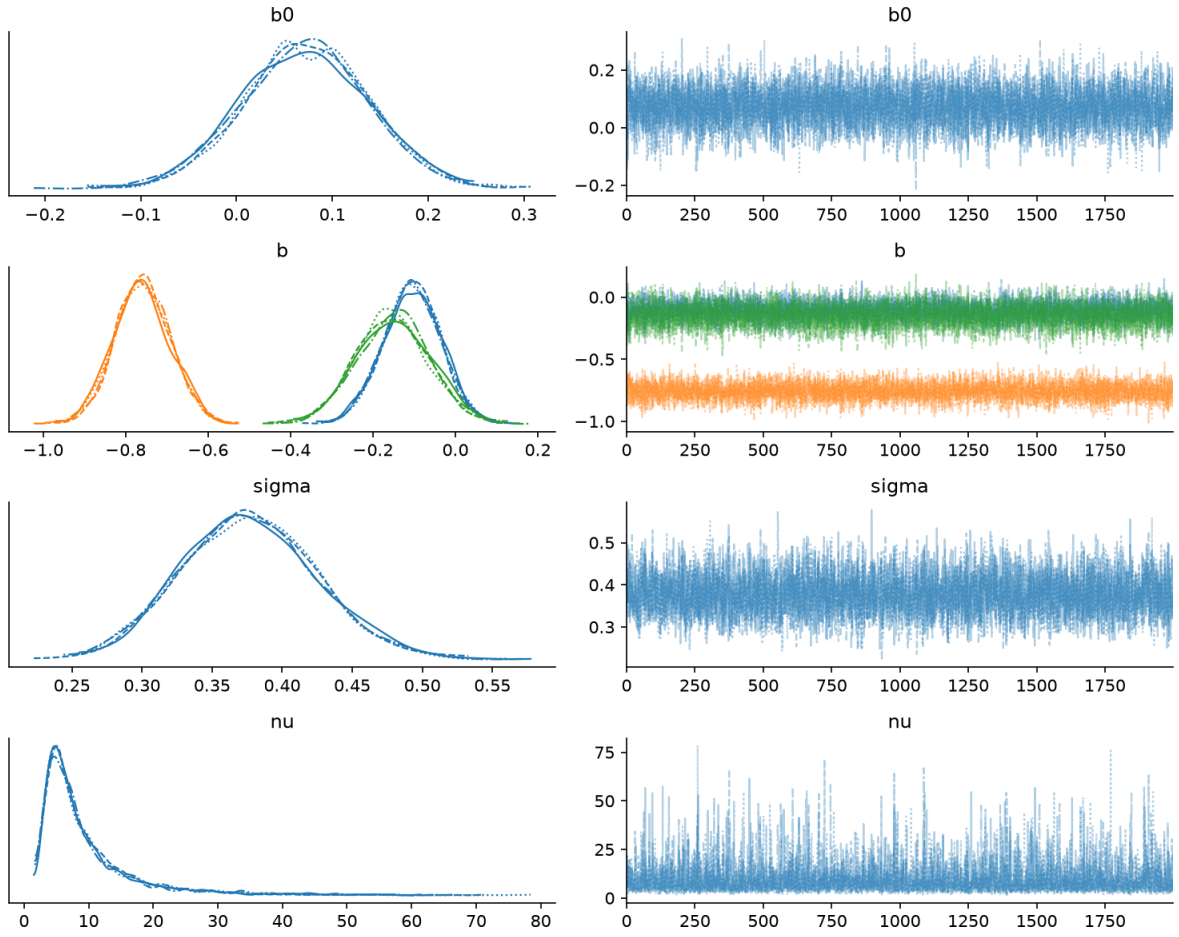
Bảng 4.2: Chẩn đoán hội tụ của năm mô hình; giá trị xấu nhất trên mọi tham số.

Mô hình	$\widehat{R}$ lớn nhất	ESS bulk nhỏ nhất	ESS tail nhỏ nhất	Số bước phân kỳ
M1	1,00	10 830	5 460	0
M2	1,00	6 013	5 295	0
M3	1,00	5 618	5 197	0
M4	1,00	5 116	5 091	0
M5	1,00	4 626	4 763	0

4.4 Bảng tóm tắt hậu nghiệm

Bảng 4.3 trình bày trung bình hậu nghiệm và HDI 95% của các hệ số trên thang chuẩn hoá. Hệ số của HP và Weight cho biết $\log(\text{City})$ chuẩn hoá thay đổi bao nhiêu khi biến tương ứng tăng một độ lệch chuẩn, còn hệ số của USA là chênh lệch giữa xe Mỹ và xe nước ngoài. M5 có thêm tham số $\nu = 9{,}4$ (HDI 95%: $[1{,}8;\ 24{,}7]$), cho thấy phân phối sai số có đuôi dày ở mức vừa phải.

Khi bổ sung Weight ở M4 và M5, hệ số của HP giảm từ khoảng $-0{,}7$ xuống còn khoảng $-0{,}1$, đồng thời σ giảm từ $0{,}68$ (M3) xuống $0{,}47$ (M4). Nguyên nhân là xe công suất lớn thường cũng nặng hơn, nên phần lớn mối liên hệ giữa HP và City ở M1–M3 thực chất phản ánh liên hệ giữa Weight và City. Với dữ liệu quan sát,

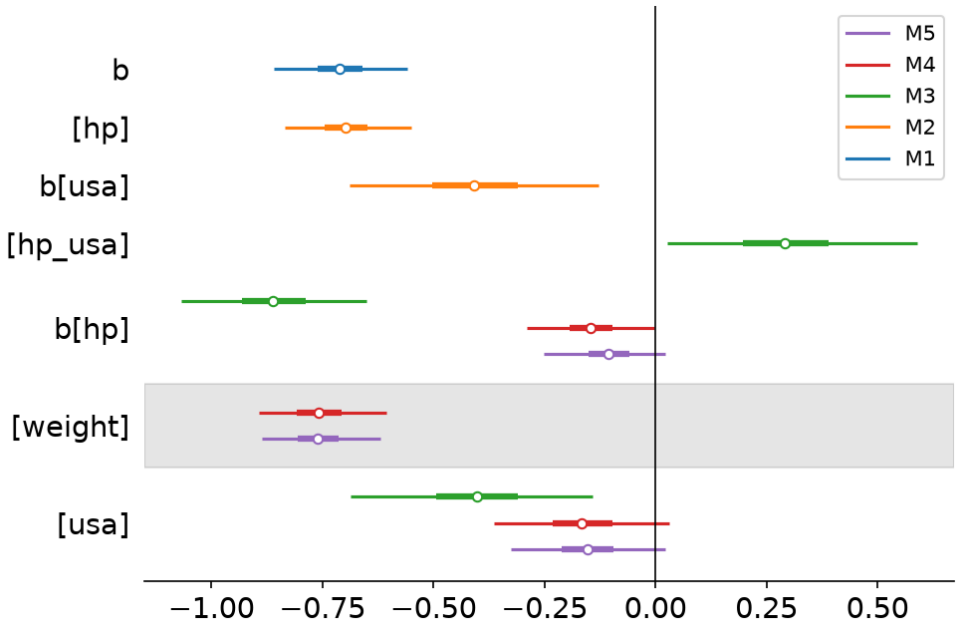


Hình 4.3: Biểu đồ vết của M5: mật độ hậu nghiệm theo chuỗi (trái) và giá trị qua các vòng lặp (phải).

Bảng 4.3: Trung bình hậu nghiệm và HDI 95% của các hệ số, thang chuẩn hoá. Cột σ là độ lệch chuẩn sai số với M1–M4 và tham số thang đo Student-t với M5.

Mô hình	β_{HP}	β_{USA}	$\beta_{\text{HP}\times\text{USA}}$	β_{Weight}	σ
M1	$-0{,}71$ [$-0{,}86$; $-0{,}56$]	–	–	–	0,72
M2	$-0{,}70$ [$-0{,}84$; $-0{,}55$]	$-0{,}41$ [$-0{,}69$; $-0{,}13$]	–	–	0,69
M3	$-0{,}86$ [$-1{,}07$; $-0{,}65$]	$-0{,}40$ [$-0{,}69$; $-0{,}14$]	0,29 [0,03; 0,59]	–	0,68
M4	$-0{,}15$ [$-0{,}29$; 0,00]	$-0{,}16$ [$-0{,}36$; 0,03]	–	$-0{,}76$ [$-0{,}89$; $-0{,}61$]	0,47
M5	$-0{,}11$ [$-0{,}25$; 0,02]	$-0{,}15$ [$-0{,}33$; 0,02]	–	$-0{,}76$ [$-0{,}89$; $-0{,}62$]	0,38

không thể tách bạch hoàn toàn tác động riêng của từng biến (hình 4.4). Cần lưu ý rằng σ ở M1–M4 là độ lệch chuẩn của sai số, còn ở M5 là tham số thang đo của phân phối Student-t, nên hai loại giá trị này không so sánh trực tiếp được (xem mục 5.5).



Hình 4.4: Hệ số hậu nghiệm của M1–M5 trên thang chuẩn hoá, trung bình và HDI 95%.

V. Đánh giá kết quả và trả lời câu hỏi

5.1 Kiểm tra dự đoán hậu nghiệm

Với mỗi mô hình, nhóm sinh $8\,000$ bộ dữ liệu từ phân phối dự đoán hậu nghiệm, chuyển về đơn vị MPG rồi so sánh mật độ với dữ liệu thực (hình 5.1). Cả năm mô hình đều tái tạo tốt giá trị trung bình của City, với p-value Bayes nằm trong khoảng $0{,}38$ đến $0{,}47$. Tuy nhiên, M1–M4 không tái tạo được hai đầu của phân phối. Dữ liệu mô phỏng hiếm khi có xe đạt 46 MPG như Geo Metro, và p-value của giá trị lớn nhất chỉ từ $0{,}006$ đến $0{,}024$. M5 cải thiện ở cả hai đầu, với p-value của giá trị lớn nhất là $0{,}041$ và của giá trị nhỏ nhất là $0{,}044$.

5.2 So sánh mô hình

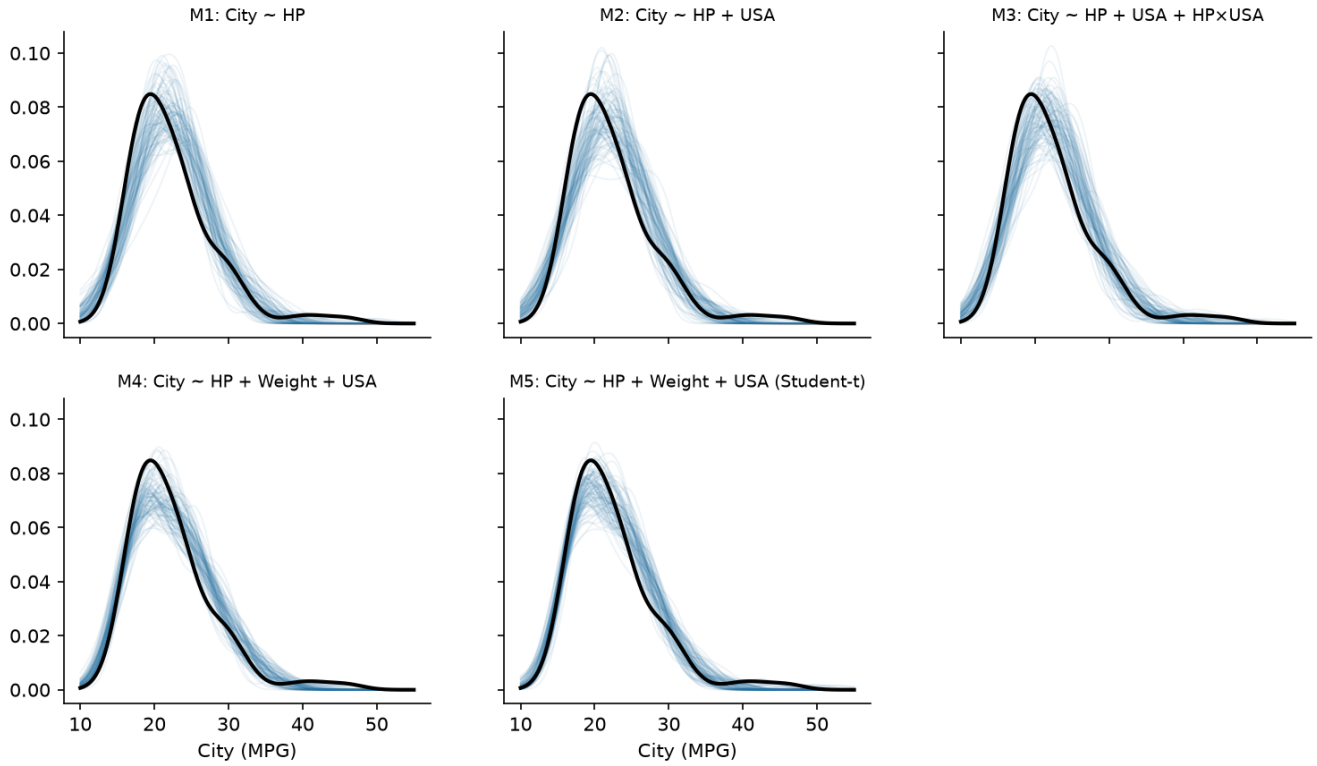
Các mô hình được so sánh qua ELPD, ước lượng bằng PSIS-LOO và WAIC [10] với thư viện ArviZ [11]. Hai tiêu chí cho cùng một thứ hạng (bảng 5.1). M5 có ELPD cao nhất và trọng số stacking $0{,}97$ nên được chọn làm mô hình cuối. M5 hơn M4 $4{,}45$ đơn vị ELPD với sai số chuẩn $2{,}60$, tức khoảng $1{,}7$ lần sai số chuẩn. Mức chênh này đủ để ưu tiên M5, dù không quá lớn. Trong khi đó, các mô hình có Weight (M4, M5) vượt các mô hình không có Weight (M1–M3) từ 34 đến 43 đơn vị ELPD, tương đương hơn bốn lần sai số chuẩn.

Không quan sát nào có Pareto k vượt $0{,}7$, nên ước lượng PSIS-LOO đáng tin cậy với cả năm mô hình (hình 5.2).

5.3 Trả lời Q1: quan hệ giữa các biến

Công suất và hiệu suất nhiên liệu có quan hệ nghịch biến rõ rệt, nhưng hệ số của công suất giảm mạnh khi trọng lượng được đưa vào mô hình. Do mô hình đặt trên thang logarit, khi HP tăng 10 đơn vị, trung vị có điều kiện của City được nhân với $\exp(10\,\beta_{\text{HP}}\,s_\ell/s_{\text{HP}})$, với s_{HP} là độ lệch chuẩn của HP. Các tỉ lệ phần trăm dưới đây vì thế là mức thay đổi tương đối của trung vị City.

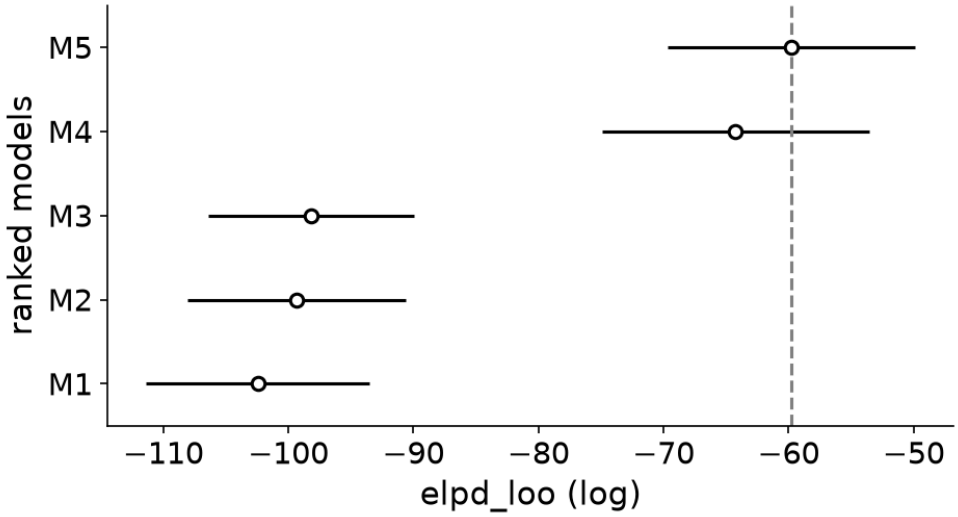
- Khi chỉ dùng HP (M1), mỗi 10 hp tăng thêm làm City giảm 3,0% (HDI 95% từ $-3{,}6\%$ đến $-2{,}4\%$). Chẳng hạn, khi công suất tăng từ 140 lên 150 hp, trung vị City giảm $0{,}66$ MPG, HDI 95% từ $-0{,}80$ đến $-0{,}52$ MPG (hình 5.3).
- Khi cố định Weight (M5), mức giảm ứng với 10 hp chỉ còn $-0{,}45\%$ (HDI 95% từ $-1{,}07\%$ đến $+0{,}10\%$), xác suất hệ số âm là $0{,}94$.



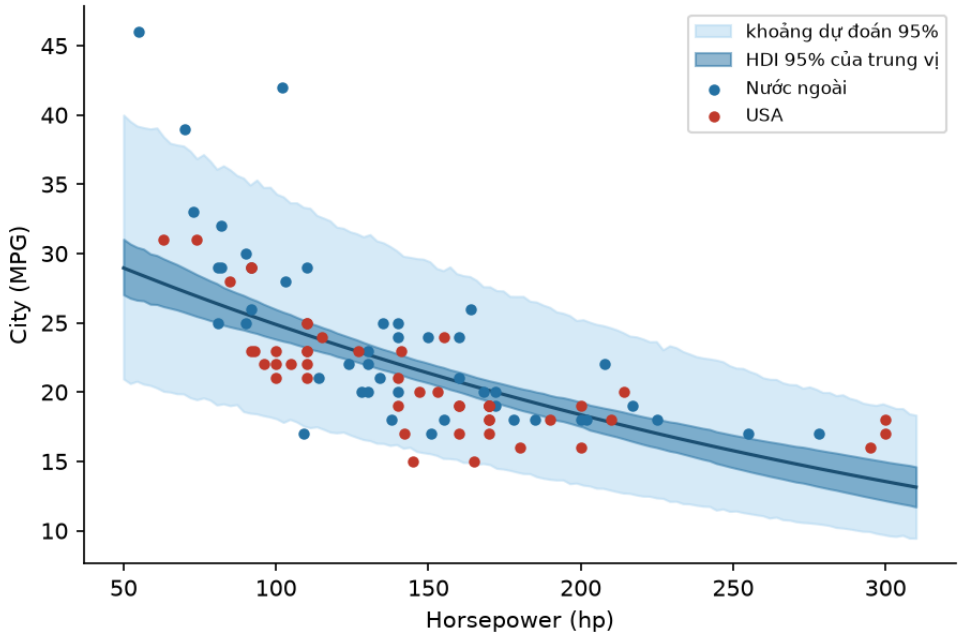
Hình 5.1: Kiểm tra dự đoán hậu nghiệm: mật độ dữ liệu thật (đen) và 100 bộ dữ liệu sinh từ hậu nghiệm (xanh).

Bảng 5.1: So sánh mô hình bằng PSIS-LOO và WAIC; chênh lệch tính so với M5.

Mô hình	ELPD-LOO	p_{loo}	Chênh lệch	SE chênh lệch	ELPD-WAIC	Pareto $k > 0{,}5$
M5	$-59{,}8$	$6{,}4$	0	–	$-59{,}7$	0
M4	$-64{,}2$	$6{,}7$	$4{,}4$	$2{,}6$	$-64{,}2$	1
M3	$-98{,}2$	$6{,}0$	$38{,}4$	$8{,}4$	$-98{,}1$	0
M2	$-99{,}3$	$5{,}1$	$39{,}6$	$8{,}2$	$-99{,}3$	0
M1	$-102{,}4$	$4{,}1$	$42{,}6$	$7{,}8$	$-102{,}4$	0



Hình 5.2: ELPD-LOO của năm mô hình, kèm sai số chuẩn và sai số chuẩn của chênh lệch so với mô hình tốt nhất.



Hình 5.3: M1: City theo HP, với HDI 95% của trung vị có điều kiện (xanh đậm) và khoảng dự đoán 95% (xanh nhạt).

- Khi cố định HP và xuất xứ, mỗi 100 kg tăng thêm ứng với trung vị City giảm 6,2% (HDI 95% từ $-7{,}1\%$ đến $-5{,}0\%$).

Kết quả này phù hợp với các biểu đồ phân tán ở mục 2.6, trong đó City giảm phi tuyến theo cả HP, Weight và Engine Size, và tương quan với Weight mạnh hơn với HP. Do City và Open Road tương quan tới $0{,}94$, nhiều khả năng Open Road cũng có xu hướng tương tự. Tuy vậy, để có kết luận định lượng cho Open Road cần ước lượng một mô hình riêng cho biến này.

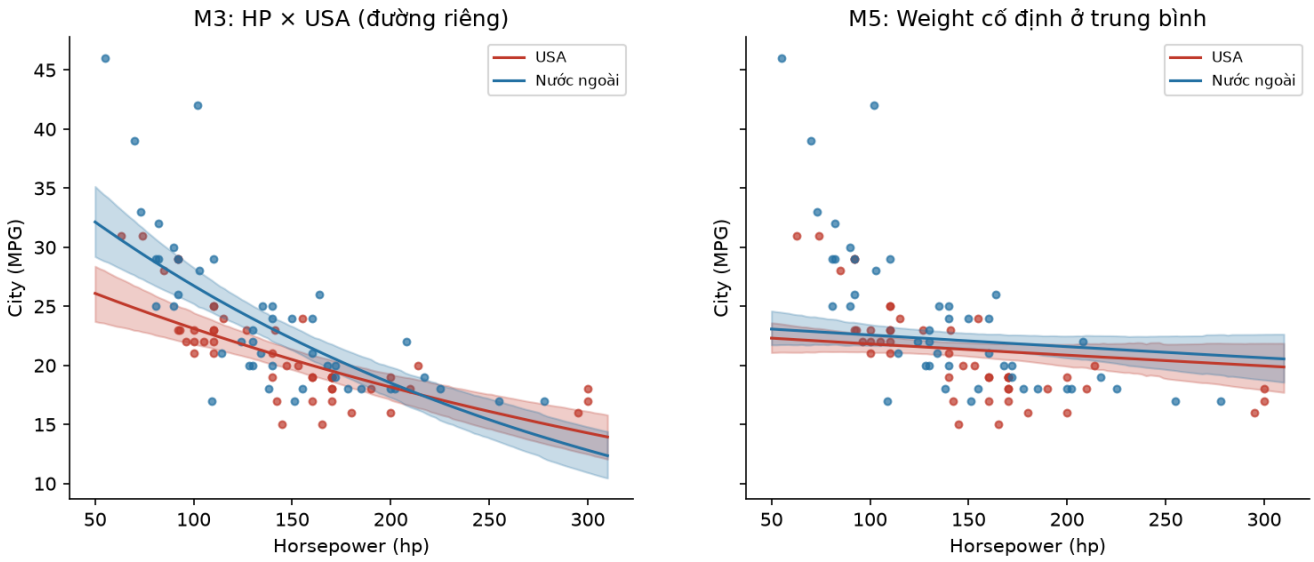
5.4 Trả lời Q2: xe Mỹ và xe nước ngoài

Ở cùng mức công suất, xe Mỹ kém tiết kiệm nhiên liệu hơn xe nước ngoài, nhưng khoảng cách này thu hẹp đáng kể khi đưa trọng lượng vào mô hình, do xe Mỹ trong mẫu nhìn chung nặng hơn (bảng 5.2). Kết quả này cho thấy xuất xứ và trọng lượng gắn liền với nhau trong dữ liệu, song chưa đủ để kết luận trọng lượng là nguyên nhân. Khi chỉ kiểm soát HP, City của xe Mỹ thấp hơn khoảng 8,6% và xác suất hậu nghiệm để xe Mỹ tiết kiệm hơn chỉ là $0{,}003$. Khi kiểm soát thêm Weight, khoảng cách còn 3,3% và HDI 95% chạm mốc 0.

Trong M3, hệ số tương tác HP $\times$ USA mang dấu dương, bằng $0{,}29$ (HDI 95%: $[0{,}03;\ 0{,}59]$), với xác suất dương là $0{,}98$. Điều này có nghĩa là xe nước ngoài tiết kiệm hơn hẳn ở phân khúc công suất thấp, nhưng lợi thế này giảm dần khi HP tăng, và hai đường hồi quy giao nhau ở khoảng 200 hp (hình 5.4, trái). Tuy nhiên, như đã chỉ ra ở mục 3.7, kết quả này nhạy với lựa chọn tiên nghiệm, nên nhóm chỉ xem đây là một dấu hiệu cần kiểm

Bảng 5.2: Hệ số của USA trong ba mô hình; chênh lệch City đổi ra phần trăm.

Mô hình	β_{USA} [HDI 95%]	Chênh lệch City của xe Mỹ	$P(\beta_{\text{USA}} > 0 \mid y)$
M2: HP + USA	$-0{,}41$ $[-0{,}69; -0{,}13]$	$-8{,}7\%$	$0{,}003$
M3: có HP $\times$ USA	$-0{,}40$ $[-0{,}69; -0{,}14]$	$-8{,}6\%$	$0{,}003$
M5: có Weight	$-0{,}15$ $[-0{,}33; 0{,}02]$	$-3{,}3\%$	$0{,}043$



Hình 5.4: Đường hồi quy và HDI 95% cho xe Mỹ và xe nước ngoài: M3 với tương tác (trái) và M5 với Weight cố định ở mức trung bình (phải).

chứng thêm. Khi cố định Weight ở mức trung bình (hình 5.4, phải), hai đường gần như trùng nhau.

5.5 Trả lời Q3: các điểm ngoại lai

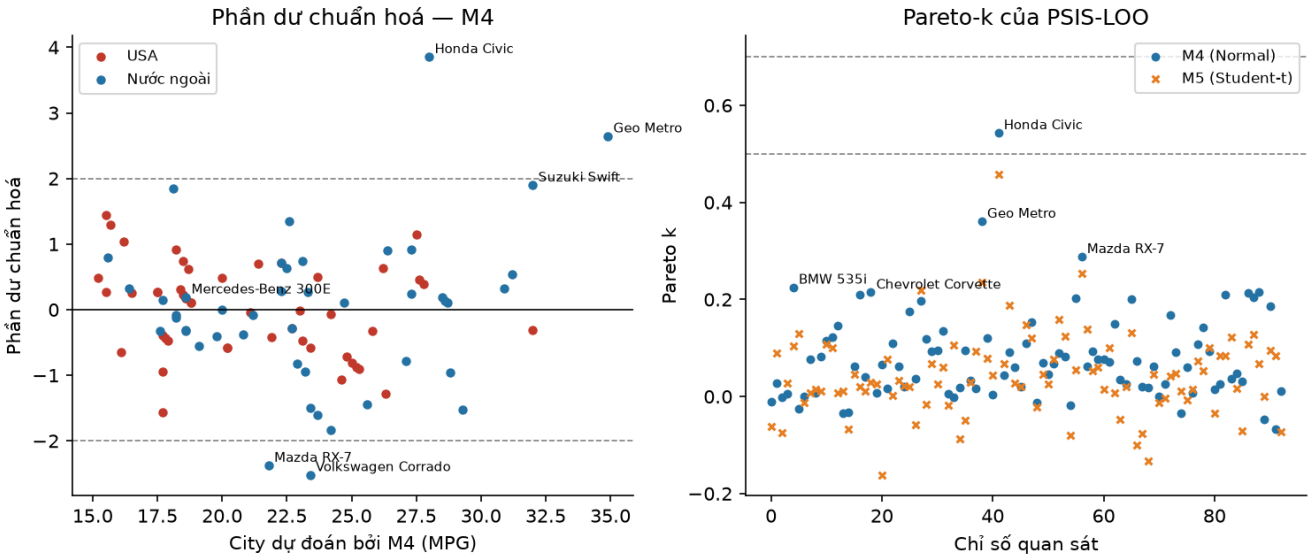
Để xác định các điểm ngoại lai, nhóm xem xét phần dư chuẩn hoá và Pareto k của M4 (phiên bản dùng hàm hợp lý chuẩn của mô hình cuối), sau đó so sánh với M5 (bảng 5.3, hình 5.5). Phần dư chuẩn hoá được tính bằng hiệu giữa y_i và trung bình hậu nghiệm của μ_i, chia cho trung bình hậu nghiệm của σ. Pareto k đo mức ảnh hưởng của từng quan sát lên hậu nghiệm, k càng lớn thì hậu nghiệm càng thay đổi nhiều khi loại bỏ quan sát đó.

Nhóm xe van có City từ 15 đến 18 MPG trông như ngoại lai khi mô hình chỉ có HP, nhưng khi thêm Weight thì phần dư của chúng chỉ còn từ $-1{,}6$ đến $+0{,}3$. Như vậy, City thấp của các xe van được giải thích bởi trọng lượng lớn. Ba xe cỡ nhỏ Honda Civic, Geo Metro và Suzuki Swift tiết kiệm hơn mức dự đoán của mô hình log-tuyến tính, ngược lại Mazda RX-7 và Volkswagen Corrado tốn nhiên liệu hơn dự đoán. Riêng lời giải thích về phiên bản động cơ của Honda Civic chỉ là giả thuyết, vì dữ liệu không ghi rõ phiên bản.

So với M4, M5 giảm bớt ảnh hưởng của các điểm này. Pareto k lớn nhất giảm từ $0{,}54$ xuống $0{,}46$, còn β_{HP} giảm

Bảng 5.3: Các xe được xét là ngoại lai, theo M4.

Xe	City	Dự đoán	Phần dư	k	Giải thích
Honda Civic	42	28,0	3,86	0,54	Xe nhẹ (1 066 kg), có thể là phiên bản động cơ tiết kiệm nhiên liệu; ảnh hưởng lớn nhất
Geo Metro	46	34,9	2,65	0,36	Xe nhẹ nhất mẫu (769 kg), máy 1,0 L 55 hp, nằm ngoài vùng có nhiều dữ liệu
Suzuki Swift	39	32,0	1,90	0,21	Cùng loại xe cỡ nhỏ với Geo Metro, máy 1,3 L, 891 kg
Mazda RX-7	17	21,8	−2,37	0,29	Động cơ rotary 1,3 L nhưng 255 hp; thân nhẹ nên mô hình dự đoán cao hơn
Volkswagen Corrado	18	23,4	−2,52	0,19	Xe thể thao, máy 2,8 L 178 hp trên thân 1 275 kg
Ford Aerostar	15	17,7	−1,57	0,10	Xe van nặng; bất thường khi chỉ dùng HP, hết bất thường khi có Weight
Mercedes-Benz 300E	19	18,6	0,19	0,09	Ngoại lai về giá (Max Price 80, cao nhất), không phải về nhiên liệu



Hình 5.5: Phần dư chuẩn hoá theo giá trị dự đoán của M4 (trái) và Pareto k của từng quan sát với M4 và M5 (phải).

về độ lớn từ $-0{,}15$ xuống $-0{,}11$ và HDI 95% lúc này chứa 0. Hệ số của Weight vẫn giữ ở mức $-0{,}76$, cho thấy liên hệ giữa trọng lượng và City không bị chi phối bởi các điểm ngoại lai.

Tham số σ của M5 bằng $0{,}38$, nhỏ hơn mức $0{,}47$ của M4, nhưng hai giá trị này không so sánh trực tiếp được. Với phân phối Student-t, σ là tham số thang đo, còn độ lệch chuẩn của sai số bằng $\sigma\sqrt{\nu/(\nu-2)}$ khi $\nu > 2$ và bằng vô cùng khi $\nu \leq 2$ (chỉ $0{,}3\%$ mẫu hậu nghiệm rơi vào trường hợp này). Quy về cùng thước đo, độ lệch chuẩn sai số của M5 có trung vị hậu nghiệm khoảng $0{,}45$, xấp xỉ M4. Vì thế, M5 không làm sai số nhỏ đi. Điểm khác biệt nằm ở chỗ phần lớn các xe bám sát đường hồi quy hơn, còn một vài xe ngoại lai được hấp thụ vào phần đuôi dày của phân phối Student-t.

Bảng 5.4: Dự đoán City cho một xe 300 hp, 1 681 kg nếu mô hình có Weight.

Mô hình	Xuất xứ	Trung vị City [HDI 95%]	Khoảng dự đoán 95%
M1: chỉ HP	bất kỳ	13,6 [12,2; 15,0]	9,7–18,8
M3	Mỹ	14,3 [12,5; 16,1]	10,3–19,6
M3	nước ngoài	12,9 [10,9; 14,8]	9,2–17,9
M5	Mỹ	16,6 [15,4; 18,0]	13,4–20,6
M5	nước ngoài	17,2 [15,9; 18,5]	13,8–21,3

Bảng 5.5: Dự đoán của M5 cho ba xe thật có từ 295 hp trở lên.

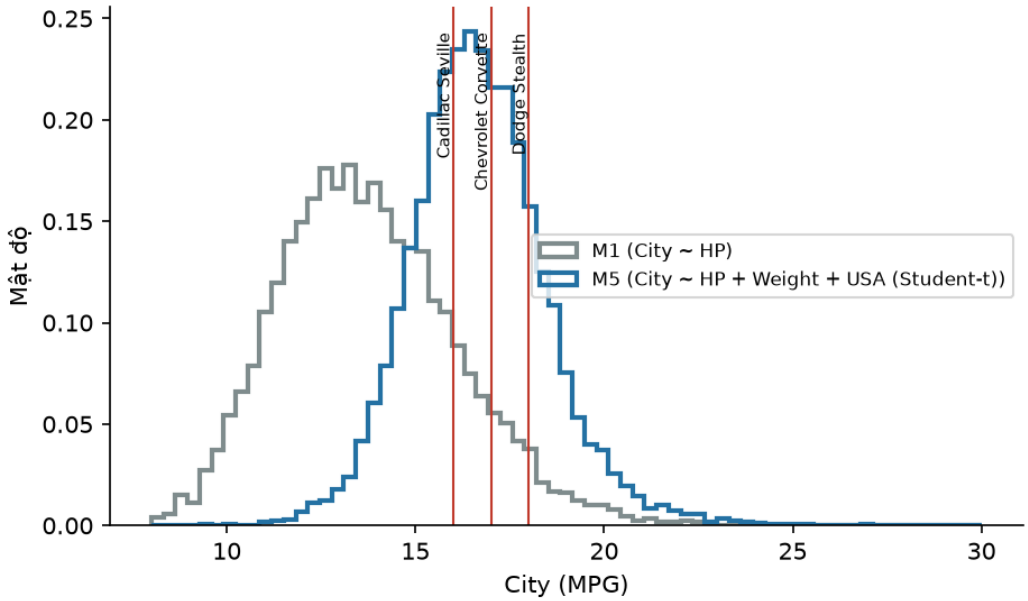
Xe	HP	Weight (kg)	City thật	Trung vị dự đoán	Khoảng dự đoán 95%
Cadillac Seville	295	1 785	16	15,6	12,6–19,2
Chevrolet Corvette	300	1 533	17	18,3	14,6–22,7
Dodge Stealth	300	1 726	18	16,1	13,0–20,0

5.6 Trả lời Q4: dự đoán cho xe 300 hp

Biến phản hồi được chọn là City và biến giải thích chính là Horsepower. Nếu chỉ biết công suất, M1 là mô hình phù hợp nhất với câu hỏi của đề. Theo M1, trung vị City của một xe 300 hp vào khoảng 13,6 MPG, khoảng dự đoán 95% từ 9,7 đến 18,8 MPG. M5 đòi hỏi thêm thông tin về xuất xứ và trọng lượng, nên dự đoán của M5 chỉ áp dụng cho một cấu hình xe cụ thể. Với một xe Mỹ 300 hp nặng 1 681 kg (trọng lượng trung bình của ba xe trong mẫu có công suất từ 295 hp trở lên), trung vị City vào khoảng 16,6 MPG, khoảng dự đoán 95% từ 13,4 đến 20,6 MPG (bảng 5.4). Một xe 300 hp nặng hơn hoặc nhẹ hơn sẽ cho kết quả dự đoán khác.

Do mô hình được xây dựng trên $\log(\text{City})$, $\exp(\mu)$ là trung vị có điều kiện của City, không phải trung bình. Cột thứ ba của bảng là trung bình hậu nghiệm của trung vị này. Với M5, khi $\log(\text{City})$ có phân phối Student-t thì kỳ vọng của City thậm chí không hữu hạn, nên nhóm chỉ báo cáo trung vị và khoảng dự đoán. Khoảng dự đoán khác HDI của trung vị ở chỗ nó tính thêm sai số của từng xe, vì vậy rộng hơn đáng kể.

Cả ba xe có công suất gần 300 hp trong mẫu đều là xe Mỹ. Khi dùng thông số riêng của từng xe, khoảng dự đoán của M5 đều chứa giá trị thực (bảng 5.5). Tuy vậy, ba xe này đã nằm trong dữ liệu dùng để ước lượng mô hình, nên đây mới chỉ là kiểm tra trên mẫu học, chưa phản ánh khả năng dự đoán cho xe mới. M1 cho dự đoán thấp hơn thực tế (13,6 MPG) vì đường log-tuyến tính theo HP tiếp tục đi xuống ở vùng công suất cao, trong khi xe 300 hp trên thực tế không nặng hơn xe 200 hp là bao (hình 5.6). Cũng cần lưu ý rằng 300 hp là giá trị lớn nhất trong mẫu, nên mọi dự đoán ở đây đều nằm ở biên của dữ liệu.



Hình 5.6: Phân phối dự đoán hậu nghiệm cho một xe Mỹ 300 hp theo M1 và M5; đường đỏ là City của ba xe thật gần 300 hp.

5.7 Hạn chế

Báo cáo còn một số hạn chế. Thứ nhất, mẫu chỉ có 93 xe, trong đó chỉ ba xe có công suất trên 280 hp, nên dự đoán ở vùng biên có độ bất định lớn. Thứ hai, dữ liệu được thu thập năm 1993, khi công nghệ động cơ còn khác xa hiện nay, nên không thể áp dụng trực tiếp kết quả cho xe ngày nay. Thứ ba, các quan hệ tìm được chỉ là tương quan, không phải quan hệ nhân quả, và dự đoán ngoài khoảng 55–300 hp hoặc 769–1 862 kg không đáng tin cậy. Cuối cùng, phần kiểm tra dự đoán ở Q4 chỉ dùng các xe có sẵn trong dữ liệu học, nhóm chưa đánh giá khả năng dự đoán trên dữ liệu ngoài mẫu.

VI. Kết luận

Trong mẫu 93 xe năm 1993, trọng lượng là biến có liên hệ chặt chẽ nhất với hiệu suất nhiên liệu trong thành phố. Mô hình cuối cùng là M5, $\log(\text{City}) \sim \text{HP} + \text{Weight} + \text{USA}$ với hàm hợp lý Student-t. Mô hình này hội tụ tốt, tái tạo dữ liệu tốt nhất và xếp hạng cao nhất theo cả PSIS-LOO lẫn WAIC. Các câu hỏi của đề được trả lời như sau.

Q1, quan hệ giữa các biến. Nếu chỉ xét HP, mỗi 10 hp tăng thêm ứng với trung vị City giảm 3,0%. Khi cố định Weight, mức giảm này gần như bằng 0 ($-0{,}45\%$), trong khi mỗi $100\,\text{kg}$ tăng thêm ứng với trung vị City giảm 6,2%. Open Road tương quan $0{,}94$ với City nên nhiều khả năng có xu hướng tương tự, tuy nhiên nhóm chưa xây dựng mô hình riêng cho biến này.

Q2, xe Mỹ và xe nước ngoài. Ở cùng mức công suất, xe Mỹ kém tiết kiệm hơn khoảng 8,6%, và xác suất để điều ngược lại xảy ra chỉ là $0{,}003$. Khi tính thêm Weight, khoảng cách còn 3,3% và HDI 95% chạm mốc 0. Như vậy, phần lớn chênh lệch giữa hai nhóm đi kèm với chênh lệch về trọng lượng, dù dữ liệu quan sát chưa cho phép khẳng định trọng lượng là nguyên nhân.

Q3, điểm ngoại lai. Honda Civic, Geo Metro và Suzuki Swift tiết kiệm nhiên liệu bất thường, trong khi Mazda RX-7 (động cơ rotary) và Volkswagen Corrado tốn nhiên liệu hơn dự đoán. Các xe van chỉ trông như ngoại lai khi bỏ qua trọng lượng. Những kết luận chính không thay đổi khi chuyển sang hàm hợp lý Student-t.

Q4, xe 300 hp. Nếu chỉ biết công suất (M1), trung vị City của xe 300 hp vào khoảng $13{,}6$ MPG, khoảng dự đoán 95% từ $9{,}7$ đến $18{,}8$ MPG. Nếu biết thêm đó là xe Mỹ nặng $1\,681$ kg (M5), trung vị City vào khoảng $16{,}6$ MPG, khoảng dự đoán 95% từ $13{,}4$ đến $20{,}6$ MPG. Cả ba xe thực tế gần 300 hp đều nằm trong khoảng dự đoán của M5, nhưng vì chúng thuộc dữ liệu học nên đây chưa phải là kiểm tra ngoài mẫu.

Hướng phát triển. Một hướng mở rộng là xây dựng mô hình phân cấp theo Type, trong đó mỗi loại xe có hệ số chặn riêng nhưng chia sẻ thông tin với các loại khác, nhằm tách phần chênh lệch do loại xe gây ra. Ngoài ra, có thể bổ sung các biến như Engine Size, Drive train, Manual, hoặc thử dùng biến phản hồi là số gallon trên mỗi dặm ($1/\text{City}$), vì trong phân tích sơ bộ biến này còn cho độ khớp tốt hơn.

A. Code và dữ liệu

Toàn bộ phân tích được tập hợp trong notebook `bayes_cars_1993.ipynb`, ghép từ năm module trong thư mục `analysis/`. Với Python 3.12, PyMC 5.28 và ArviZ 0.23 (seed 2026), notebook chạy hết trong khoảng 8 phút. Phân công từng module được ghi ở bảng A.1.

Dữ liệu sau khi làm sạch được lưu tại `outputs/data_clean.csv`, bảng hậu nghiệm đầy đủ của các mô hình tại `outputs/tables/tab_4_4_posterior.csv`, còn các hình nằm trong `outputs/figures/`. Hàm khai báo chung cho năm mô hình trong PyMC được trình bày dưới đây.

```
def build_model(d, sc, terms, prior="weak", likelihood="normal"):
    X = design(d, sc, terms)          # standardised HP, Weight; USA as 0/1
    y = sc.y(d["city"])               # standardised log(City)
    coords = {"term": terms, "obs": d["name"].to_numpy()}
    with pm.Model(coords=coords) as model:
        Xd = pm.Data("X", X, dims=("obs", "term"))
        b0 = pm.Normal("b0", 0, PRIOR_SD[prior])
        b = pm.Normal("b", 0, PRIOR_SD[prior], dims="term")
        sigma = pm.HalfNormal("sigma", 1)
        mu = pm.Deterministic("mu", b0 + pm.math.dot(Xd, b), dims="obs")
        if likelihood == "student":
            nu = pm.Gamma("nu", 2, 0.1)
            pm.StudentT("y", nu=nu, mu=mu, sigma=sigma, observed=y, dims="obs")
        else:
            pm.Normal("y", mu=mu, sigma=sigma, observed=y, dims="obs")
    return model
```

Bảng A.1: Các module trong notebook chung.

Module	Phụ trách	Mục trong báo cáo
`02_data_eda.py`	TV2	Chương II, mục 3.3
`03_models.py`	TV3	Mục 3.4–3.7
`04_sampling.py`	TV4	Mục 4.2–4.4
`01_conjugate.py`	TV1	Mục 4.1
`05_evaluation.py`	TV5	Chương V

B. Khai báo sử dụng AI

Trong quá trình thực hiện, nhóm có sử dụng trợ lý AI **Claude** của Anthropic vào các việc sau:

- hỗ trợ viết, chú thích và sửa lỗi code Python (PyMC, ArviZ) trong thư mục `analysis/`;
- hỗ trợ soạn, sửa văn bản và trình bày LaTeX của báo cáo;
- rà soát cách diễn giải thống kê, ví dụ phân biệt trung vị với trung bình trên thang log, ý nghĩa tham số thang đo của Student-t và tránh diễn giải nhân quả.

Mọi con số trong báo cáo đều lấy từ kết quả chạy code của nhóm (`outputs/`), không lấy từ câu trả lời của AI. Nhóm đã đối chiếu các nhận định với kết quả tính toán và tài liệu tham khảo, và chịu trách nhiệm về toàn bộ nội dung bài.

Tài liệu tham khảo

[1] Andrew Gelman et al. *Bayesian Data Analysis*. 3rd ed. CRC Press, 2013.

[2] Richard McElreath. *Statistical Rethinking: A Bayesian Course with Examples in R and Stan*. 2nd ed. CRC Press, 2020.

[3] Consumer Reports. *The 1993 Cars – Annual Auto Issue*. 1993.

[4] PACE Publications. *PACE New Car & Truck 1993 Buying Guide*. 1993.

[5] Robin H. Lock. "1993 New Car Data". In: *Journal of Statistics Education* 1.1 (1993).

[6] W. N. Venables and B. D. Ripley. *Cars93: Data from 93 Cars on Sale in the USA in 1993 (R package MASS)*. Tài liệu bộ dữ liệu trong gói MASS, đi kèm sách Modern Applied Statistics with S. 2002. URL: https://stat.ethz.ch/R-manual/R-devel/library/MASS/html/Cars93.html.

[7] Matthew D. Hoffman and Andrew Gelman. "The No-U-Turn Sampler: Adaptively Setting Path Lengths in Hamiltonian Monte Carlo". In: *Journal of Machine Learning Research* 15 (2014), pp. 1593–1623.

[8] Oriol Abril-Pla et al. "PyMC: A Modern and Comprehensive Probabilistic Programming Framework in Python". In: *PeerJ Computer Science* 9 (2023), e1516.

[9] Aki Vehtari et al. "Rank-Normalization, Folding, and Localization: An Improved $\widehat{R}$ for Assessing Convergence of MCMC". In: *Bayesian Analysis* 16.2 (2021), pp. 667–718.

[10] Aki Vehtari, Andrew Gelman, and Jonah Gabry. "Practical Bayesian Model Evaluation Using Leave-One-Out Cross-Validation and WAIC". In: *Statistics and Computing* 27 (2017), pp. 1413–1432.

[11] Ravin Kumar et al. "ArviZ: A Unified Library for Exploratory Analysis of Bayesian Models in Python". In: *Journal of Open Source Software* 4.33 (2019), p. 1143.