ĐẠI HỌC QUỐC GIA HÀ NỘI

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA TOÁN - CƠ - TIN HỌC



BÁO CÁO CUỐI KỲ

MÔ HÌNH HỒI QUY TUYẾN TÍNH BAYES VÀ ỨNG DỤNG

ĐỀ TÀI:

HỒI QUY TUYẾN TÍNH BAYES CHO HIỆU SUẤT NHIÊN LIỆU CỦA XE MỚI TẠI MỸ NĂM 1993

Nhóm 10 thực hiện:	Nguyễn Thục Anh	25007949
	Bùi Quang Huy	25007877
	Nguyễn Thị Bích Ngọc	25007937
	Nguyễn Thu Ngân	25007865
	Nguyễn Hồng Phúc	25007860

Hà Nội, tháng 10 năm 2026

Tóm tắt

Nhóm dùng hồi quy tuyến tính Bayes để giải thích và dự đoán hiệu suất nhiên liệu trong thành phố (biến City, đơn vị MPG) của 93 mẫu xe mới bán tại Mỹ năm 1993, dựa trên công suất, trọng lượng và xuất xứ. Nhóm xây dựng năm mô hình, ước lượng bằng NUTS trong PyMC, kiểm tra hội tụ, so sánh bằng PSIS-LOO và WAIC, và đối chiếu với công thức hậu nghiệm Normal–Inverse-Gamma cho mô hình đơn giản nhất. Kết quả cho thấy trọng lượng là biến liên hệ mạnh nhất với City: khi thêm trọng lượng vào mô hình, hệ số của công suất gần như bằng 0, còn mỗi 100 kg nặng hơn ứng với City thấp hơn 6,2%. Chênh lệch City giữa xe Mỹ và xe nước ngoài cũng giảm nhiều khi có trọng lượng. Đây là liên hệ trên dữ liệu quan sát, không phải quan hệ nhân quả. Mô hình cuối dùng hàm hợp lý Student-t để giảm ảnh hưởng của vài xe cỡ nhỏ tiết kiệm bất thường. Với một xe Mỹ 300 hp nặng 1 681 kg, mô hình dự đoán trung vị City khoảng 16,6 MPG, khoảng dự đoán 95% từ 13,4 đến 20,6 MPG; ba xe thật gần 300 hp (có trong dữ liệu học) đều nằm trong khoảng này. Báo cáo gồm sáu chương, trong đó bốn chương chính ứng với bốn yêu cầu (i)–(iv) của đề.

Mục lục

Tóm tắt **1**

I Giới thiệu **5**

1.1 Bối cảnh 5

1.2 Mục tiêu và câu hỏi nghiên cứu 5

1.3 Vì sao chọn cách tiếp cận Bayes 5

II Dữ liệu sử dụng **7**

2.1 Nguồn và cách lấy mẫu 7

2.2 Danh sách biến 7

2.3 Làm sạch dữ liệu 7

2.4 Đơn vị nhiên liệu 7

2.5 Thống kê mô tả 8

2.6 Phân tích khám phá 9

III Quá trình mô hình hoá **11**

3.1 Cơ sở lý thuyết hồi quy tuyến tính . . . 11
3.2 Chọn biến . . . 11
3.3 Biến đổi biến . . . 11
3.4 Năm mô hình ứng viên . . . 12
3.5 Đặc tả đầy đủ cho M3 . . . 13
3.6 Chọn tiên nghiệm và kiểm tra dự đoán tiên nghiệm . . . 13
3.7 Ảnh hưởng của tiên nghiệm đến kết quả . . . 14

IV Quá trình ước lượng Bayes **16**

4.1 Công thức hậu nghiệm cho M1 . . . 16
4.2 Lấy mẫu MCMC . . . 16
4.3 Chẩn đoán hội tụ . . . 17
4.4 Bảng tóm tắt hậu nghiệm . . . 18

V Đánh giá kết quả và trả lời câu hỏi **21**

5.1 Kiểm tra dự đoán hậu nghiệm . . . 21
5.2 So sánh mô hình . . . 21
5.3 Trả lời Q1: quan hệ giữa các biến . . . 21
5.4 Trả lời Q2: xe Mỹ và xe nước ngoài . . . 23
5.5 Trả lời Q3: các điểm ngoại lai . . . 24
5.6 Trả lời Q4: dự đoán cho xe 300 hp . . . 26
5.7 Hạn chế . . . 27

VI Kết luận **28**

A Code và dữ liệu **29**

B Khai báo sử dụng AI **31**

Tài liệu tham khảo **32**

Danh sách hình vẽ

2.1 Ma trận biểu đồ phân tán các biến chính, tô màu theo xuất xứ. 9
2.2 City theo loại xe; điểm tô màu theo xuất xứ. 10

3.1 Phần dư OLS theo giá trị khớp, với City và log(City) làm biến phản hồi; đường cam là đường làm trơn LOWESS. 12
3.2 Phân phối City mô phỏng từ tiên nghiệm của M3 với ba tiên nghiệm, so với dữ liệu thật; trục hoành theo thang logarit, đường đứt đỏ ở 80 MPG. 14
3.3 Hậu nghiệm của M3 với ba tiên nghiệm, trung bình và HDI 95%. 15

4.1 Hậu nghiệm của M1: mật độ t tính bằng công thức (đen), NUTS với cùng tiên nghiệm NIG (xanh) và NUTS với tiên nghiệm của M1 (đỏ). 17
4.2 Biểu đồ vết của Metropolis–Hastings tự viết cho M1, bốn chuỗi. 18
4.3 Biểu đồ vết của M5: mật độ hậu nghiệm theo chuỗi (trái) và giá trị qua các vòng lặp (phải). . . 19
4.4 Hệ số hậu nghiệm của M1–M5 trên thang chuẩn hoá, trung bình và HDI 95%. 20

5.1 Kiểm tra dự đoán hậu nghiệm: mật độ dữ liệu thật (đen) và 100 bộ dữ liệu sinh từ hậu nghiệm (xanh). 22
5.2 ELPD-LOO của năm mô hình, kèm sai số chuẩn và sai số chuẩn của chênh lệch so với mô hình tốt nhất. 22
5.3 M1: City theo HP, với HDI 95% của trung vị có điều kiện (xanh đậm) và khoảng dự đoán 95% (xanh nhạt). 23
5.4 Đường hồi quy và HDI 95% cho xe Mỹ và xe nước ngoài: M3 với tương tác (trái) và M5 với Weight cố định ở mức trung bình (phải). 24
5.5 Phần dư chuẩn hoá theo giá trị dự đoán của M4 (trái) và Pareto k của từng quan sát với M4 và M5 (phải). 25
5.6 Phân phối dự đoán hậu nghiệm cho một xe Mỹ 300 hp theo M1 và M5; đường đỏ là City của ba xe thật gần 300 hp. 27

Danh sách bảng

1.1 Bốn câu hỏi của đề và cách trả lời bằng hồi quy Bayes. 6

2.1 Các nhóm biến trong bộ dữ liệu gốc. 8
2.2 Thống kê mô tả các biến chính, $n = 93$. 8

3.1 Hệ số phóng đại phương sai của hai bộ biến giải thích. 12
3.2 So sánh hai thang của biến phản hồi trong hồi quy OLS theo HP; logarit hàm hợp lý và AIC tính trên thang City. 12
3.3 Năm mô hình ứng viên; biến phản hồi luôn là $\log(\text{City})$ đã chuẩn hoá. 13
3.4 Kiểm tra dự đoán tiên nghiệm cho M3 với ba tiên nghiệm, mỗi tiên nghiệm $1\,000$ lần mô phỏng. 13

4.1 Hậu nghiệm của β_{HP} trong M1, thang chuẩn hoá: công thức so với MCMC. 17
4.2 Chẩn đoán hội tụ của năm mô hình; giá trị xấu nhất trên mọi tham số. 17
4.3 Trung bình hậu nghiệm và HDI 95% của các hệ số, thang chuẩn hoá. Cột σ là độ lệch chuẩn sai số với M1–M4 và tham số thang đo Student-t với M5. 18

5.1 So sánh mô hình bằng PSIS-LOO và WAIC; chênh lệch tính so với M5. 22
5.2 Hệ số của USA trong ba mô hình; chênh lệch City đổi ra phần trăm. 24
5.3 Các xe được xét là ngoại lai, theo M4. 25
5.4 Dự đoán City cho một xe 300 hp, $1\,681$ kg nếu mô hình có Weight. 26
5.5 Dự đoán của M5 cho ba xe thật có từ 295 hp trở lên. 26

A.1 Các module trong notebook chung. 30

I. Giới thiệu

1.1 Bối cảnh

Thập niên 1990, ngành ô tô Mỹ làm ăn có lãi. Thu nhập tăng nên người mua chuộng xe lớn và mạnh hơn: xe thể thao, sedan cỡ lớn, xe van và SUV. Xe mạnh và nặng thường tốn nhiên liệu hơn, nên câu hỏi công suất và trọng lượng ảnh hưởng thế nào đến mức tiêu hao nhiên liệu có ý nghĩa với cả người mua lẫn nhà sản xuất. Bộ dữ liệu của đề cho phép trả lời câu hỏi này trên một mẫu ngẫu nhiên các xe bán ra năm 1993.

1.2 Mục tiêu và câu hỏi nghiên cứu

Biến phản hồi chính là City, biến giải thích chính là Horsepower; Weight và USA được thêm dần qua năm mô hình. Bốn chương chính ứng với bốn yêu cầu (i)–(iv) của đề và trả lời bốn câu hỏi trong tài liệu đính kèm, như ở bảng 1.1.

1.3 Vì sao chọn cách tiếp cận Bayes

Với cách tiếp cận Bayes, mỗi hệ số có cả một phân phối hậu nghiệm chứ không chỉ một giá trị ước lượng. Nhờ vậy câu hỏi như “xe Mỹ có kém tiết kiệm hơn không” được trả lời trực tiếp bằng một xác suất. Tiên nghiệm ít thông tin loại bỏ các giá trị vô lý, ví dụ City âm hoặc trên 80 MPG, nhưng vẫn để dữ liệu quyết định kết quả. Phân phối dự đoán hậu nghiệm tính đến cả việc chưa biết chắc tham số lẫn sai số của từng quan sát. Điều này đặc biệt cần cho câu hỏi Q4, vì điểm cần dự đoán nằm ở rìa dữ liệu. Phần lý thuyết dựa theo [1, 2].

Bảng 1.1: Bốn câu hỏi của đề và cách trả lời bằng hồi quy Bayes.

#	Câu hỏi của đề	Cách trả lời	Mục
Q1	Quan hệ giữa các biến, so sánh các biểu đồ phân tán	Ma trận biểu đồ phân tán, hệ số hậu nghiệm và HDI 95%	2.6, 5.3
Q2	Khác biệt giữa xe Mỹ và xe nước ngoài	Biến giả USA, tương tác HP $\times$ USA, xác suất $P(\beta_{\text{USA}} > 0 \mid y)$	3.4, 5.4
Q3	Các điểm ngoại lai và lời giải thích	Kiểm tra dự đoán hậu nghiệm, phần dư chuẩn hoá, Pareto k của PSIS-LOO, hàm hợp lý Student-t	5.5
Q4	Chọn biến giải thích và phản hồi; dự đoán xe 300 hp	Phân phối dự đoán hậu nghiệm tại HP $= 300$, so với ba xe thật gần 300 hp	5.6

II. Dữ liệu sử dụng

2.1 Nguồn và cách lấy mẫu

Bộ dữ liệu gồm 93 mẫu xe mới bán tại Mỹ năm 1993, lấy ngẫu nhiên từ *The 1993 Cars – Annual Auto Issue* của Consumer Reports [3] và *PACE New Car & Truck 1993 Buying Guide* [4]. Mỗi dòng là một mẫu xe.

2.2 Danh sách biến

File có 25 cột gồm tên xe, 20 biến liên tục và 4 biến mã hoá, như ở bảng 2.1. Bốn biến dùng trong mô hình được in đậm.

2.3 Làm sạch dữ liệu

Dấu $*$ trong file gốc được đổi thành giá trị thiếu. Luggage capacity thiếu 11 dòng (9 xe van cùng Chevrolet Corvette và Mazda RX-7), rear seat room thiếu 2 dòng (Corvette, RX-7), Cylinders thiếu 1 dòng (RX-7, xe này dùng động cơ rotary nên không có xi-lanh theo nghĩa thông thường). Hai cột RPM được lưu dạng chuỗi có dấu phẩy ngăn cách hàng nghìn, ví dụ "6,300", nên được chuyển sang số. Bốn biến của mô hình là City, Horsepower, Weight và USA không thiếu giá trị nào, nên giữ lại cả 93 dòng; kết quả lưu trong `data_clean.csv`.

2.4 Đơn vị nhiên liệu

Tiêu đề cột ghi "km/100L" còn tài liệu đi kèm ghi "litres per 100km", hai đơn vị này ngược nhau. Giá trị chạy từ 15 đến 46, và xe nhỏ nhẹ nhất là Geo Metro (55 hp, 769 kg) lại có giá trị cao nhất, nên cả hai cách ghi đều không hợp lý. Để xác định đơn vị, nhóm so từng dòng với bộ dữ liệu gốc `Cars93` trong gói R `MASS` [5, 6], bộ này có cùng 93 mẫu xe theo cùng thứ tự. Kết quả:

- City trùng khớp cả 93 dòng với `MPG.city`, Open Road trùng khớp với `MPG.highway`; tài liệu của `MASS` ghi rõ hai biến này là dặm trên gallon Mỹ theo xếp hạng EPA;
- Horsepower trùng khớp cả 93 dòng, còn Weight bằng `Weight` (pound) nhân $0{,}4536$, sai lệch không quá $0{,}5$ kg do làm tròn. Ví dụ Acura Integra: City 25, Open Road 31, 140 hp, 1 227 kg so với 25, 31, 140 hp

Bảng 2.1: Các nhóm biến trong bộ dữ liệu gốc.

Nhóm	Biến
Giá (nghìn USD)	Min Price, Mid Price, Max Price
Nhiên liệu (MPG)	**City**, Open Road
Động cơ	**Horsepower** (hp), Engine Size (L), Cylinders, RPM tại công suất cực đại, RPM khi chạy đều, Fuel Tank (L)
Kích thước	**Weight** (kg), Length, Wheelbase, Width (cm), U-turn (m), Rear seat (cm), Luggage (m^3), Passengers
Mã hoá	Type 1–6 (Small, Midsize, Large, Compact, Sporty, Van); Airbag 0–2; Drive train 0–2; Manual 0/1; **USA** 0/1 (1 là xe Mỹ)

Bảng 2.2: Thống kê mô tả các biến chính, $n = 93$.

Biến	Trung bình	Độ lệch chuẩn	Nhỏ nhất	Trung vị	Lớn nhất
City (MPG)	22,4	5,6	15	21	46
Open Road (MPG)	29,1	5,3	20	28	50
Horsepower (hp)	143,8	52,4	55	140	300
Weight (kg)	1 394	268	769	1 379	1 862
Engine Size (L)	2,7	1,0	1,0	2,4	5,7
Mid Price (nghìn USD)	19,5	9,7	7,4	17,7	61,9

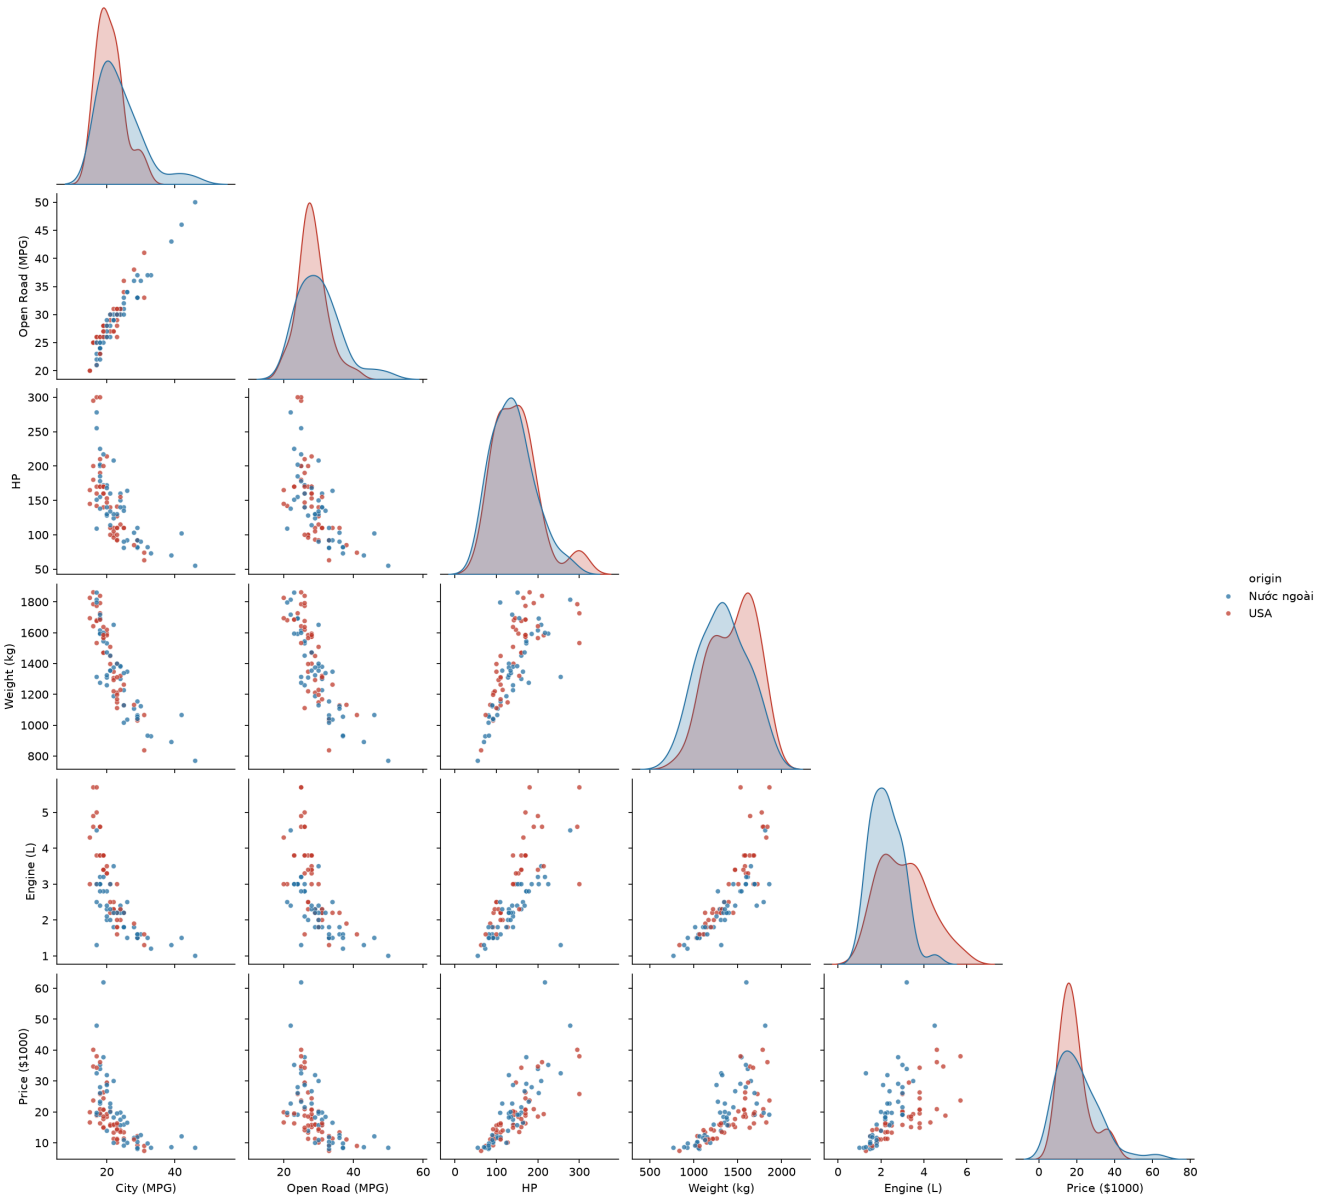
và 2705 lb.

Vậy bản Q_10 là `Cars93` đã đổi một số cột sang hệ mét, nhưng giữ nguyên hai cột nhiên liệu và ghi nhầm đơn vị. Từ đây báo cáo dùng MPG (dặm trên gallon, càng cao càng tiết kiệm). Nếu cần đổi đơn vị thì L/100km $= 235{,}2/\text{MPG}$.

2.5 Thống kê mô tả

Mẫu có 48 xe Mỹ và 45 xe nước ngoài. Công suất từ 55 đến 300 hp, trung vị 140; City từ 15 đến 46 MPG, trung vị 21 (bảng 2.2). Hệ số tương quan giữa HP và City là $-0{,}67$, giữa City và Open Road là $0{,}94$.

Chia theo xuất xứ, xe Mỹ nặng hơn (trung bình 1 449 kg so với 1 335 kg), máy lớn hơn (3,1 L so với 2,2 L) và kém tiết kiệm hơn (City 21,0 so với 23,9 MPG), trong khi công suất trung bình gần bằng nhau (147,5 so với 139,9 hp). Vì vậy chênh lệch City giữa hai nhóm có thể do trọng lượng chứ chưa chắc do công suất; mục 5.4 sẽ kiểm tra điều này.

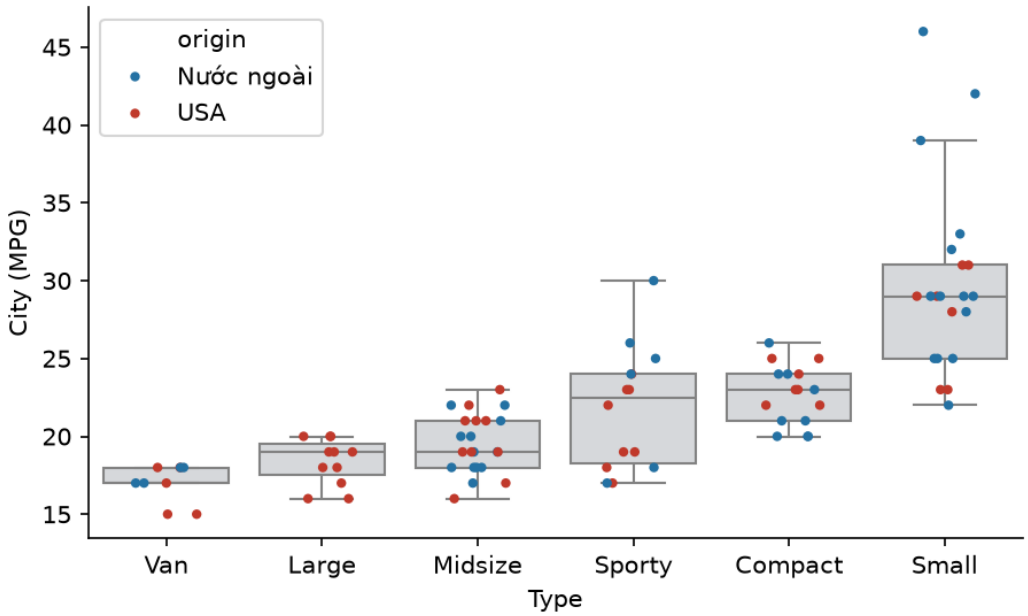


Hình 2.1: Ma trận biểu đồ phân tán các biến chính, tô màu theo xuất xứ.

2.6 Phân tích khám phá

Ma trận biểu đồ phân tán ở hình 2.1 cho thấy City giảm theo HP, Weight và Engine Size theo dạng cong: giảm nhanh ở nhóm xe nhỏ và chậm lại ở nhóm xe lớn. Xe nước ngoài tập trung ở vùng nhẹ, máy nhỏ, City cao; xe Mỹ nặng hơn và máy lớn hơn. City và Open Road gần như nằm trên một đường thẳng, nên hai biến nhiều khả năng có xu hướng giống nhau; báo cáo chỉ xây dựng mô hình cho City.

Theo loại xe (hình 2.2), nhóm Small tiết kiệm nhất, còn Van và Large tốn nhiên liệu nhất. Một hồi quy OLS sơ bộ $\log(\text{City}) \sim \text{HP}$ cho thấy năm xe có phần dư studentised vượt ± 2: Honda Civic $(+3{,}6)$, Geo Metro $(+3{,}2)$, Suzuki Swift $(+2{,}4)$, Ford Aerostar $(-2{,}4)$ và Volkswagen Eurovan $(-2{,}3)$. Mục 5.5 xét lại các xe này với mô hình đầy đủ.



Hình 2.2: City theo loại xe; điểm tô màu theo xuất xứ.

III. Quá trình mô hình hoá

3.1 Cơ sở lý thuyết hồi quy tuyến tính

Mô hình hồi quy tuyến tính biểu diễn biến phản hồi qua các biến giải thích và một sai số ngẫu nhiên:

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i, \qquad \varepsilon_i \sim \mathcal{N}(0, \sigma^2). \tag{3.1}$$

Mô hình giả định quan hệ là tuyến tính (sau khi biến đổi biến nếu cần), các sai số độc lập, cùng phương sai và có phân phối chuẩn. Biến giả USA bằng 1 với xe Mỹ và 0 với xe nước ngoài, nên hệ số của nó là chênh lệch hệ số chặn giữa hai nhóm. Số hạng tương tác HP $\times$ USA cho phép hệ số góc theo HP khác nhau giữa hai nhóm. Khi hai biến giải thích tương quan mạnh, hệ số của chúng không ổn định và khó diễn giải riêng; hiện tượng đa cộng tuyến này được đo bằng hệ số phóng đại phương sai VIF.

Phương pháp bình phương tối thiểu (OLS) cho một giá trị ước lượng và một khoảng tin cậy theo tần suất, còn cách tiếp cận Bayes cho cả phân phối hậu nghiệm của mỗi hệ số. Với tiên nghiệm ít thông tin, trung bình hậu nghiệm gần bằng ước lượng OLS; ví dụ hệ số β_{HP} của M3 là $-0{,}860$ theo OLS và $-0{,}859$ theo Bayes.

3.2 Chọn biến

City là biến phản hồi và HP là biến giải thích chính, đúng với câu hỏi Q4. Weight và Engine Size tương quan mạnh với HP ($0{,}74$ và $0{,}73$) và với nhau ($0{,}85$), nên nhóm tính VIF trước khi đưa cả ba vào (bảng 3.1). Mọi VIF đều dưới 5, nhưng Engine Size gần như lặp lại thông tin của Weight, nên nhóm chỉ giữ Weight. Với bộ biến của M4, VIF lớn nhất là $2{,}34$.

3.3 Biến đổi biến

Quan hệ giữa City và HP có dạng cong, nên nhóm so sánh hai cách: hồi quy OLS City theo HP và hồi quy $\log(\text{City})$ theo HP. Để so được hai mô hình, logarit hàm hợp lý của mô hình logarit được tính lại trên thang City bằng cách cộng thêm Jacobian $-\sum_i \log \text{City}_i$. Theo bảng 3.2, $\log(\text{City})$ khớp tốt hơn rõ rệt, AIC thấp hơn 36 đơn vị, và đường làm trơn của phần dư ở hình 3.1 không còn dạng cong.

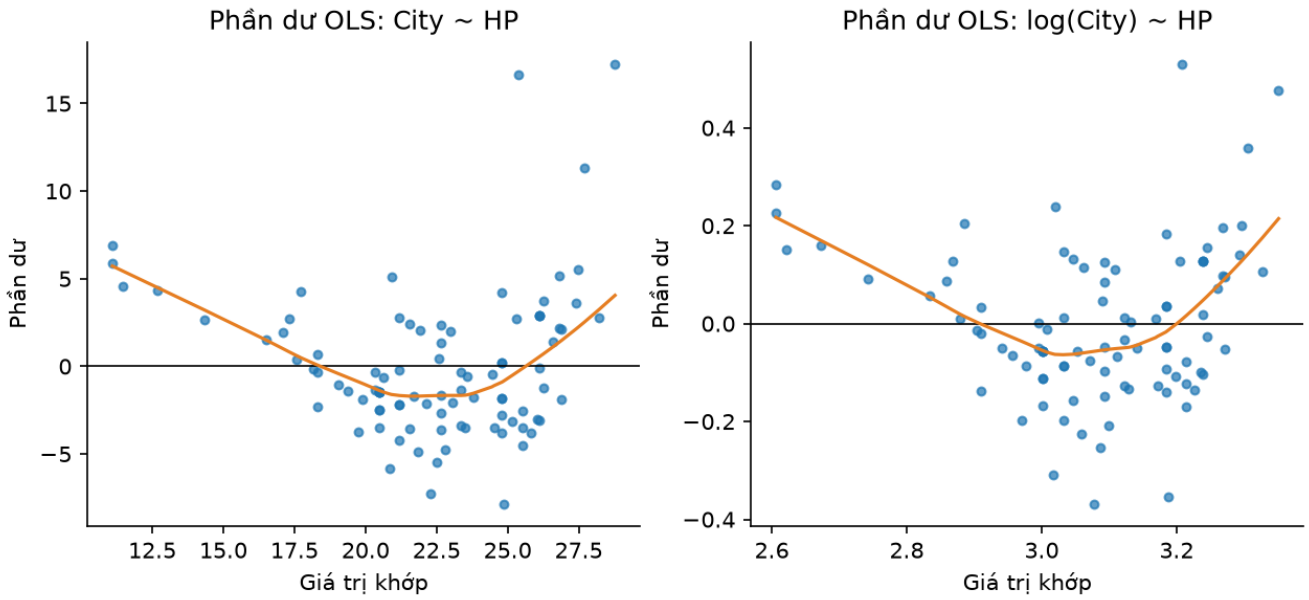
Vì vậy mọi mô hình đều dùng $y = \log(\text{City})$ đã chuẩn hoá. HP và Weight được chuẩn hoá bằng cách trừ trung

Bảng 3.1: Hệ số phóng đại phương sai của hai bộ biến giải thích.

Biến	HP + Weight + Engine Size	M4: HP + Weight + USA
HP	2,42	2,24
Weight	3,93	2,34
Engine Size	3,84	–
USA	–	1,07

Bảng 3.2: So sánh hai thang của biến phản hồi trong hồi quy OLS theo HP; logarit hàm hợp lý và AIC tính trên thang City.

Biến phản hồi	R^2	Logarit hàm hợp lý	AIC
City	0,452	−264,0	534,0
log(City)	0,506	−246,0	498,0



Hình 3.1: Phần dư OLS theo giá trị khớp, với City và log(City) làm biến phản hồi; đường cam là đường làm trơn LOWESS.

bình và chia độ lệch chuẩn mẫu, còn USA giữ nguyên 0/1. Chuẩn hoá giúp đặt tiên nghiệm dễ hơn vì mọi hệ số cùng một thang, và giúp MCMC hội tụ tốt hơn. Kết quả cuối được đổi ngược về MPG bằng City $= \exp(\bar{\ell} + s_\ell\, y)$, trong đó $\bar{\ell}$ và s_ℓ là trung bình và độ lệch chuẩn của log(City) trong mẫu.

3.4 Năm mô hình ứng viên

Năm mô hình ở bảng 3.3 thêm dần biến giải thích. M5 dùng cùng bộ biến với M4, mô hình tốt nhất trong M1–M4 theo PSIS-LOO, nhưng thay hàm hợp lý chuẩn bằng Student-t để giảm ảnh hưởng của điểm ngoại lai.

Bảng 3.3: Năm mô hình ứng viên; biến phản hồi luôn là $\log(\text{City})$ đã chuẩn hoá.

Mô hình	Công thức	Hàm hợp lý
M1	City $\sim$ HP	Chuẩn
M2	City $\sim$ HP + USA	Chuẩn
M3	City $\sim$ HP + USA + HP $\times$ USA	Chuẩn
M4	City $\sim$ HP + Weight + USA	Chuẩn
M5	City $\sim$ HP + Weight + USA	Student-t

Bảng 3.4: Kiểm tra dự đoán tiên nghiệm cho M3 với ba tiên nghiệm, mỗi tiên nghiệm $1\,000$ lần mô phỏng.

Tiên nghiệm	City ≤ 80 MPG	City trong 5–80 MPG	Trung vị (MPG)
Phẳng, sd $= 100$	53,3%	3,4%	5,4
Ít thông tin, sd $= 2{,}5$	92,1%	86,2%	21,0
Hẹp, sd $= 0{,}5$	99,9%	99,9%	21,6

3.5 Đặc tả đầy đủ cho M3

Trên thang đã chuẩn hoá, M3 có dạng

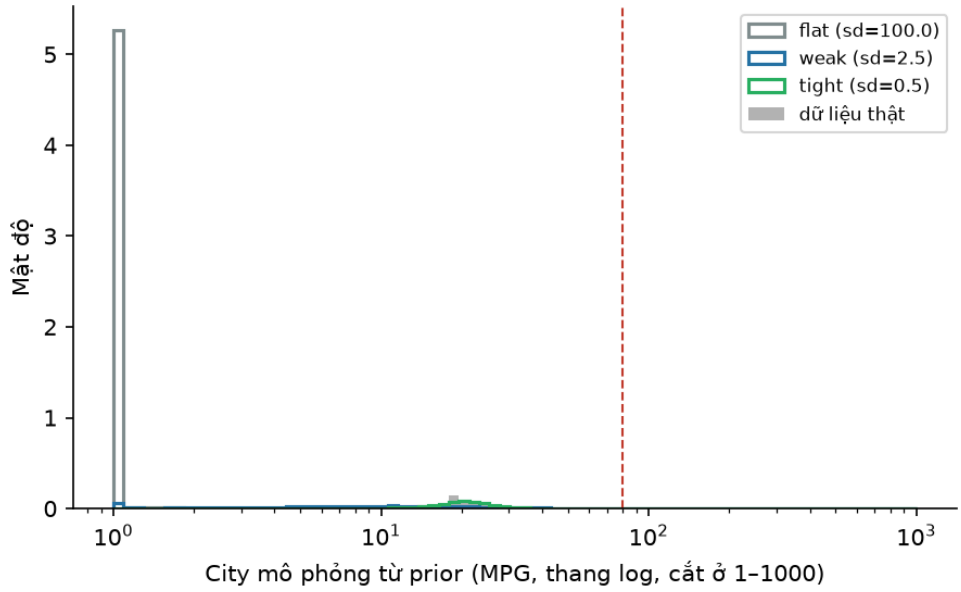
$$\begin{aligned} y_i &\sim \mathcal{N}(\mu_i, \sigma^2), \\ \mu_i &= \beta_0 + \beta_1 \text{HP}_i + \beta_2 \text{USA}_i + \beta_3 \text{HP}_i \text{USA}_i, \\ \beta_j &\sim \mathcal{N}(0, 2{,}5^2), \qquad j = 0, \ldots, 3, \\ \sigma &\sim \text{Half-Normal}(1). \end{aligned} \tag{3.2}$$

Các mô hình khác bỏ bớt hoặc thay số hạng trong μ_i. M5 thay hàm hợp lý chuẩn bằng $y_i \sim t_\nu(\mu_i, \sigma)$ với $\nu \sim \text{Gamma}(2;\, 0{,}1)$, cho phép phân phối có đuôi dày hơn khi dữ liệu có điểm ngoại lai. Tiên nghiệm này có trung bình 20 nhưng vẫn cho xác suất đáng kể với các giá trị ν nhỏ.

3.6 Chọn tiên nghiệm và kiểm tra dự đoán tiên nghiệm

Nhóm so sánh ba tiên nghiệm cho các hệ số: tiên nghiệm phẳng $\mathcal{N}(0, 100^2)$, tiên nghiệm ít thông tin $\mathcal{N}(0, 2{,}5^2)$ và tiên nghiệm hẹp $\mathcal{N}(0, 0{,}5^2)$. Tiên nghiệm liên hợp Normal–Inverse-Gamma cho công thức hậu nghiệm ở mục 4.1; còn các tiên nghiệm độc lập trong (3.2) không liên hợp nên phải dùng MCMC. Để kiểm tra, nhóm sinh $1\,000$ bộ dữ liệu từ tiên nghiệm của M3 và đếm tỉ lệ City nằm trong miền hợp lý. Vì mô hình đặt trên thang logarit nên City luôn dương, điều kiện còn lại là City không quá 80 MPG.

Theo bảng 3.4 và hình 3.2, tiên nghiệm phẳng sinh ra phần lớn giá trị vô lý, chỉ 3,4% mô phỏng nằm trong

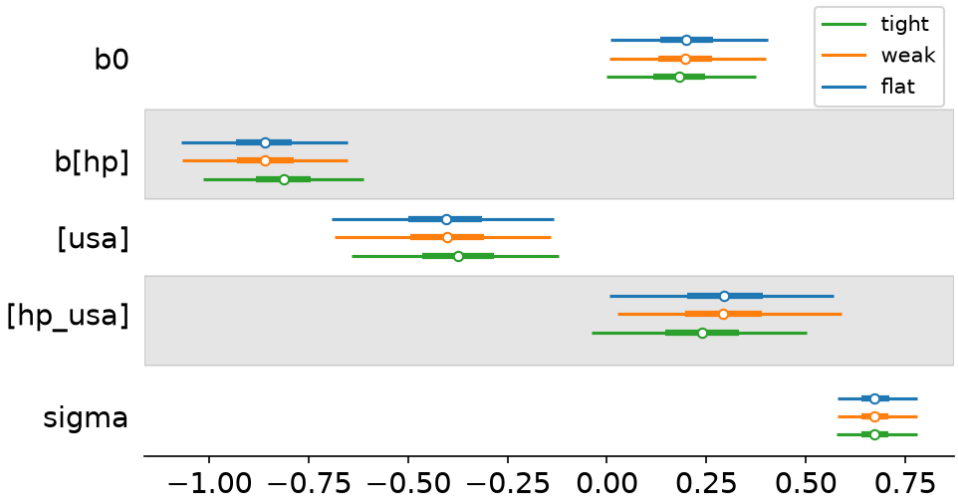


Hình 3.2: Phân phối City mô phỏng từ tiên nghiệm của M3 với ba tiên nghiệm, so với dữ liệu thật; trục hoành theo thang logarit, đường đứt đỏ ở 80 MPG.

khoảng 5–80 MPG. Tiên nghiệm ít thông tin giữ 86% mô phỏng trong khoảng đó mà vẫn đủ rộng để không ép kết quả, nên được chọn làm tiên nghiệm chính. Tiên nghiệm hẹp cho giá trị hợp lý nhưng có thể kéo hệ số về 0; mục 3.7 kiểm tra điều này.

3.7 Ảnh hưởng của tiên nghiệm đến kết quả

Nhóm chạy lại M3 với cả ba tiên nghiệm. Tiên nghiệm phẳng và tiên nghiệm ít thông tin cho hậu nghiệm gần như trùng nhau, trung bình lệch nhau nhiều nhất $0{,}04$ độ lệch chuẩn hậu nghiệm, tức kết quả do dữ liệu quyết định. Tiên nghiệm hẹp kéo các hệ số về 0 nhiều nhất $0{,}42$ độ lệch chuẩn hậu nghiệm, rõ nhất ở tương tác HP $\times$ USA: hệ số này giảm từ $0{,}294$ xuống $0{,}239$ và HDI 95% bắt đầu chứa 0 (hình 3.3). Vì vậy kết luận về tương tác ở mục 5.4 cần nói thận trọng.



Hình 3.3: Hậu nghiệm của M3 với ba tiên nghiệm, trung bình và HDI 95%.

IV. Quá trình ước lượng Bayes

4.1 Công thức hậu nghiệm cho M1

Theo định lý Bayes, hậu nghiệm tỉ lệ với tích của hàm hợp lý và tiên nghiệm:

$$p(\beta, \sigma^2 \mid y) \propto p(y \mid \beta, \sigma^2)\, p(\beta, \sigma^2). \tag{4.1}$$

Với tiên nghiệm liên hợp Normal–Inverse-Gamma $\beta \mid \sigma^2 \sim \mathcal{N}(m_0, \sigma^2 V_0)$ và $\sigma^2 \sim \mathrm{IG}(a_0, b_0)$, hậu nghiệm có cùng dạng với các tham số

$$\begin{aligned} V_n &= \left(V_0^{-1} + X^\top X\right)^{-1}, \quad & m_n &= V_n\left(V_0^{-1} m_0 + X^\top y\right), \\ a_n &= a_0 + \tfrac{n}{2}, & b_n &= b_0 + \tfrac{1}{2}\left(y^\top y + m_0^\top V_0^{-1} m_0 - m_n^\top V_n^{-1} m_n\right). \end{aligned} \tag{4.2}$$

Lấy tích phân theo σ^2 ta được phân phối biên của β là phân phối t nhiều chiều với $2a_n$ bậc tự do, tâm m_n và ma trận tỉ lệ $(b_n/a_n)V_n$ [1]. Nhóm chọn $m_0 = 0$, $V_0 = 2{,}5^2 I$, $a_0 = 2$, $b_0 = 1$ và tính được $a_n = 48{,}5$, $b_n = 23{,}76$.

Để kiểm tra code, nhóm viết lại đúng tiên nghiệm này trong PyMC và lấy mẫu bằng NUTS. Bảng 4.1 cho thấy hai kết quả khớp đến chữ số thập phân thứ ba; nếu lệch nhau thì code có lỗi. Dòng thứ ba dùng tiên nghiệm ít thông tin độc lập của M1, khác tiên nghiệm liên hợp, nhưng hậu nghiệm vẫn gần như trùng, vì cả hai tiên nghiệm đều rộng và 93 quan sát đủ để dữ liệu quyết định kết quả (hình 4.1).

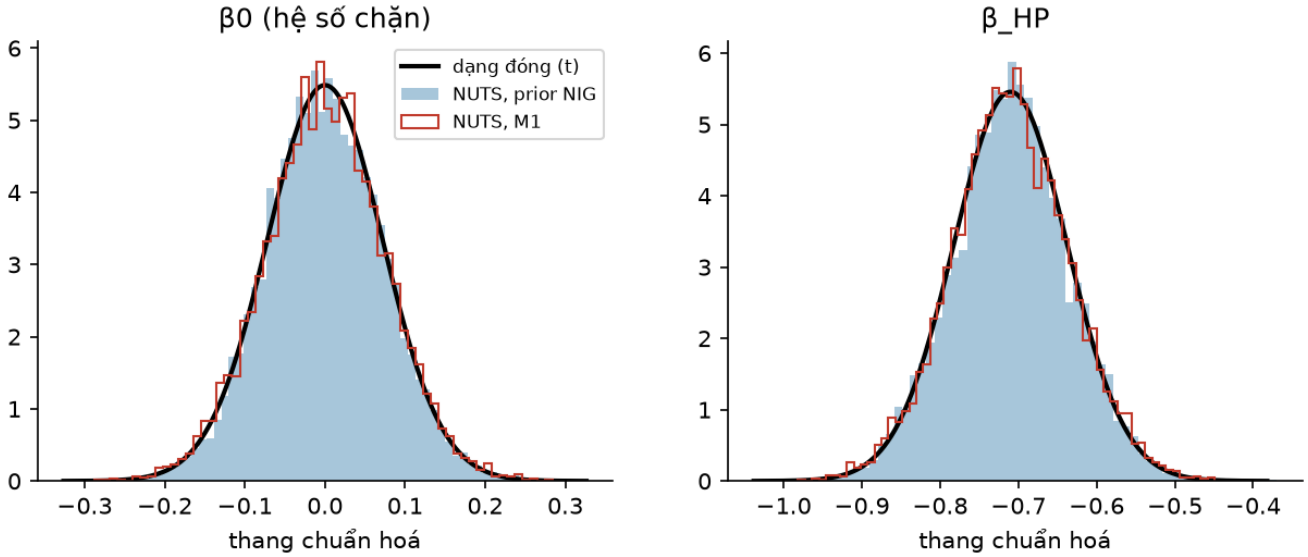
4.2 Lấy mẫu MCMC

M2–M5 không có công thức hậu nghiệm nên được lấy mẫu bằng NUTS [7] trong PyMC 5.28 [8], với 4 chuỗi, mỗi chuỗi $2\,000$ vòng sau $1\,000$ vòng khởi động, seed cố định 2026. NUTS là một dạng của Hamiltonian Monte Carlo: nó dùng gradient của logarit hậu nghiệm để đề xuất các bước đi xa mà vẫn có xác suất chấp nhận cao, và tự chọn độ dài bước thay vì để người dùng chỉnh tay.

Để thấy sự khác biệt, nhóm tự viết thuật toán Metropolis–Hastings bước ngẫu nhiên cho M1. Thuật toán lấy mẫu trên $(\beta_0, \beta_1, \log\sigma)$, cộng thêm Jacobian $\log\sigma$ vào logarit hậu nghiệm, bước đề xuất có phân phối chuẩn với độ lệch chuẩn $0{,}08$, chạy 4 chuỗi $6\,000$ vòng và bỏ $1\,000$ vòng đầu. Tỉ lệ chấp nhận từ $0{,}41$ đến $0{,}43$. Metropolis–Hastings cho cùng hậu nghiệm với NUTS ($\beta_{\mathrm{HP}} = -0{,}708$ so với $-0{,}710$) nhưng kém hiệu quả hơn nhiều: cỡ mẫu hiệu dụng khoảng $1\,700$ từ $20\,000$ mẫu, trong khi NUTS đạt khoảng $12\,000$ từ $8\,000$ mẫu. Lý

Bảng 4.1: Hậu nghiệm của β_{HP} trong M1, thang chuẩn hoá: công thức so với MCMC.

Cách tính	Trung bình	Độ lệch chuẩn	Khoảng 95%
Công thức (NIG)	$-0{,}710\,1$	$0{,}073\,7$	$[-0{,}855; -0{,}565]$
NUTS, cùng tiên nghiệm NIG	$-0{,}709\,9$	$0{,}074\,2$	$[-0{,}857; -0{,}564]$
NUTS, tiên nghiệm ít thông tin M1	$-0{,}710\,3$	$0{,}075\,4$	$[-0{,}862; -0{,}560]$



Hình 4.1: Hậu nghiệm của M1: mật độ t tính bằng công thức (đen), NUTS với cùng tiên nghiệm NIG (xanh) và NUTS với tiên nghiệm của M1 (đỏ).

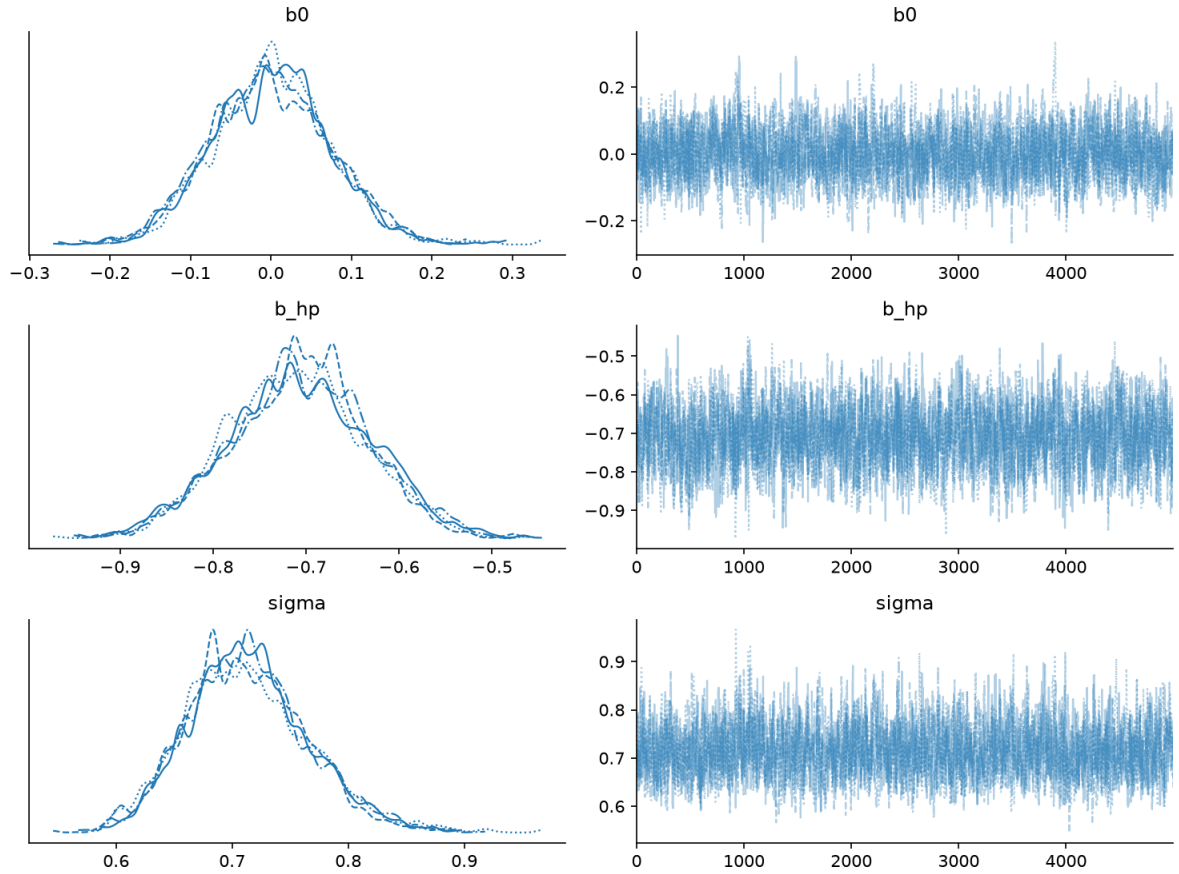
Bảng 4.2: Chẩn đoán hội tụ của năm mô hình; giá trị xấu nhất trên mọi tham số.

Mô hình	$\widehat{R}$ lớn nhất	ESS bulk nhỏ nhất	ESS tail nhỏ nhất	Số bước phân kỳ
M1	1,00	10 830	5 460	0
M2	1,00	6 013	5 295	0
M3	1,00	5 618	5 197	0
M4	1,00	5 116	5 091	0
M5	1,00	4 626	4 763	0

do là mỗi bước của Metropolis–Hastings chỉ dịch đi một đoạn ngắn, nên các mẫu liên tiếp tương quan mạnh (hình 4.2).

4.3 Chẩn đoán hội tụ

Nhóm dùng bốn tiêu chí: $\widehat{R}$ (tính theo thứ hạng) [9] nhỏ hơn 1,01, cỡ mẫu hiệu dụng (ESS) bulk và tail đều trên 400, không có bước phân kỳ (divergence), và biểu đồ vết cùng biểu đồ thứ hạng không có dấu hiệu bất thường. Cả năm mô hình đều đạt (bảng 4.2); biểu đồ vết của mô hình cuối ở hình 4.3 cho thấy bốn chuỗi trộn đều. Code sẽ dừng nếu có mô hình không đạt, nên không có hệ số nào được lấy từ chuỗi chưa hội tụ.



Hình 4.2: Biểu đồ vết của Metropolis–Hastings tự viết cho M1, bốn chuỗi.

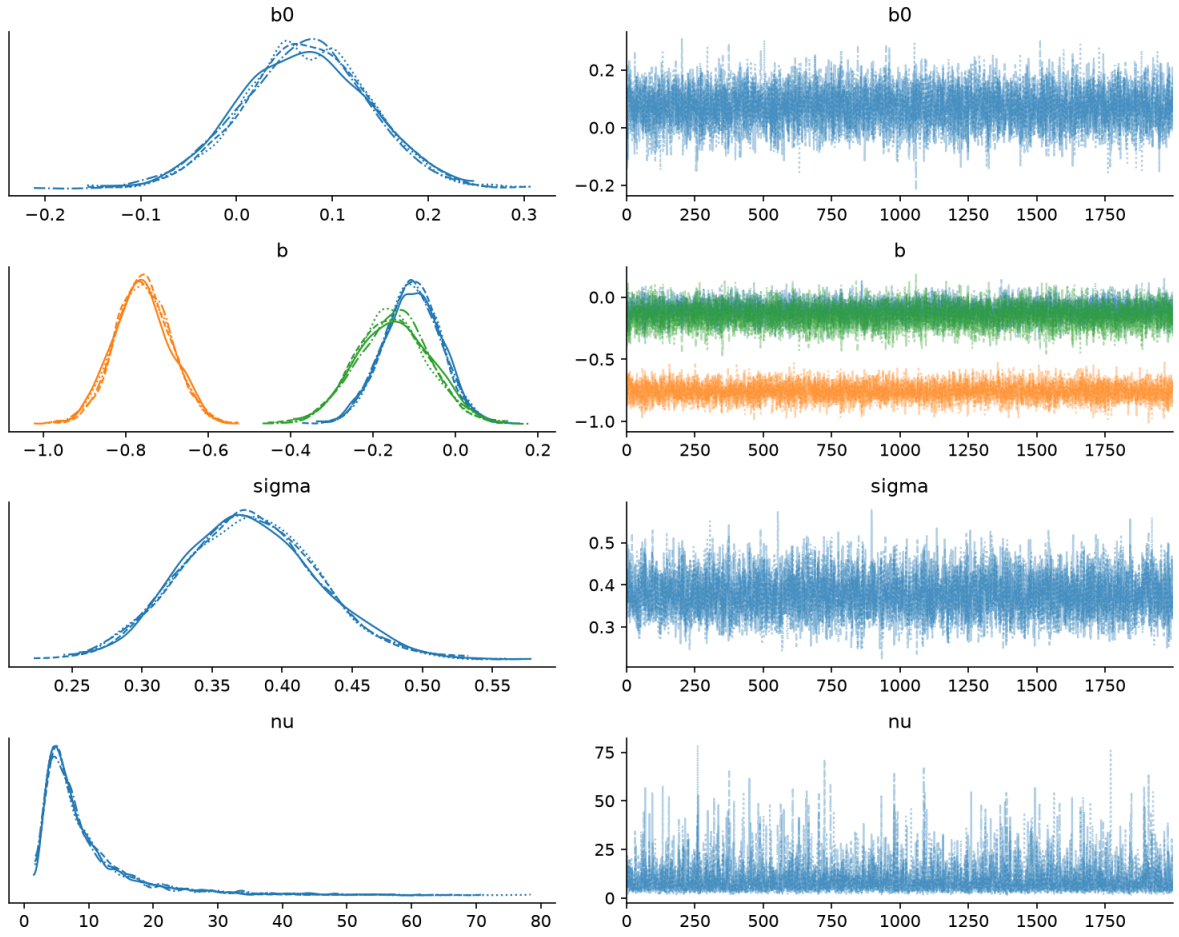
Bảng 4.3: Trung bình hậu nghiệm và HDI 95% của các hệ số, thang chuẩn hoá. Cột σ là độ lệch chuẩn sai số với M1–M4 và tham số thang đo Student-t với M5.

Mô hình	β_{HP}	β_{USA}	$\beta_{\text{HP}\times\text{USA}}$	β_{Weight}	σ
M1	$-0{,}71$ [$-0{,}86$; $-0{,}56$]	–	–	–	$0{,}72$
M2	$-0{,}70$ [$-0{,}84$; $-0{,}55$]	$-0{,}41$ [$-0{,}69$; $-0{,}13$]	–	–	$0{,}69$
M3	$-0{,}86$ [$-1{,}07$; $-0{,}65$]	$-0{,}40$ [$-0{,}69$; $-0{,}14$]	$0{,}29$ [$0{,}03$; $0{,}59$]	–	$0{,}68$
M4	$-0{,}15$ [$-0{,}29$; $0{,}00$]	$-0{,}16$ [$-0{,}36$; $0{,}03$]	–	$-0{,}76$ [$-0{,}89$; $-0{,}61$]	$0{,}47$
M5	$-0{,}11$ [$-0{,}25$; $0{,}02$]	$-0{,}15$ [$-0{,}33$; $0{,}02$]	–	$-0{,}76$ [$-0{,}89$; $-0{,}62$]	$0{,}38$

4.4 Bảng tóm tắt hậu nghiệm

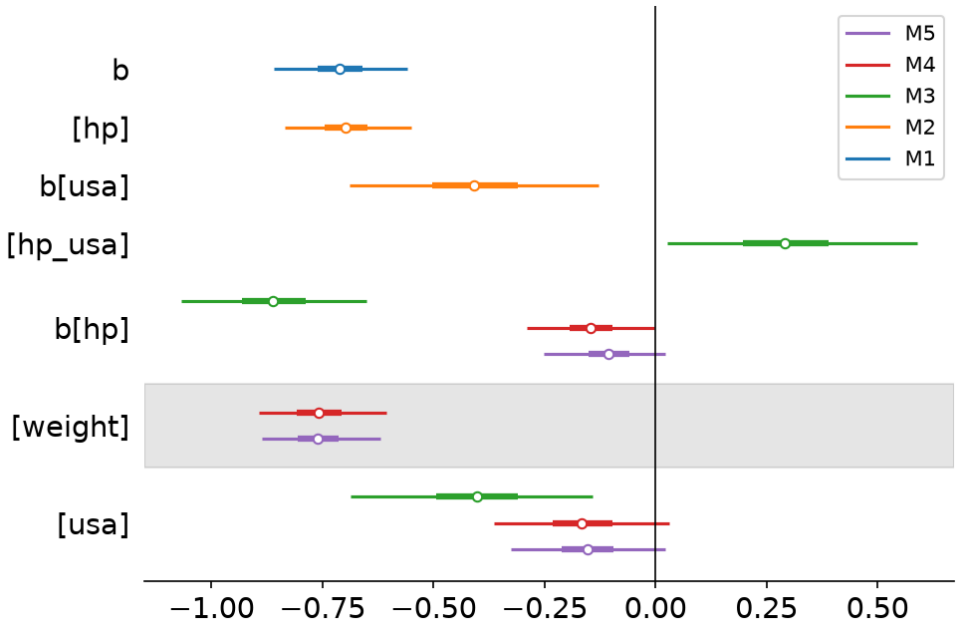
Bảng 4.3 cho trung bình hậu nghiệm và HDI 95% trên thang chuẩn hoá. Hệ số của HP và Weight là mức thay đổi của $\log(\text{City})$ chuẩn hoá khi biến tăng một độ lệch chuẩn; hệ số của USA là chênh lệch giữa xe Mỹ và xe nước ngoài. M5 có thêm $\nu = 9{,}4$ với HDI 95% là $[1{,}8;\ 24{,}7]$, tức đuôi phân phối dày vừa phải.

Khi thêm Weight ở M4 và M5, hệ số của HP giảm từ khoảng $-0{,}7$ xuống khoảng $-0{,}1$, còn σ giảm từ $0{,}68$ (M3) xuống $0{,}47$ (M4). Xe mạnh thường cũng là xe nặng, nên liên hệ giữa HP và City trong M1–M3 phần lớn chính là liên hệ giữa Weight và City. Dữ liệu quan sát không đủ để tách riêng tác động của từng biến (hình 4.4). Lưu ý ở M1–M4, σ là độ lệch chuẩn của sai số; còn ở M5, σ là tham số thang đo của phân phối Student-t nên



Hình 4.3: Biểu đồ vết của M5: mật độ hậu nghiệm theo chuỗi (trái) và giá trị qua các vòng lặp (phải).

không so trực tiếp được với các mô hình khác (xem mục 5.5).



Hình 4.4: Hệ số hậu nghiệm của M1–M5 trên thang chuẩn hoá, trung bình và HDI 95%.

V. Đánh giá kết quả và trả lời câu hỏi

5.1 Kiểm tra dự đoán hậu nghiệm

Với mỗi mô hình, nhóm sinh $8\,000$ bộ dữ liệu từ hậu nghiệm, đổi về MPG, rồi so mật độ của chúng với dữ liệu thật (hình 5.1). Cả năm mô hình đều tái tạo tốt trung bình của City, với p-value Bayes từ $0{,}38$ đến $0{,}47$. M1–M4 không tái tạo được hai đầu phân phối: dữ liệu sinh ra hiếm khi có xe đạt 46 MPG như Geo Metro, p-value của giá trị lớn nhất chỉ từ $0{,}006$ đến $0{,}024$. M5 tốt hơn ở cả hai đầu, p-value của giá trị lớn nhất là $0{,}041$ và của giá trị nhỏ nhất là $0{,}044$.

5.2 So sánh mô hình

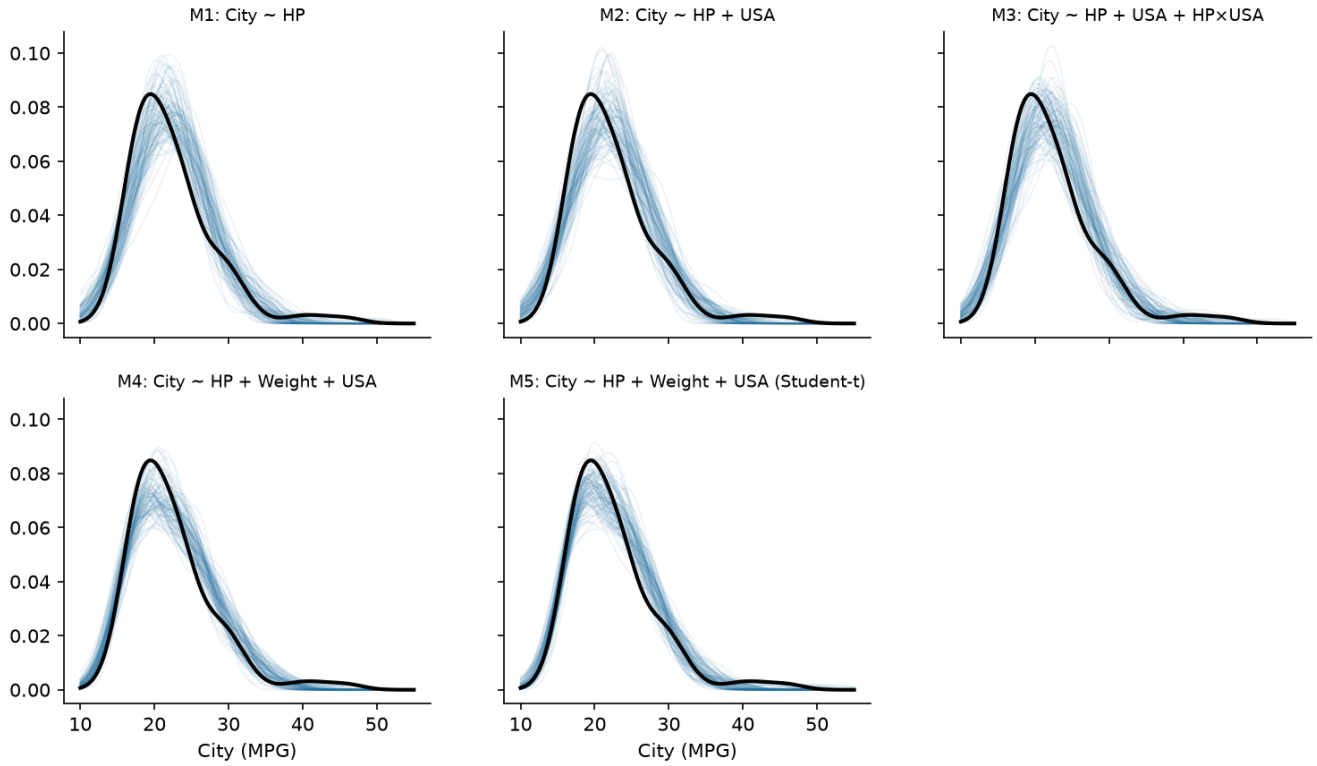
Nhóm so sánh các mô hình bằng ELPD ước lượng qua PSIS-LOO và WAIC [10], tính bằng ArviZ [11]. Hai tiêu chí cho cùng thứ hạng (bảng 5.1). Mô hình được chọn là M5, có ELPD cao nhất và trọng số stacking $0{,}97$. M5 hơn M4 $4{,}45$ đơn vị ELPD, với sai số chuẩn $2{,}60$, tức khoảng $1{,}7$ lần sai số chuẩn: đủ để chọn M5 nhưng chênh lệch không lớn. Nhóm có Weight (M4, M5) hơn nhóm không có (M1–M3) từ 34 đến 43 đơn vị ELPD, tức hơn bốn lần sai số chuẩn.

Không có quan sát nào có Pareto k vượt $0{,}7$, nên ước lượng PSIS-LOO dùng được cho mọi mô hình (hình 5.2).

5.3 Trả lời Q1: quan hệ giữa các biến

Công suất và hiệu suất nhiên liệu có quan hệ nghịch rõ rệt, nhưng khi thêm trọng lượng vào mô hình thì hệ số của công suất nhỏ đi nhiều. Trên thang logarit, khi HP tăng 10 thì trung vị có điều kiện của City được nhân với $\exp(10\,\beta_{\text{HP}}\,s_\ell/s_{\text{HP}})$, trong đó s_{HP} là độ lệch chuẩn của HP. Vì vậy các phần trăm dưới đây là mức thay đổi tương đối của trung vị City.

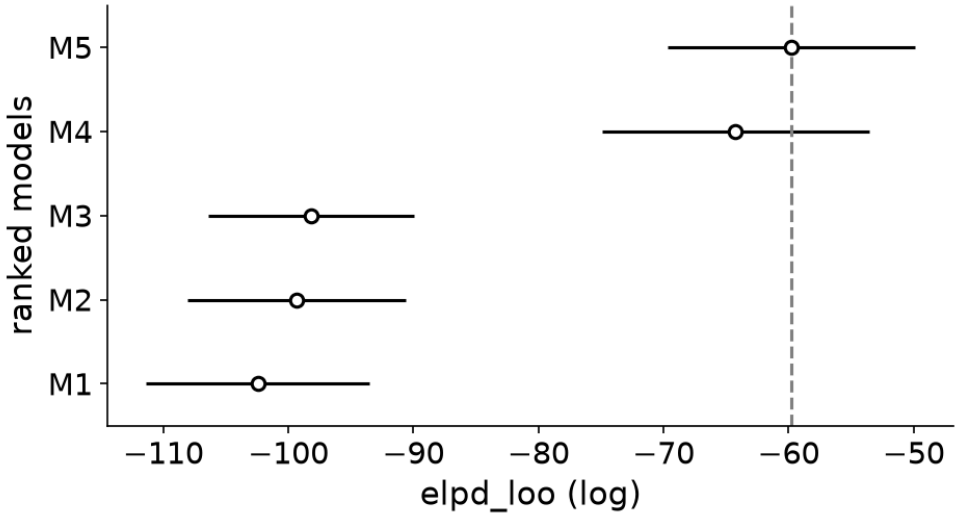
- Chỉ dùng HP (M1): mỗi 10 hp tăng thêm làm City giảm 3,0%, HDI 95% từ $-3{,}6\%$ đến $-2{,}4\%$. Từ 140 lên 150 hp, trung vị City giảm $0{,}66$ MPG, HDI 95% từ $-0{,}80$ đến $-0{,}52$ MPG (hình 5.3).
- Với cùng Weight (M5): mức giảm ứng với 10 hp chỉ còn $-0{,}45\%$, HDI 95% từ $-1{,}07\%$ đến $+0{,}10\%$, xác suất hệ số âm là $0{,}94$.



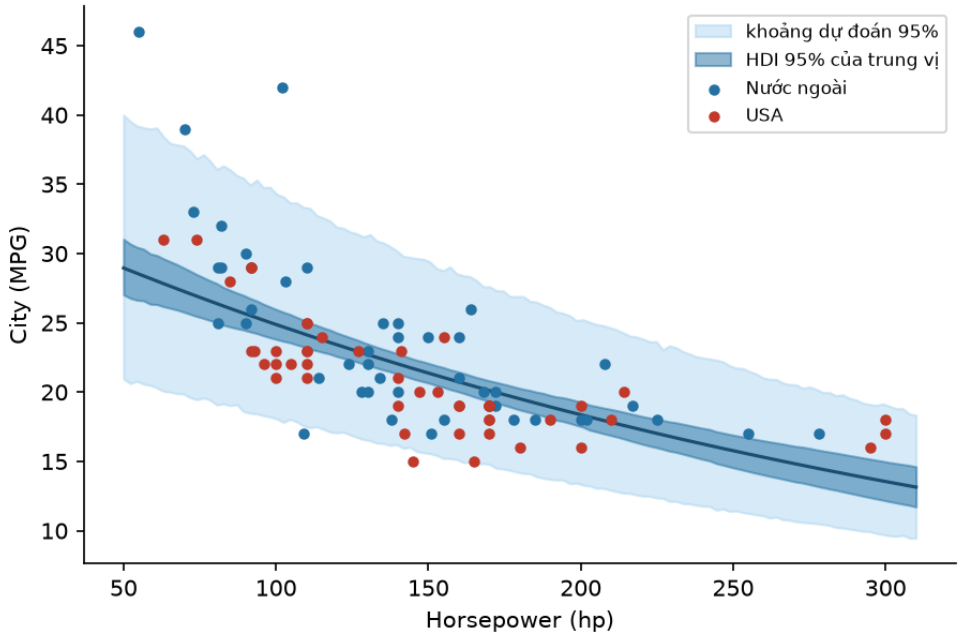
Hình 5.1: Kiểm tra dự đoán hậu nghiệm: mật độ dữ liệu thật (đen) và 100 bộ dữ liệu sinh từ hậu nghiệm (xanh).

Bảng 5.1: So sánh mô hình bằng PSIS-LOO và WAIC; chênh lệch tính so với M5.

Mô hình	ELPD-LOO	p_{loo}	Chênh lệch	SE chênh lệch	ELPD-WAIC	Pareto $k > 0{,}5$
M5	$-59{,}8$	$6{,}4$	0	–	$-59{,}7$	0
M4	$-64{,}2$	$6{,}7$	$4{,}4$	$2{,}6$	$-64{,}2$	1
M3	$-98{,}2$	$6{,}0$	$38{,}4$	$8{,}4$	$-98{,}1$	0
M2	$-99{,}3$	$5{,}1$	$39{,}6$	$8{,}2$	$-99{,}3$	0
M1	$-102{,}4$	$4{,}1$	$42{,}6$	$7{,}8$	$-102{,}4$	0



Hình 5.2: ELPD-LOO của năm mô hình, kèm sai số chuẩn và sai số chuẩn của chênh lệch so với mô hình tốt nhất.



Hình 5.3: M1: City theo HP, với HDI 95% của trung vị có điều kiện (xanh đậm) và khoảng dự đoán 95% (xanh nhạt).

- Với cùng HP và xuất xứ: mỗi 100 kg nặng hơn ứng với trung vị City thấp hơn 6,2%, HDI 95% từ $-7{,}1\%$ đến $-5{,}0\%$.

Các biểu đồ phân tán ở mục 2.6 cũng cho thấy điều này: City giảm theo cả HP, Weight và Engine Size theo dạng cong, và tương quan với Weight mạnh hơn với HP. City và Open Road có tương quan $0{,}94$, nên Open Road nhiều khả năng có xu hướng tương tự; tuy nhiên muốn có kết luận định lượng cho Open Road thì phải ước lượng mô hình riêng cho biến này.

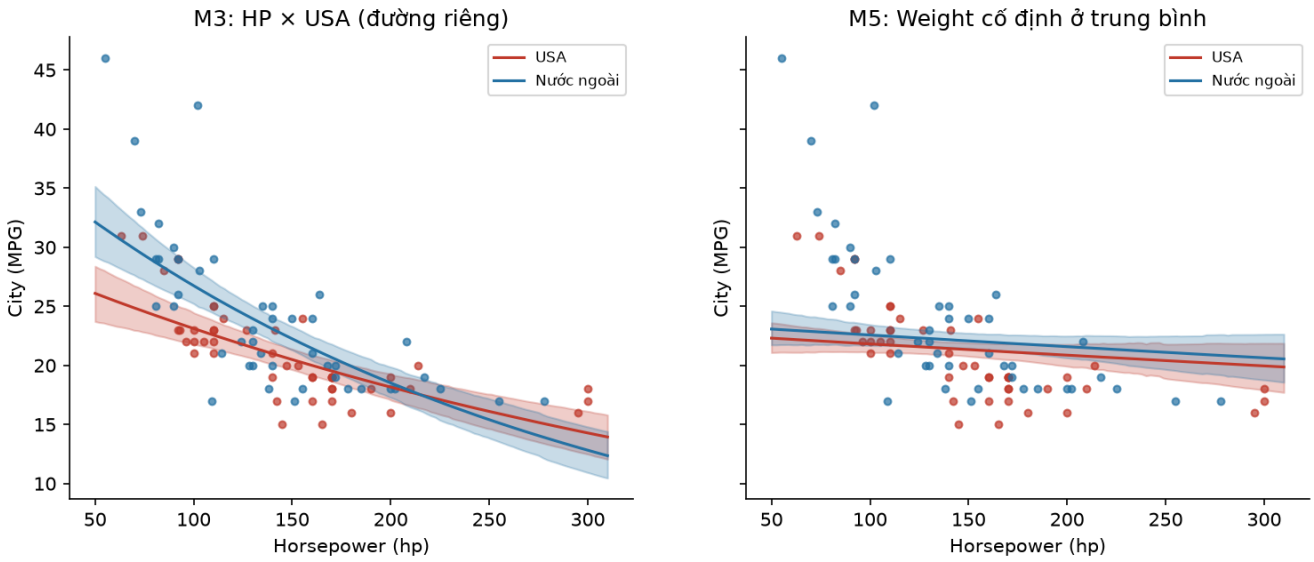
5.4 Trả lời Q2: xe Mỹ và xe nước ngoài

Xe Mỹ kém tiết kiệm hơn xe nước ngoài cùng công suất, nhưng khoảng cách này giảm nhiều khi thêm trọng lượng vào mô hình, vì xe Mỹ trong mẫu nặng hơn (bảng 5.2). Điều này cho thấy xuất xứ và trọng lượng gắn chặt với nhau trong dữ liệu, chứ chưa chứng minh trọng lượng là nguyên nhân. Khi chỉ xét cùng HP, xe Mỹ có City thấp hơn khoảng 8,6% và xác suất hậu nghiệm để xe Mỹ tiết kiệm hơn chỉ là $0{,}003$. Khi xét thêm cùng Weight, khoảng cách chỉ còn 3,3% và HDI 95% chạm 0.

Trong M3, hệ số tương tác HP $\times$ USA dương, bằng $0{,}29$ với HDI 95% $[0{,}03;\ 0{,}59]$ và xác suất dương $0{,}98$. Nghĩa là xe nước ngoài tiết kiệm hơn hẳn ở công suất thấp nhưng mất dần lợi thế khi HP tăng, và hai đường hồi quy gặp nhau quanh 200 hp (hình 5.4, trái). Theo mục 3.7, kết quả này thay đổi khi đổi tiên nghiệm, nên nhóm chỉ coi đây là gợi ý chứ chưa phải kết luận chắc chắn. Khi giữ Weight ở mức trung bình (hình 5.4, phải),

Bảng 5.2: Hệ số của USA trong ba mô hình; chênh lệch City đổi ra phần trăm.

Mô hình	β_{USA} [HDI 95%]	Chênh lệch City của xe Mỹ	$P(\beta_{\text{USA}} > 0 \mid y)$
M2: HP + USA	$-0{,}41$ $[-0{,}69; -0{,}13]$	$-8{,}7\%$	$0{,}003$
M3: có HP $\times$ USA	$-0{,}40$ $[-0{,}69; -0{,}14]$	$-8{,}6\%$	$0{,}003$
M5: có Weight	$-0{,}15$ $[-0{,}33; 0{,}02]$	$-3{,}3\%$	$0{,}043$



Hình 5.4: Đường hồi quy và HDI 95% cho xe Mỹ và xe nước ngoài: M3 với tương tác (trái) và M5 với Weight cố định ở mức trung bình (phải).

hai đường gần như trùng nhau.

5.5 Trả lời Q3: các điểm ngoại lai

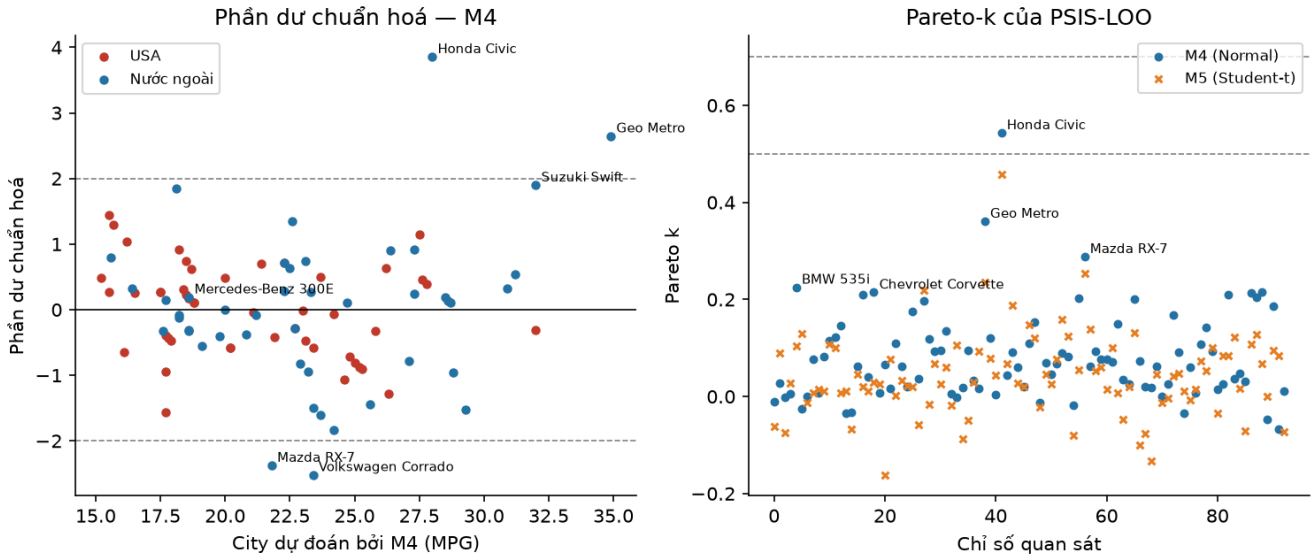
Nhóm xét phần dư chuẩn hoá và Pareto k từ M4 (bản hàm hợp lý chuẩn của mô hình cuối), rồi so với M5 (bảng 5.3, hình 5.5). Phần dư chuẩn hoá là hiệu giữa y_i và trung bình hậu nghiệm của μ_i, chia cho trung bình hậu nghiệm của σ. Pareto k cho biết một quan sát ảnh hưởng đến hậu nghiệm nhiều hay ít: k lớn nghĩa là nếu bỏ quan sát đó thì hậu nghiệm thay đổi nhiều.

Nhóm xe van có City từ 15 đến 18 MPG trông bất thường khi mô hình chỉ dùng HP, nhưng khi có Weight thì phần dư của chúng chỉ từ $-1{,}6$ đến $+0{,}3$. Vậy City thấp của các xe này là do chúng nặng chứ không phải do công suất. Ba xe cỡ nhỏ Honda Civic, Geo Metro và Suzuki Swift tiết kiệm hơn mức mà một đường log-tuyến tính dự đoán, còn Mazda RX-7 và Volkswagen Corrado tốn nhiên liệu hơn dự đoán. Giải thích về phiên bản động cơ của Honda Civic chỉ là giả thuyết của nhóm, vì dữ liệu không ghi phiên bản.

So với M4, M5 giảm trọng số của các điểm này: Pareto k lớn nhất giảm từ $0{,}54$ xuống $0{,}46$, và β_{HP} giảm độ lớn từ $-0{,}15$ xuống $-0{,}11$, HDI 95% giờ chứa 0. Hệ số của Weight giữ nguyên ở $-0{,}76$, nên liên hệ giữa trọng

Bảng 5.3: Các xe được xét là ngoại lai, theo M4.

Xe	City	Dự đoán	Phần dư	k	Giải thích
Honda Civic	42	28,0	3,86	0,54	Xe nhẹ (1 066 kg), có thể là phiên bản động cơ tiết kiệm nhiên liệu; ảnh hưởng lớn nhất
Geo Metro	46	34,9	2,65	0,36	Xe nhẹ nhất mẫu (769 kg), máy 1,0 L 55 hp, nằm ngoài vùng có nhiều dữ liệu
Suzuki Swift	39	32,0	1,90	0,21	Cùng loại xe cỡ nhỏ với Geo Metro, máy 1,3 L, 891 kg
Mazda RX-7	17	21,8	−2,37	0,29	Động cơ rotary 1,3 L nhưng 255 hp; thân nhẹ nên mô hình dự đoán cao hơn
Volkswagen Corrado	18	23,4	−2,52	0,19	Xe thể thao, máy 2,8 L 178 hp trên thân 1 275 kg
Ford Aerostar	15	17,7	−1,57	0,10	Xe van nặng; bất thường khi chỉ dùng HP, hết bất thường khi có Weight
Mercedes-Benz 300E	19	18,6	0,19	0,09	Ngoại lai về giá (Max Price 80, cao nhất), không phải về nhiên liệu



Hình 5.5: Phần dư chuẩn hoá theo giá trị dự đoán của M4 (trái) và Pareto k của từng quan sát với M4 và M5 (phải).

lượng và City không phụ thuộc vào các điểm ngoại lai.

Tham số σ của M5 bằng $0{,}38$, nhỏ hơn $0{,}47$ của M4, nhưng hai số này không so trực tiếp được. Với Student-t, σ là tham số thang đo; độ lệch chuẩn của sai số bằng $\sigma\sqrt{\nu/(\nu-2)}$ khi $\nu > 2$ và vô hạn khi $\nu \leq 2$ (chỉ $0{,}3\%$ mẫu hậu nghiệm có $\nu \leq 2$). Khi đổi về cùng thước đo, độ lệch chuẩn sai số của M5 có trung vị hậu nghiệm khoảng $0{,}45$, gần bằng M4. Vậy M5 không làm sai số nhỏ đi; khác biệt là phần lớn xe nằm sát đường hồi quy hơn, còn vài xe ngoại lai rơi vào phần đuôi dày của Student-t.

Bảng 5.4: Dự đoán City cho một xe 300 hp, 1 681 kg nếu mô hình có Weight.

Mô hình	Xuất xứ	Trung vị City [HDI 95%]	Khoảng dự đoán 95%
M1: chỉ HP	bất kỳ	13,6 [12,2; 15,0]	9,7–18,8
M3	Mỹ	14,3 [12,5; 16,1]	10,3–19,6
M3	nước ngoài	12,9 [10,9; 14,8]	9,2–17,9
M5	Mỹ	16,6 [15,4; 18,0]	13,4–20,6
M5	nước ngoài	17,2 [15,9; 18,5]	13,8–21,3

Bảng 5.5: Dự đoán của M5 cho ba xe thật có từ 295 hp trở lên.

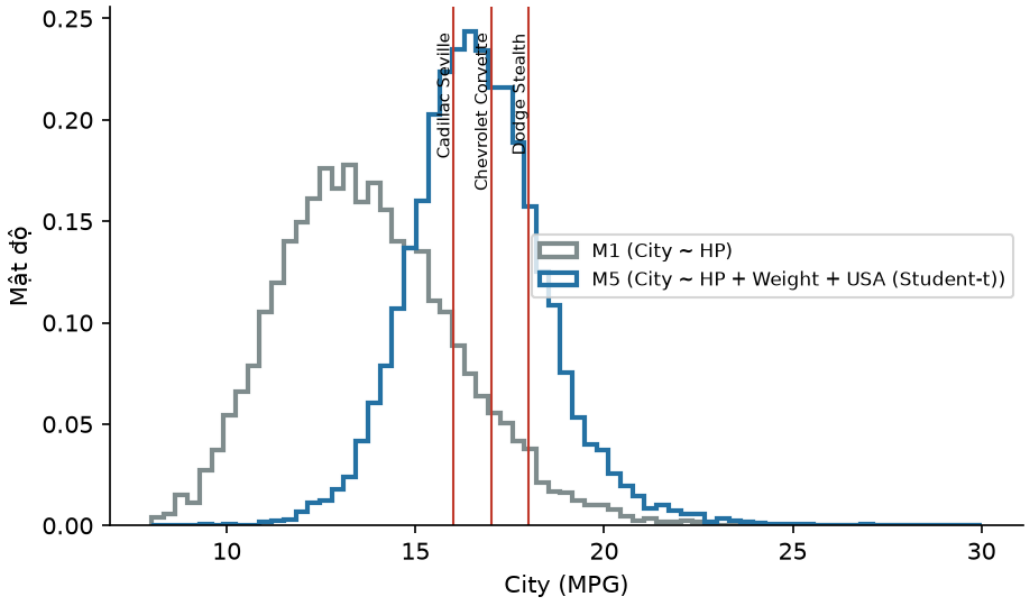
Xe	HP	Weight (kg)	City thật	Trung vị dự đoán	Khoảng dự đoán 95%
Cadillac Seville	295	1 785	16	15,6	12,6–19,2
Chevrolet Corvette	300	1 533	17	18,3	14,6–22,7
Dodge Stealth	300	1 726	18	16,1	13,0–20,0

5.6 Trả lời Q4: dự đoán cho xe 300 hp

Biến phản hồi là City và biến giải thích chính là Horsepower. Nếu chỉ biết công suất thì M1 là mô hình đúng với câu hỏi của đề: trung vị City của một xe 300 hp khoảng 13,6 MPG, khoảng dự đoán 95% từ 9,7 đến 18,8 MPG. M5 cần biết thêm xuất xứ và trọng lượng, nên kết quả của M5 chỉ áp dụng cho một xe cụ thể. Với xe Mỹ 300 hp nặng 1 681 kg (trọng lượng trung bình của ba xe thật có từ 295 hp trở lên), trung vị City khoảng 16,6 MPG, khoảng dự đoán 95% từ 13,4 đến 20,6 MPG (bảng 5.4). Một xe 300 hp nặng hơn hay nhẹ hơn sẽ có dự đoán khác.

Vì mô hình đặt trên $\log(\text{City})$, $\exp(\mu)$ là trung vị có điều kiện của City chứ không phải trung bình; cột thứ ba của bảng là trung bình hậu nghiệm của trung vị này. Với M5, trung bình của City khi $\log(\text{City})$ có phân phối Student-t thậm chí là vô hạn, nên nhóm chỉ báo cáo trung vị và khoảng dự đoán. Khoảng dự đoán khác HDI của trung vị ở chỗ nó tính cả sai số của từng xe, nên rộng hơn nhiều.

Ba xe thật gần 300 hp trong mẫu đều là xe Mỹ. Khi dùng thông số riêng của từng xe, khoảng dự đoán của M5 đều chứa giá trị thật (bảng 5.5). Tuy nhiên ba xe này nằm trong dữ liệu dùng để ước lượng mô hình, nên đây chỉ là kiểm tra trên mẫu học, chưa phải kiểm tra khả năng dự đoán cho xe mới. M1 dự đoán thấp hơn thực tế (13,6 MPG), vì đường log-tuyến tính theo HP tiếp tục đi xuống ở phía phải, trong khi xe 300 hp thực tế không nặng hơn xe 200 hp bao nhiêu (hình 5.6). Vì 300 hp là giá trị lớn nhất trong mẫu, mọi dự đoán ở đây đều nằm ở rìa dữ liệu.



Hình 5.6: Phân phối dự đoán hậu nghiệm cho một xe Mỹ 300 hp theo M1 và M5; đường đỏ là City của ba xe thật gần 300 hp.

5.7 Hạn chế

Mẫu chỉ có 93 xe và chỉ có ba xe trên 280 hp, nên dự đoán ở rìa dữ liệu kém chắc chắn. Dữ liệu từ năm 1993, công nghệ động cơ khi đó khác xa hiện nay, nên kết quả không áp dụng cho xe ngày nay. Các quan hệ tìm được là tương quan chứ không phải nhân quả, và dự đoán ngoài khoảng 55–300 hp hoặc 769–1 862 kg không đáng tin. Phần kiểm tra dự đoán ở Q4 chỉ dùng các xe đã có trong dữ liệu học; nhóm chưa đánh giá khả năng dự đoán trên xe ngoài mẫu.

VI. Kết luận

Trong mẫu 93 xe năm 1993, trọng lượng là biến liên hệ mạnh nhất với hiệu suất nhiên liệu trong thành phố. Đây là kết luận về liên hệ trên dữ liệu quan sát, không phải về quan hệ nhân quả. Mô hình cuối M5, $\log(\text{City}) \sim \text{HP} + \text{Weight} + \text{USA}$ với hàm hợp lý Student-t, hội tụ tốt, tái tạo dữ liệu tốt nhất và đứng đầu theo cả PSIS-LOO lẫn WAIC.

Q1, quan hệ giữa các biến. Nếu chỉ xét HP, mỗi 10 hp cao hơn ứng với trung vị City thấp hơn 3,0%. Với cùng Weight, mức này gần như bằng 0, chỉ còn $-0{,}45\%$, trong khi mỗi 100 kg nặng hơn ứng với trung vị City thấp hơn 6,2%. Open Road tương quan $0{,}94$ với City nên nhiều khả năng có xu hướng tương tự, nhưng nhóm chưa xây dựng mô hình riêng cho biến này.

Q2, xe Mỹ và xe nước ngoài. Cùng công suất, xe Mỹ kém tiết kiệm hơn 8,6%, xác suất điều ngược lại chỉ là $0{,}003$. Khi tính cả Weight, khoảng cách chỉ còn 3,3% và HDI 95% chạm 0. Vậy phần lớn chênh lệch giữa hai nhóm đi kèm với chênh lệch trọng lượng, dù dữ liệu quan sát không cho phép khẳng định trọng lượng là nguyên nhân.

Q3, điểm ngoại lai. Honda Civic, Geo Metro và Suzuki Swift tiết kiệm bất thường, còn Mazda RX-7 (động cơ rotary) và Volkswagen Corrado tốn nhiên liệu hơn dự đoán. Xe van chỉ là ngoại lai khi bỏ qua trọng lượng. Các kết luận chính không đổi khi chuyển sang hàm hợp lý Student-t.

Q4, xe 300 hp. Nếu chỉ biết công suất (M1), trung vị City của một xe 300 hp khoảng $13{,}6$ MPG, khoảng dự đoán 95% từ $9{,}7$ đến $18{,}8$ MPG. Nếu biết thêm đó là xe Mỹ nặng $1\,681$ kg (M5), trung vị City khoảng $16{,}6$ MPG, khoảng dự đoán 95% từ $13{,}4$ đến $20{,}6$ MPG. Ba xe thật gần 300 hp đều nằm trong khoảng của M5, nhưng chúng thuộc dữ liệu học nên đây chỉ là kiểm tra trên mẫu học.

Hướng phát triển. Có thể dùng mô hình phân cấp theo Type, trong đó mỗi loại xe có hệ số chặn riêng và các loại xe dùng chung thông tin với nhau, để tách phần chênh lệch do loại xe. Cũng có thể thêm các biến như Engine Size, Drive train hoặc Manual, hoặc thử biến phản hồi gallon trên dặm $1/\text{City}$, vì trong phân tích sơ bộ biến này còn khớp tốt hơn.

A. Code và dữ liệu

Toàn bộ phân tích nằm trong notebook chung `bayes_cars_1993.ipynb`, ghép từ năm module trong thư mục `analysis/`. Notebook chạy từ đầu đến cuối trong khoảng 8 phút với Python 3.12, PyMC 5.28 và ArviZ 0.23, seed 2026. Phân công như ở bảng A.1.

Dữ liệu đã làm sạch nằm ở `outputs/data_clean.csv`, bảng hậu nghiệm đầy đủ của mọi mô hình ở `outputs/tables/tab_4_4_posterior.csv`, và các hình ở `outputs/figures/`. Dưới đây là hàm khai báo chung cho năm mô hình trong PyMC.

```
def build_model(d, sc, terms, prior="weak", likelihood="normal"):
    X = design(d, sc, terms)          # standardised HP, Weight; USA as 0/1
    y = sc.y(d["city"])               # standardised log(City)
    coords = {"term": terms, "obs": d["name"].to_numpy()}
    with pm.Model(coords=coords) as model:
        Xd = pm.Data("X", X, dims=("obs", "term"))
        b0 = pm.Normal("b0", 0, PRIOR_SD[prior])
        b = pm.Normal("b", 0, PRIOR_SD[prior], dims="term")
        sigma = pm.HalfNormal("sigma", 1)
        mu = pm.Deterministic("mu", b0 + pm.math.dot(Xd, b), dims="obs")
        if likelihood == "student":
            nu = pm.Gamma("nu", 2, 0.1)
            pm.StudentT("y", nu=nu, mu=mu, sigma=sigma, observed=y, dims="obs")
        else:
            pm.Normal("y", mu=mu, sigma=sigma, observed=y, dims="obs")
    return model
```

Bảng A.1: Các module trong notebook chung.

Module	Phụ trách	Mục trong báo cáo
`02_data_eda.py`	TV2	Chương II, mục 3.3
`03_models.py`	TV3	Mục 3.4–3.7
`04_sampling.py`	TV4	Mục 4.2–4.4
`01_conjugate.py`	TV1	Mục 4.1
`05_evaluation.py`	TV5	Chương V

B. Khai báo sử dụng AI

Nhóm có dùng trợ lý AI **Claude** của Anthropic trong quá trình làm bài, cụ thể:

- hỗ trợ viết, chú thích và sửa lỗi code Python (PyMC, ArviZ) trong thư mục `analysis/`;
- hỗ trợ soạn, sửa văn bản và trình bày LaTeX của báo cáo;
- rà soát cách diễn giải thống kê, ví dụ phân biệt trung vị với trung bình trên thang log, ý nghĩa tham số thang đo của Student-t và tránh diễn giải nhân quả.

Mọi con số trong báo cáo đều lấy từ kết quả chạy code của nhóm (`outputs/`), không lấy từ câu trả lời của AI. Nhóm đã đối chiếu các nhận định với kết quả tính toán và tài liệu tham khảo, và chịu trách nhiệm về toàn bộ nội dung bài.

Tài liệu tham khảo

[1] Andrew Gelman et al. *Bayesian Data Analysis*. 3rd ed. CRC Press, 2013.

[2] Richard McElreath. *Statistical Rethinking: A Bayesian Course with Examples in R and Stan*. 2nd ed. CRC Press, 2020.

[3] Consumer Reports. *The 1993 Cars – Annual Auto Issue*. 1993.

[4] PACE Publications. *PACE New Car & Truck 1993 Buying Guide*. 1993.

[5] Robin H. Lock. "1993 New Car Data". In: *Journal of Statistics Education* 1.1 (1993).

[6] W. N. Venables and B. D. Ripley. *Cars93: Data from 93 Cars on Sale in the USA in 1993 (R package MASS)*. Tài liệu bộ dữ liệu trong gói MASS, đi kèm sách Modern Applied Statistics with S. 2002. URL: https://stat.ethz.ch/R-manual/R-devel/library/MASS/html/Cars93.html.

[7] Matthew D. Hoffman and Andrew Gelman. "The No-U-Turn Sampler: Adaptively Setting Path Lengths in Hamiltonian Monte Carlo". In: *Journal of Machine Learning Research* 15 (2014), pp. 1593–1623.

[8] Oriol Abril-Pla et al. "PyMC: A Modern and Comprehensive Probabilistic Programming Framework in Python". In: *PeerJ Computer Science* 9 (2023), e1516.

[9] Aki Vehtari et al. "Rank-Normalization, Folding, and Localization: An Improved $\widehat{R}$ for Assessing Convergence of MCMC". In: *Bayesian Analysis* 16.2 (2021), pp. 667–718.

[10] Aki Vehtari, Andrew Gelman, and Jonah Gabry. "Practical Bayesian Model Evaluation Using Leave-One-Out Cross-Validation and WAIC". In: *Statistics and Computing* 27 (2017), pp. 1413–1432.

[11] Ravin Kumar et al. "ArviZ: A Unified Library for Exploratory Analysis of Bayesian Models in Python". In: *Journal of Open Source Software* 4.33 (2019), p. 1143.