ĐẠI HỌC QUỐC GIA HÀ NỘI

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA TOÁN - CƠ - TIN HỌC



BÁO CÁO CUỐI KỲ

MÔ HÌNH HỒI QUY TUYẾN TÍNH BAYES VÀ ỨNG DỤNG

ĐỀ TÀI:

HỒI QUY TUYẾN TÍNH BAYES CHO HIỆU SUẤT NHIÊN LIỆU CỦA XE MỚI TẠI MỸ NĂM 1993

Nhóm 10 thực hiện:	Nguyễn Thục Anh	25007949
	Bùi Quang Huy	25007877
	Nguyễn Thị Bích Ngọc	25007937
	Nguyễn Thu Ngân	25007865
	Nguyễn Hồng Phúc	25007860

Hà Nội, tháng 10 năm 2026

Tóm tắt

Báo cáo sử dụng hồi quy tuyến tính Bayes để khảo sát mối liên hệ giữa công suất, trọng lượng, xuất xứ và khả năng tiết kiệm nhiên liệu của 93 mẫu xe mới bán tại Mỹ năm 1993. Biến phản hồi là City, đo số dặm xe đi được với một gallon nhiên liệu khi chạy trong thành phố (MPG); giá trị càng lớn thì xe càng tiết kiệm. Nhóm xây dựng năm mô hình để xem kết quả thay đổi như thế nào khi bổ sung biến giải thích và thay đổi giả định về sai số. Các mô hình được ước lượng bằng phương pháp lấy mẫu, kiểm tra hội tụ và so sánh khả năng dự đoán.

Trong các biến được xét, trọng lượng có mối liên hệ rõ nhất với City. Khi so sánh các xe có cùng công suất và xuất xứ, trọng lượng tăng 100 kg ứng với trung vị City giảm khoảng 6,2%. Khi đã xét đến trọng lượng, mối liên hệ giữa công suất và City yếu đi rõ rệt, đồng thời chênh lệch giữa xe Mỹ và xe nước ngoài cũng thu hẹp. Nhóm chọn mô hình sai số Student-t để hạn chế ảnh hưởng của các quan sát có độ lệch lớn so với dự đoán. Với một xe Mỹ có công suất 300 hp, nặng 1 681 kg, ước lượng trung vị City là 16,6 MPG và khoảng dự đoán 95% là 13,4–20,6 MPG. Khi dự đoán theo thông số riêng của ba xe gần 300 hp trong mẫu, các khoảng dự đoán đều chứa giá trị quan sát; đây là kiểm tra trên dữ liệu đã dùng để ước lượng mô hình.

Mục lục

Tóm tắt **1**

I Giới thiệu **5**

1.1 Bối cảnh 5

1.2 Mục tiêu và câu hỏi nghiên cứu 5

1.3 Vì sao chọn cách tiếp cận Bayes 5

II Dữ liệu sử dụng **7**

2.1 Nguồn và cách lấy mẫu 7

2.2 Danh sách biến 7

2.3 Làm sạch dữ liệu 7

2.4 Đơn vị nhiên liệu 7

2.5 Thống kê mô tả 8

2.6 Phân tích khám phá 9

III Quá trình mô hình hoá **11**

3.1 Cơ sở lý thuyết hồi quy tuyến tính 11
3.2 Chọn biến 11
3.3 Biến đổi biến 12
3.4 Năm mô hình ứng viên 13
3.5 Đặc tả đầy đủ cho M3 13
3.6 Chọn tiên nghiệm và kiểm tra dự đoán tiên nghiệm 14
3.7 Ảnh hưởng của tiên nghiệm đến kết quả 15

IV Quá trình ước lượng Bayes **16**

4.1 Công thức hậu nghiệm cho M1 16
4.2 Lấy mẫu MCMC 16
4.3 Chẩn đoán hội tụ 17
4.4 Bảng tóm tắt hậu nghiệm 18

V Đánh giá kết quả và trả lời câu hỏi **21**

5.1 Kiểm tra dự đoán hậu nghiệm 21
5.2 So sánh mô hình 21
5.3 Trả lời Q1: quan hệ giữa các biến 23
5.4 Trả lời Q2: xe Mỹ và xe nước ngoài 23
5.5 Trả lời Q3: các điểm ngoại lai 24
5.6 Trả lời Q4: dự đoán cho xe 300 hp 26
5.7 Hạn chế 27

VI Kết luận **29**

A Mã nguồn và dữ liệu **31**

B Khai báo sử dụng AI **33**

Tài liệu tham khảo **34**

Danh sách hình vẽ

2.1 Ma trận biểu đồ phân tán các biến chính, tô màu theo xuất xứ. 9
2.2 City theo loại xe; điểm tô màu theo xuất xứ. 10

3.1 Phần dư OLS theo giá trị khớp, với City và log(City) làm biến phản hồi; đường cam là đường làm trơn LOWESS. 12
3.2 Phân phối City mô phỏng từ tiên nghiệm của M3 với ba tiên nghiệm, so với dữ liệu thật; trục hoành theo thang logarit, đường đứt đỏ ở 80 MPG. 14
3.3 Hậu nghiệm của M3 với ba tiên nghiệm, trung bình và HDI 95%. 15

4.1 Hậu nghiệm của M1: mật độ t tính bằng công thức (đen), NUTS với cùng tiên nghiệm NIG (xanh) và NUTS với tiên nghiệm của M1 (đỏ). 17
4.2 Biểu đồ vết của Metropolis–Hastings tự viết cho M1, bốn chuỗi. 18
4.3 Biểu đồ vết của M5: mật độ hậu nghiệm theo chuỗi (trái) và giá trị qua các vòng lặp (phải). . . 19
4.4 Hệ số hậu nghiệm của M1–M5 trên thang chuẩn hoá, trung bình và HDI 95%. 20

5.1 Kiểm tra dự đoán hậu nghiệm: mật độ dữ liệu thật (đen) và 100 bộ dữ liệu sinh từ hậu nghiệm (xanh). 22
5.2 ELPD-LOO của năm mô hình, kèm sai số chuẩn và sai số chuẩn của chênh lệch so với mô hình tốt nhất. 22
5.3 M1: City theo HP, với HDI 95% của trung vị có điều kiện (xanh đậm) và khoảng dự đoán 95% (xanh nhạt). 24
5.4 Đường hồi quy và HDI 95% cho xe Mỹ và xe nước ngoài: M3 với tương tác (trái) và M5 với Weight cố định ở mức trung bình (phải). 25
5.5 Phần dư chuẩn hoá theo giá trị dự đoán của M4 (trái) và Pareto k của từng quan sát với M4 và M5 (phải). 26
5.6 Phân phối dự đoán hậu nghiệm cho một xe Mỹ 300 hp theo M1 và M5; đường đỏ là City của ba xe thật gần 300 hp. 28

Danh sách bảng

1.1 Bốn câu hỏi của đề và cách trả lời bằng hồi quy Bayes. 6

2.1 Các nhóm biến trong bộ dữ liệu gốc. 8
2.2 Thống kê mô tả các biến chính, $n = 93$. 8

3.1 Hệ số phóng đại phương sai của hai bộ biến giải thích. 12
3.2 So sánh hai thang của biến phản hồi trong hồi quy OLS theo HP; logarit hàm hợp lý và AIC tính trên thang City. 12
3.3 Năm mô hình ứng viên; biến phản hồi luôn là $\log(\text{City})$ đã chuẩn hoá. 13
3.4 Kiểm tra dự đoán tiên nghiệm cho M3 với ba tiên nghiệm, mỗi tiên nghiệm $1\,000$ lần mô phỏng. 14

4.1 Hậu nghiệm của β_{HP} trong M1, thang chuẩn hoá: công thức so với MCMC. 17
4.2 Chẩn đoán hội tụ của năm mô hình; giá trị xấu nhất trên mọi tham số. 18
4.3 Trung bình hậu nghiệm và HDI 95% của các hệ số, thang chuẩn hoá. Cột σ là độ lệch chuẩn sai số với M1–M4 và tham số thang đo Student-t với M5. 19

5.1 So sánh mô hình bằng PSIS-LOO và WAIC; chênh lệch tính so với M5. 22
5.2 Hệ số USA và chênh lệch trung vị City của xe Mỹ so với xe nước ngoài. Riêng M3, chênh lệch được tính tại công suất trung bình của mẫu. 24
5.3 Các xe cần xem xét khi phân tích ngoại lai; dự đoán và phần dư chuẩn hoá được tính theo M4. 25
5.4 Dự đoán City cho xe 300 hp. Riêng M5, trọng lượng được đặt ở $1\,681$ kg; cột ước lượng trung vị là trung bình hậu nghiệm của m. 27
5.5 Dự đoán của M5 cho ba xe thật có từ 295 hp trở lên. 27

A.1 Các module trong notebook chung. 32

I. Giới thiệu

1.1 Bối cảnh

Khả năng tiết kiệm nhiên liệu là một đặc điểm cần quan tâm khi so sánh các mẫu xe. Xe có công suất lớn thường tiêu thụ nhiều nhiên liệu hơn, nhưng các xe này cũng có thể khác nhau về trọng lượng, dung tích động cơ và loại xe. Vì vậy, cần xem xét đồng thời nhiều đặc điểm để hiểu rõ mối liên hệ giữa công suất và khả năng tiết kiệm nhiên liệu. Bộ dữ liệu gồm 93 mẫu xe mới bán tại Mỹ năm 1993 cho phép khảo sát vấn đề này và so sánh kết quả giữa xe Mỹ với xe nước ngoài.

1.2 Mục tiêu và câu hỏi nghiên cứu

Mục tiêu của báo cáo là mô tả mối liên hệ giữa các đặc điểm của xe và chỉ số MPG trong thành phố, đồng thời dự đoán chỉ số này cho một xe có công suất 300 hp. Nhóm chọn City làm biến phản hồi và công suất (Horsepower, viết tắt HP) làm biến giải thích chính. Trọng lượng (Weight) và xuất xứ (USA) được xét thêm để đánh giá liệu mối liên hệ ban đầu có thay đổi hay không. Các chương từ chương II đến chương V tương ứng với bốn yêu cầu (i)–(iv) của đề. Bốn câu hỏi trong tài liệu đính kèm và cách nhóm trả lời được tóm tắt ở bảng 1.1.

1.3 Vì sao chọn cách tiếp cận Bayes

Trong cách tiếp cận Bayes, thông tin ban đầu về tham số được biểu diễn bằng phân phối tiên nghiệm. Sau khi kết hợp với dữ liệu qua định lý Bayes, ta thu được phân phối hậu nghiệm, mô tả những giá trị tham số còn phù hợp với dữ liệu và mức độ bất định của chúng. Nhờ đó, nhóm có thể tính xác suất hậu nghiệm để hệ số chênh lệch giữa xe Mỹ và xe nước ngoài mang dấu âm hoặc dấu dương. Báo cáo dùng trung bình hậu nghiệm để tóm tắt tham số và khoảng mật độ hậu nghiệm cao nhất 95% (HDI 95%) để mô tả sự bất định. Khoảng này chứa 95% xác suất hậu nghiệm và nằm ở vùng có mật độ cao nhất.

Mô hình trên thang logarit bảo đảm City dự đoán luôn dương. Việc chọn tiên nghiệm giúp hạn chế các giá trị quá lớn hoặc quá nhỏ so với phạm vi hợp lý; ảnh hưởng của lựa chọn này được kiểm tra ở chương III. Ngoài ra, phân phối dự đoán hậu nghiệm tính đến cả sự bất định của tham số và sự khác biệt giữa các xe có cùng đặc điểm. Điều này cần thiết khi dự đoán cho xe 300 hp, vì đây là mức công suất lớn nhất trong mẫu. Phần lý thuyết chủ yếu tham khảo [1, 2].

Bảng 1.1: Bốn câu hỏi của đề và cách trả lời bằng hồi quy Bayes.

#	Câu hỏi của đề	Cách trả lời	Mục
Q1	Quan hệ giữa các biến, so sánh các biểu đồ phân tán	Ma trận biểu đồ phân tán, hệ số hậu nghiệm và HDI 95%	2.6, 5.3
Q2	Khác biệt giữa xe Mỹ và xe nước ngoài	Biến giả USA, tương tác HP $\times$ USA, xác suất $P(\beta_{\text{USA}} > 0 \mid y)$	3.4, 5.4
Q3	Các điểm ngoại lai và lời giải thích	Kiểm tra dự đoán hậu nghiệm, phần dư chuẩn hoá, Pareto k của PSIS-LOO, hàm hợp lý Student-t	5.5
Q4	Chọn biến giải thích và phản hồi; dự đoán xe 300 hp	Phân phối dự đoán hậu nghiệm tại HP $= 300$, so với ba xe thật gần 300 hp	5.6

II. Dữ liệu sử dụng

2.1 Nguồn và cách lấy mẫu

Bộ dữ liệu gồm 93 mẫu xe mới bán tại Mỹ năm 1993, mỗi dòng ứng với một mẫu xe. Các xe được chọn ngẫu nhiên từ *The 1993 Cars – Annual Auto Issue* của Consumer Reports [3] và *PACE New Car & Truck 1993 Buying Guide* [4].

2.2 Danh sách biến

Tệp dữ liệu có 25 cột, gồm tên xe, 20 biến định lượng và 4 biến mã hoá (bảng 2.1). Bốn biến được dùng trong mô hình được in đậm.

2.3 Làm sạch dữ liệu

Các ô đánh dấu $*$ trong tệp gốc được chuyển thành giá trị thiếu. Biến Luggage capacity thiếu 11 dòng (9 xe van, Chevrolet Corvette và Mazda RX-7), Rear seat room thiếu 2 dòng (Corvette và RX-7), còn Cylinders thiếu 1 dòng ở RX-7 do xe này dùng động cơ rotary, không có xi-lanh theo nghĩa thông thường. Hai cột RPM được lưu dưới dạng chuỗi có dấu phẩy phân cách hàng nghìn (ví dụ "6,300") nên cần chuyển sang dạng số. Do bốn biến dùng trong mô hình (City, Horsepower, Weight và USA) không thiếu giá trị nào, toàn bộ 93 dòng được giữ lại và lưu vào `data_clean.csv`.

2.4 Đơn vị nhiên liệu

Tiêu đề cột ghi đơn vị "km/100L", còn tài liệu đi kèm lại ghi "litres per 100km", hai cách ghi mang ý nghĩa ngược nhau. Tuy nhiên, cả hai đều không khớp với dữ liệu. Các giá trị chỉ dao động từ 15 đến 46, và Geo Metro, xe nhỏ nhẹ nhất mẫu (55 hp, 769 kg), lại có giá trị cao nhất. Để xác định đúng đơn vị, nhóm đối chiếu từng dòng với bộ dữ liệu `Cars93` trong gói R `MASS` [5, 6], vốn có cùng 93 mẫu xe theo đúng thứ tự. Kết quả đối chiếu như sau.

- City khớp hoàn toàn với `MPG.city` ở cả 93 dòng, Open Road khớp với `MPG.highway`. Theo tài liệu của

Bảng 2.1: Các nhóm biến trong bộ dữ liệu gốc.

Nhóm	Biến
Giá (nghìn USD)	Min Price, Mid Price, Max Price
Nhiên liệu (MPG)	**City**, Open Road
Động cơ	**Horsepower** (hp), Engine Size (L), Cylinders, RPM tại công suất cực đại, RPM khi chạy đều, Fuel Tank (L)
Kích thước	**Weight** (kg), Length, Wheelbase, Width (cm), U-turn (m), Rear seat (cm), Luggage (m^3), Passengers
Mã hoá	Type 1–6 (Small, Midsize, Large, Compact, Sporty, Van); Airbag 0–2; Drive train 0–2; Manual 0/1; **USA** 0/1 (1 là xe Mỹ)

Bảng 2.2: Thống kê mô tả các biến chính, $n = 93$.

Biến	Trung bình	Độ lệch chuẩn	Nhỏ nhất	Trung vị	Lớn nhất
City (MPG)	22,4	5,6	15	21	46
Open Road (MPG)	29,1	5,3	20	28	50
Horsepower (hp)	143,8	52,4	55	140	300
Weight (kg)	1 394	268	769	1 379	1 862
Engine Size (L)	2,7	1,0	1,0	2,4	5,7
Mid Price (nghìn USD)	19,5	9,7	7,4	17,7	61,9

`MASS`, hai biến này có đơn vị dặm trên gallon Mỹ theo xếp hạng của EPA.

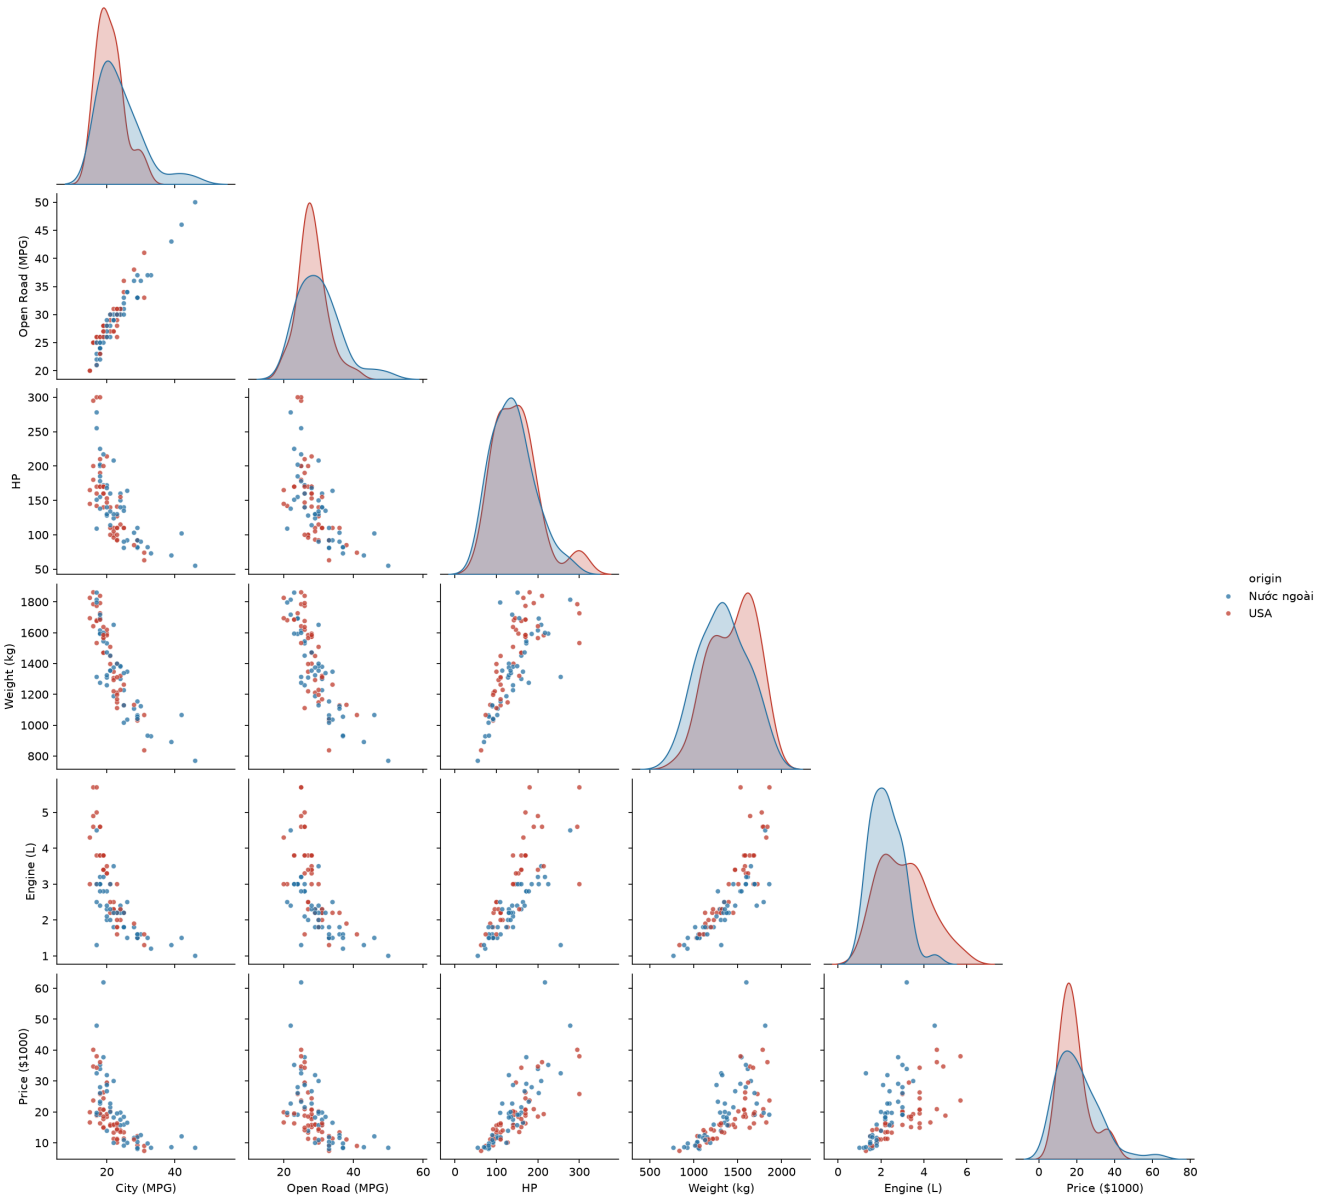
- Horsepower cũng khớp ở cả 93 dòng, còn Weight bằng `Weight` (pound) nhân với $0{,}4536$, sai lệch không quá $0{,}5$ kg do làm tròn. Chẳng hạn, Acura Integra có City 25, Open Road 31, 140 hp và 1 227 kg, so với 25, 31, 140 hp và 2705 lb trong `Cars93`.

Như vậy, bộ Q_10 thực chất là `Cars93` với một số cột đã đổi sang hệ mét, riêng hai cột nhiên liệu vẫn giữ nguyên giá trị nhưng bị ghi sai đơn vị. Từ đây trở đi, báo cáo dùng đơn vị MPG (dặm trên gallon, giá trị càng cao thì xe càng tiết kiệm). Có thể quy đổi sang lít trên 100 km theo công thức $\text{L/100km} = 235{,}2/\text{MPG}$.

2.5 Thống kê mô tả

Mẫu gồm 48 xe Mỹ và 45 xe nước ngoài. Công suất dao động từ 55 đến 300 hp (trung vị 140), City từ 15 đến 46 MPG (trung vị 21), chi tiết ở bảng 2.2. HP và City có hệ số tương quan $-0{,}67$, còn City và Open Road tương quan tới $0{,}94$.

So với xe nước ngoài, xe Mỹ trung bình nặng hơn (1 449 kg so với 1 335 kg), dung tích động cơ lớn hơn (3,1 L so với 2,2 L) và kém tiết kiệm nhiên liệu hơn (City 21,0 so với 23,9 MPG), dù công suất trung bình của hai nhóm khá gần nhau (147,5 so với 139,9 hp). Điều này gợi ý cần xét thêm trọng lượng khi so sánh khả năng tiết kiệm nhiên liệu giữa hai nhóm. Kết quả so sánh sau khi bổ sung trọng lượng được trình bày ở mục 5.4.



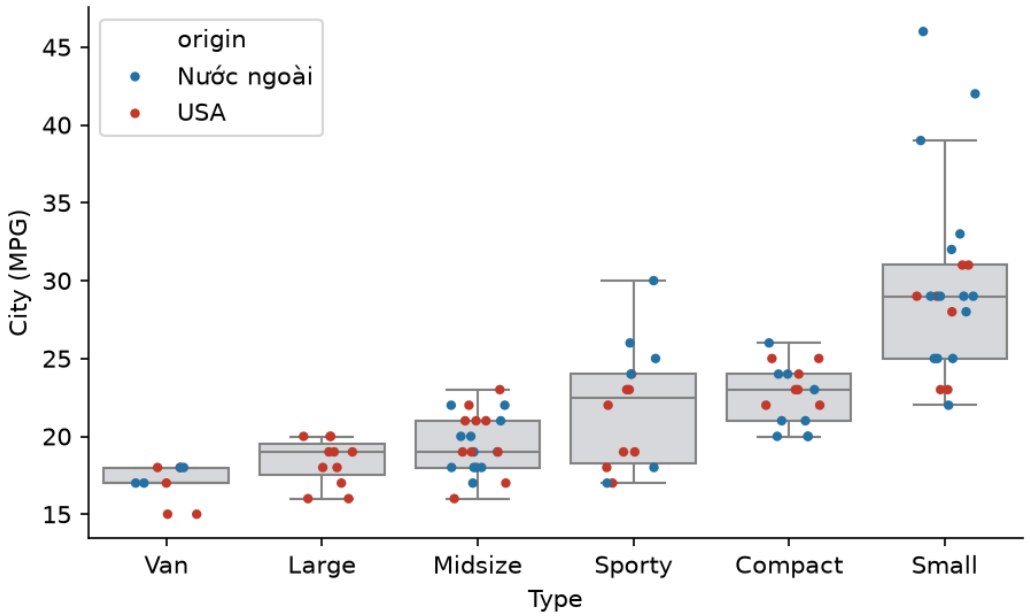
Hình 2.1: Ma trận biểu đồ phân tán các biến chính, tô màu theo xuất xứ.

2.6 Phân tích khám phá

Ma trận biểu đồ phân tán (hình 2.1) cho thấy các xe có công suất, trọng lượng hoặc dung tích động cơ lớn hơn thường có City thấp hơn. Các mối liên hệ này có dạng cong: City giảm nhanh ở nhóm xe nhỏ và giảm chậm hơn ở nhóm xe lớn. Xe nước ngoài tập trung nhiều ở nhóm xe nhẹ, động cơ nhỏ và City cao, trong khi xe Mỹ thường nặng hơn và có động cơ lớn hơn.

City và Open Road, chỉ số MPG khi chạy ngoài đô thị, có mối liên hệ gần tuyến tính. Trong phạm vi báo cáo, nhóm tập trung xây dựng mô hình cho City theo câu hỏi dự đoán của đề; kết quả định lượng cho Open Road cần được đánh giá bằng một mô hình riêng.

Xét theo loại xe (hình 2.2), nhóm xe cỡ nhỏ (Small) có City cao nhất, còn nhóm xe van (Van) và xe cỡ lớn



Hình 2.2: City theo loại xe; điểm tô màu theo xuất xứ.

(Large) có City thấp nhất. Để bước đầu xác định những xe có giá trị khác xa dự đoán, nhóm dùng phương pháp bình phương tối thiểu (OLS) để hồi quy $\log(\text{City})$ theo công suất. Có năm xe có phần dư đã chia cho độ lệch chuẩn ước lượng tương ứng (studentised) vượt ngưỡng ± 2, gồm Honda Civic $(+3{,}6)$, Geo Metro $(+3{,}2)$, Suzuki Swift $(+2{,}4)$, Ford Aerostar $(-2{,}4)$ và Volkswagen Eurovan $(-2{,}3)$. Các xe này sẽ được xem xét lại với mô hình đầy đủ ở mục 5.5.

III. Quá trình mô hình hoá

3.1 Cơ sở lý thuyết hồi quy tuyến tính

Hồi quy tuyến tính mô tả biến phản hồi như một hàm tuyến tính của các biến giải thích cộng với một sai số ngẫu nhiên:

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i, \qquad \varepsilon_i \sim \mathcal{N}(0, \sigma^2). \tag{3.1}$$

Mô hình dựa trên các giả định: quan hệ tuyến tính (có thể sau khi biến đổi biến), các sai số độc lập, có phương sai không đổi và tuân theo phân phối chuẩn. Biến giả USA nhận giá trị 1 với xe Mỹ và 0 với xe nước ngoài, do đó hệ số của nó chính là chênh lệch hệ số chặn giữa hai nhóm. Số hạng tương tác HP $\times$ USA cho phép độ dốc theo HP khác nhau giữa hai nhóm. Khi các biến giải thích tương quan mạnh với nhau, ước lượng hệ số trở nên kém ổn định và khó diễn giải riêng lẻ. Hiện tượng này gọi là đa cộng tuyến và thường được đo bằng hệ số phóng đại phương sai (VIF).

Phương pháp bình phương tối thiểu ước lượng các hệ số bằng cách làm nhỏ nhất tổng bình phương phần dư. Trong cách tiếp cận Bayes, ta kết hợp hàm hợp lý với phân phối tiên nghiệm để tìm phân phối hậu nghiệm của các hệ số. Hai cách có thể cho ước lượng điểm gần nhau khi ảnh hưởng của tiên nghiệm nhỏ so với thông tin từ dữ liệu. Chẳng hạn, hệ số β_{HP} trong mô hình M3 được giới thiệu ở mục 3.4 bằng $-0{,}860$ theo OLS và có trung bình hậu nghiệm bằng $-0{,}859$ theo Bayes.

3.2 Chọn biến

City được chọn làm biến phản hồi và công suất làm biến giải thích chính theo câu hỏi Q4. Nhóm xem xét bổ sung trọng lượng và dung tích động cơ, vì cả hai đều có liên hệ rõ với City trong phân tích khám phá. Tuy nhiên, hai biến này cũng tương quan mạnh với công suất (lần lượt $0{,}74$ và $0{,}73$) và với nhau ($0{,}85$). Do đó, nhóm tính VIF để kiểm tra mức độ đa cộng tuyến (bảng 3.1).

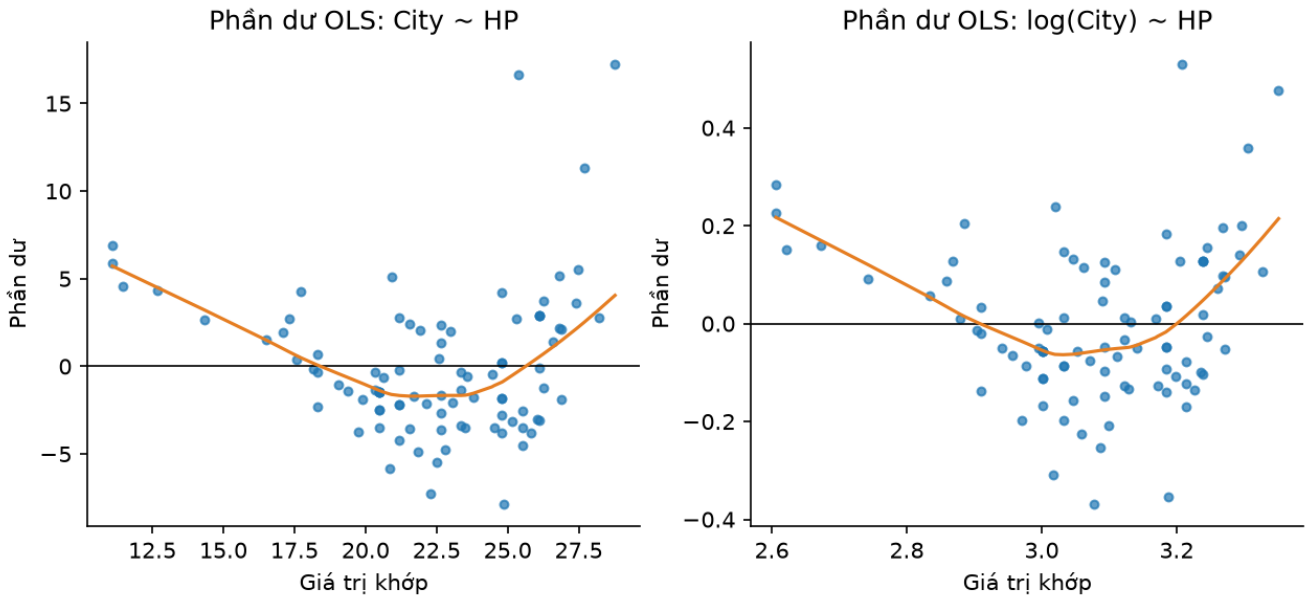
Tất cả VIF đều nhỏ hơn 5. Để giữ mô hình gọn và tránh đưa đồng thời hai biến có tương quan cao, nhóm chọn trọng lượng và chưa đưa dung tích động cơ vào các mô hình chính. Các hệ số tương quan và VIF chưa đủ để khẳng định dung tích động cơ không bổ sung thông tin dự đoán. Với bộ biến công suất, trọng lượng và xuất xứ của M4, VIF lớn nhất là $2{,}34$.

Bảng 3.1: Hệ số phóng đại phương sai của hai bộ biến giải thích.

Biến	HP + Weight + Engine Size	M4: HP + Weight + USA
HP	2,42	2,24
Weight	3,93	2,34
Engine Size	3,84	–
USA	–	1,07

Bảng 3.2: So sánh hai thang của biến phản hồi trong hồi quy OLS theo HP; logarit hàm hợp lý và AIC tính trên thang City.

Biến phản hồi	R^2	Logarit hàm hợp lý	AIC
City	0,452	−264,0	534,0
log(City)	0,506	−246,0	498,0



Hình 3.1: Phần dư OLS theo giá trị khớp, với City và log(City) làm biến phản hồi; đường cam là đường làm trơn LOWESS.

3.3 Biến đổi biến

Do quan hệ giữa City và HP có dạng cong, nhóm so sánh hai phương án: hồi quy OLS của City theo HP và của log(City) theo HP. Để hai mô hình so sánh được với nhau, logarit hàm hợp lý của mô hình logarit được quy về thang City bằng cách cộng thêm số hạng Jacobian $-\sum_i \log \text{City}_i$. Kết quả ở bảng 3.2 cho thấy log(City) khớp dữ liệu tốt hơn hẳn, với AIC thấp hơn 36 đơn vị. Đường làm trơn phần dư ở hình 3.1 cũng không còn dạng cong.

Do đó, các mô hình Bayes sau đây dùng log(City) đã chuẩn hoá làm biến phản hồi, ký hiệu là y. Công suất và trọng lượng cũng được chuẩn hoá bằng cách trừ trung bình rồi chia cho độ lệch chuẩn mẫu; biến xuất xứ USA

Bảng 3.3: Năm mô hình ứng viên; biến phản hồi luôn là $\log(\text{City})$ đã chuẩn hoá.

Mô hình	Công thức	Hàm hợp lý
M1	$y \sim$ HP	Chuẩn
M2	$y \sim$ HP + USA	Chuẩn
M3	$y \sim$ HP + USA + HP $\times$ USA	Chuẩn
M4	$y \sim$ HP + Weight + USA	Chuẩn
M5	$y \sim$ HP + Weight + USA	Student-t

giữ dạng 0/1. Việc chuẩn hoá giúp lựa chọn tiên nghiệm cho các hệ số thuận tiện hơn và hỗ trợ quá trình lấy mẫu MCMC (Monte Carlo theo xích Markov), được trình bày ở mục 4.2. Kết quả được chuyển về đơn vị MPG để diễn giải theo công thức $\text{City} = \exp(\bar{\ell} + s_\ell\, y)$, với $\bar{\ell}$ và s_ℓ là trung bình và độ lệch chuẩn mẫu của $\log(\text{City})$.

3.4 Năm mô hình ứng viên

Nhóm xây dựng năm mô hình để lần lượt xem xét vai trò của xuất xứ, sự khác biệt về độ dốc giữa hai nhóm xe và vai trò của trọng lượng (bảng 3.3). M1 chỉ dùng công suất. M2 bổ sung xuất xứ, còn M3 thêm tương tác giữa công suất và xuất xứ. M4 xét đồng thời công suất, trọng lượng và xuất xứ, không có số hạng tương tác. Cuối cùng, M5 giữ bộ biến của M4 nhưng thay phân phối sai số chuẩn bằng Student-t để hạn chế ảnh hưởng của những quan sát có phần dư lớn. Kết quả so sánh các mô hình được trình bày ở mục 5.2.

3.5 Đặc tả đầy đủ cho M3

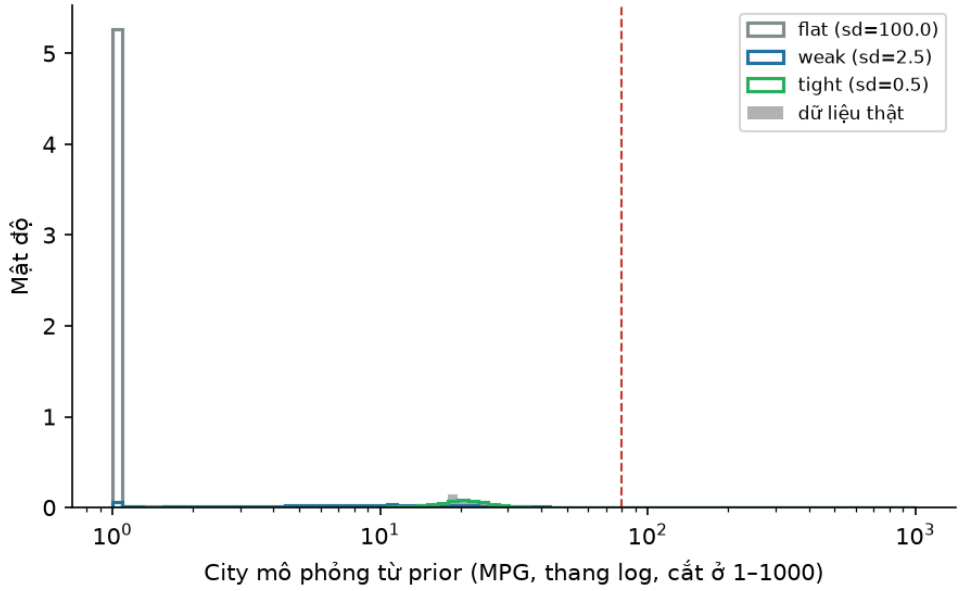
Trên thang đã chuẩn hoá, M3 có dạng

$$\begin{aligned} y_i &\sim \mathcal{N}(\mu_i, \sigma^2), \\ \mu_i &= \beta_0 + \beta_1 \text{HP}_i + \beta_2 \text{USA}_i + \beta_3 \text{HP}_i \text{USA}_i, \\ \beta_j &\sim \mathcal{N}(0, 2{,}5^2), \qquad j = 0, \ldots, 3, \\ \sigma &\sim \text{Half-Normal}(1). \end{aligned} \tag{3.2}$$

Các mô hình còn lại được suy ra bằng cách bớt hoặc thay đổi các số hạng trong μ_i. Riêng M5 dùng hàm hợp lý $y_i \sim t_\nu(\mu_i, \sigma)$ với $\nu \sim \text{Gamma}(2;\, 0{,}1)$, cho phép phân phối có đuôi dày hơn để thích ứng với các điểm ngoại lai. Tiên nghiệm Gamma này có trung bình bằng 20, song vẫn dành xác suất đáng kể cho các giá trị ν nhỏ.

Bảng 3.4: Kiểm tra dự đoán tiên nghiệm cho M3 với ba tiên nghiệm, mỗi tiên nghiệm 1 000 lần mô phỏng.

Tiên nghiệm	City ≤ 80 MPG	City trong 5–80 MPG	Trung vị (MPG)
Rất rộng, sd $= 100$	53,3%	3,4%	5,4
Ít thông tin, sd $= 2{,}5$	92,1%	86,2%	21,0
Hẹp, sd $= 0{,}5$	99,9%	99,9%	21,6

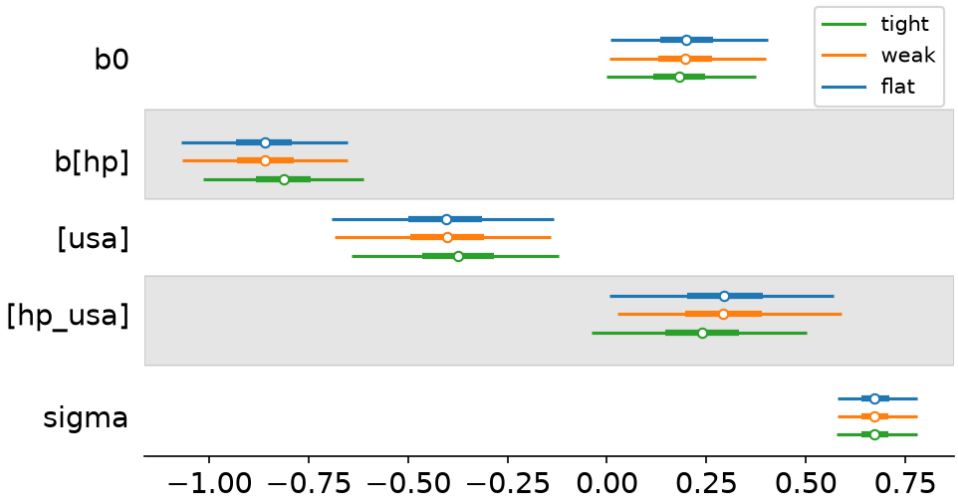


Hình 3.2: Phân phối City mô phỏng từ tiên nghiệm của M3 với ba tiên nghiệm, so với dữ liệu thật; trục hoành theo thang logarit, đường đứt đỏ ở 80 MPG.

3.6 Chọn tiên nghiệm và kiểm tra dự đoán tiên nghiệm

Trước khi ước lượng từ dữ liệu, nhóm kiểm tra xem các tiên nghiệm có sinh ra những giá trị City hợp lý hay không. Ba lựa chọn cho các hệ số gồm tiên nghiệm rất rộng $\mathcal{N}(0, 100^2)$, tiên nghiệm ít thông tin $\mathcal{N}(0, 2{,}5^2)$ và tiên nghiệm hẹp $\mathcal{N}(0, 0{,}5^2)$. Tiên nghiệm liên hợp Normal–Inverse-Gamma cho phép tính hậu nghiệm dưới dạng đóng (mục 4.1), nhưng các tiên nghiệm độc lập trong (3.2) không có tính liên hợp nên nhóm dùng MCMC. Với mỗi lựa chọn, nhóm sinh 1 000 bộ dữ liệu theo mô hình M3 trước khi cập nhật hậu nghiệm. Đây là kiểm tra dự đoán tiên nghiệm. Mô hình trên thang logarit đã bảo đảm City dương; nhóm xét thêm tỉ lệ giá trị không vượt 80 MPG và tỉ lệ nằm trong khoảng 5–80 MPG để phát hiện cả dự đoán quá lớn lẫn quá nhỏ.

Bảng 3.4 và hình 3.2 cho thấy tiên nghiệm rất rộng sinh ra nhiều giá trị phi thực tế: chỉ 3,4% giá trị City mô phỏng nằm trong khoảng 5–80 MPG. Với tiên nghiệm ít thông tin, tỉ lệ này là 86,2%. Nhóm chọn tiên nghiệm ít thông tin cho các mô hình chính vì nó hạn chế các giá trị cực đoan tốt hơn lựa chọn rất rộng. Tiên nghiệm hẹp cho phần lớn giá trị trong phạm vi đã xét, nhưng cũng có thể thu hẹp các hệ số về gần 0. Ảnh hưởng đến kết quả ước lượng được kiểm tra tiếp ở mục 3.7.



Hình 3.3: Hậu nghiệm của M3 với ba tiên nghiệm, trung bình và HDI 95%.

3.7 Ảnh hưởng của tiên nghiệm đến kết quả

Để đánh giá độ nhạy, M3 được ước lượng lại với cả ba tiên nghiệm. Hậu nghiệm dưới tiên nghiệm rất rộng và tiên nghiệm ít thông tin gần như trùng nhau: các trung bình hậu nghiệm chênh lệch tối đa $0{,}04$ độ lệch chuẩn hậu nghiệm. Như vậy, kết quả của M3 ít thay đổi giữa hai lựa chọn này. Tiên nghiệm hẹp kéo các hệ số về gần 0, với mức thay đổi lớn nhất là $0{,}42$ độ lệch chuẩn hậu nghiệm. Ảnh hưởng này thấy rõ nhất ở hệ số tương tác HP $\times$ USA, giảm từ $0{,}294$ xuống $0{,}239$, và HDI 95% lúc này đã chứa 0 (hình 3.3). Do đó, kết luận về tương tác ở mục 5.4 cần được diễn giải thận trọng.

IV. Quá trình ước lượng Bayes

4.1 Công thức hậu nghiệm cho M1

Theo định lý Bayes, phân phối hậu nghiệm tỉ lệ với tích của hàm hợp lý và tiên nghiệm:

$$p(\beta, \sigma^2 \mid y) \propto p(y \mid \beta, \sigma^2)\, p(\beta, \sigma^2). \tag{4.1}$$

Với tiên nghiệm liên hợp Normal–Inverse-Gamma $\beta \mid \sigma^2 \sim \mathcal{N}(m_0, \sigma^2 V_0)$ và $\sigma^2 \sim \mathrm{IG}(a_0, b_0)$, hậu nghiệm có cùng dạng với các tham số

$$\begin{aligned} V_n &= \left(V_0^{-1} + X^\top X\right)^{-1}, \quad m_n = V_n\left(V_0^{-1} m_0 + X^\top y\right), \\ a_n &= a_0 + \tfrac{n}{2}, \qquad\qquad b_n = b_0 + \tfrac{1}{2}\left(y^\top y + m_0^\top V_0^{-1} m_0 - m_n^\top V_n^{-1} m_n\right). \end{aligned} \tag{4.2}$$

Lấy tích phân theo σ^2, phân phối biên của β là phân phối t nhiều chiều với $2a_n$ bậc tự do, tâm m_n và ma trận tỉ lệ $(b_n/a_n)V_n$ [1]. Với lựa chọn $m_0 = 0$, $V_0 = 2{,}5^2 I$, $a_0 = 2$ và $b_0 = 1$, ta tính được $a_n = 48{,}5$ và $b_n = 23{,}76$.

Để kiểm chứng phần cài đặt, nhóm khai báo lại đúng tiên nghiệm này trong PyMC và lấy mẫu bằng NUTS. Như bảng 4.1 cho thấy, hai cách tính cho kết quả gần nhau về trung bình, độ lệch chuẩn và khoảng hậu nghiệm. Dòng cuối của bảng dùng tiên nghiệm ít thông tin độc lập của M1 thay cho tiên nghiệm liên hợp. Dù vậy, hậu nghiệm gần như không đổi, do cả hai tiên nghiệm đều rộng và 93 quan sát đã đủ để dữ liệu chi phối kết quả (hình 4.1).

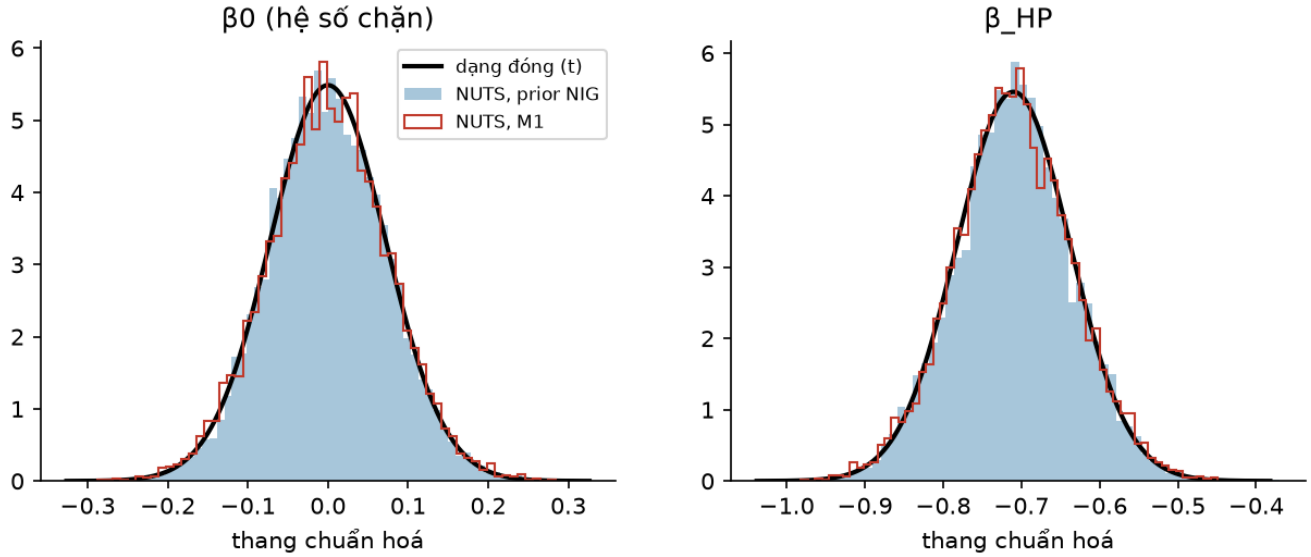
4.2 Lấy mẫu MCMC

Với M2–M5, hậu nghiệm không có dạng đóng nên được lấy mẫu bằng NUTS [7] trong PyMC 5.28 [8]. Mỗi mô hình chạy 4 chuỗi, mỗi chuỗi $2\,000$ vòng lặp sau $1\,000$ vòng khởi động, với seed cố định là 2026. NUTS là một biến thể của Hamiltonian Monte Carlo. Thuật toán dùng gradient của logarit hậu nghiệm để đề xuất những bước di chuyển xa nhưng vẫn giữ xác suất chấp nhận cao, đồng thời tự điều chỉnh độ dài quỹ đạo thay vì để người dùng tinh chỉnh thủ công.

Để so sánh, nhóm tự cài đặt thuật toán Metropolis–Hastings bước ngẫu nhiên cho M1. Thuật toán lấy mẫu trên không gian $(\beta_0, \beta_1, \log\sigma)$, có cộng Jacobian $\log\sigma$ vào logarit hậu nghiệm, với bước đề xuất phân phối chuẩn có độ lệch chuẩn $0{,}08$. Nhóm chạy 4 chuỗi, mỗi chuỗi $6\,000$ vòng và bỏ $1\,000$ vòng đầu, tỉ lệ chấp nhận đạt từ

Bảng 4.1: Hậu nghiệm của β_{HP} trong M1, thang chuẩn hoá: công thức so với MCMC.

Cách tính	Trung bình	Độ lệch chuẩn	Khoảng 95%
Công thức (NIG)	$-0{,}710\,1$	$0{,}073\,7$	$[-0{,}855; -0{,}565]$
NUTS, cùng tiên nghiệm NIG	$-0{,}709\,9$	$0{,}074\,2$	$[-0{,}857; -0{,}564]$
NUTS, tiên nghiệm ít thông tin M1	$-0{,}710\,3$	$0{,}075\,4$	$[-0{,}862; -0{,}560]$



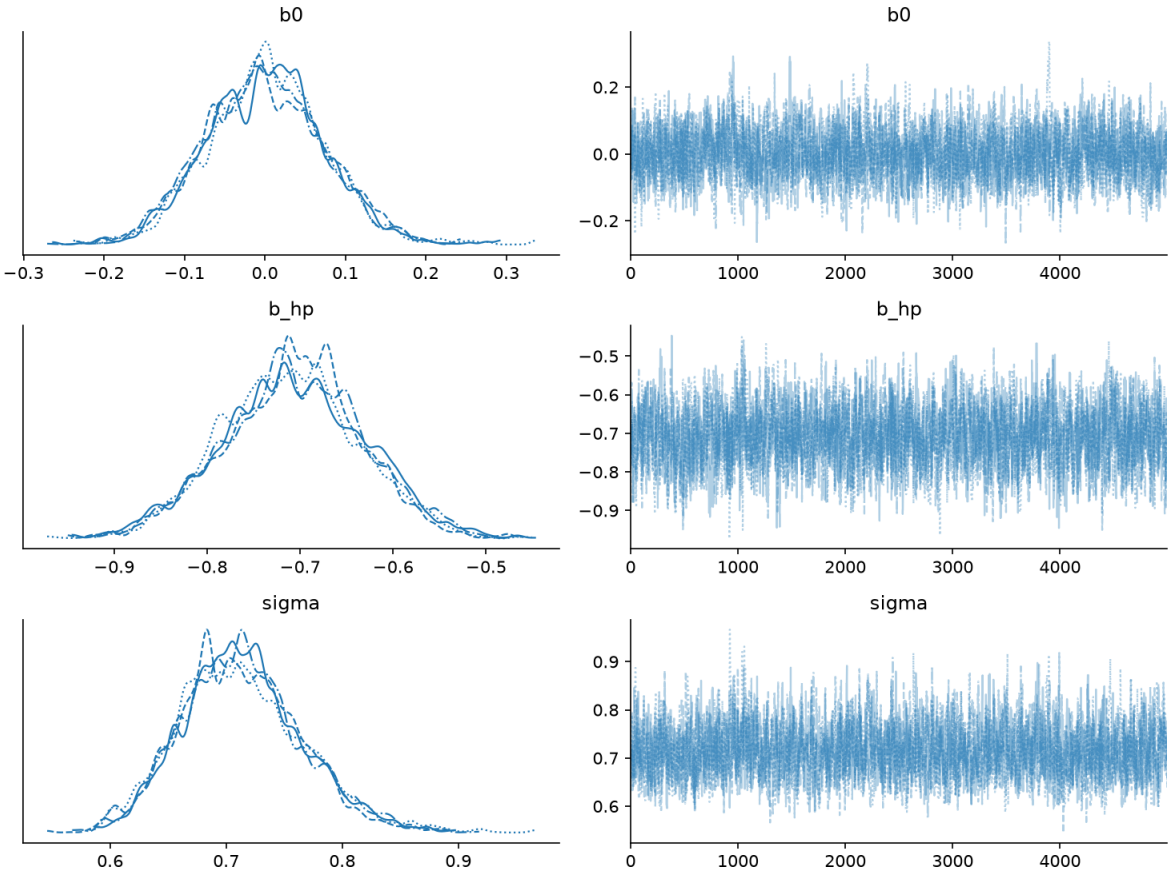
Hình 4.1: Hậu nghiệm của M1: mật độ t tính bằng công thức (đen), NUTS với cùng tiên nghiệm NIG (xanh) và NUTS với tiên nghiệm của M1 (đỏ).

$0{,}41$ đến $0{,}43$. Metropolis–Hastings cho hậu nghiệm giống NUTS ($\beta_{\text{HP}} = -0{,}708$ so với $-0{,}710$) nhưng kém hiệu quả hơn nhiều. Từ $20\,000$ mẫu, thuật toán chỉ thu được cỡ mẫu hiệu dụng khoảng $1\,700$, trong khi NUTS đạt khoảng $12\,000$ từ $8\,000$ mẫu. Nguyên nhân là mỗi bước Metropolis–Hastings chỉ di chuyển một quãng ngắn, khiến các mẫu liên tiếp tự tương quan mạnh (hình 4.2).

4.3 Chẩn đoán hội tụ

Nhóm kiểm tra xem các chuỗi lấy mẫu có cho kết quả ổn định và nhất quán với nhau hay không. Bốn tiêu chí được sử dụng gồm: $\widehat{R}$ (phiên bản dựa trên thứ hạng [9]) nhỏ hơn $1{,}01$; cỡ mẫu hiệu dụng (ESS) cho phần trung tâm (bulk) và phần đuôi (tail) đều lớn hơn 400; không có bước phân kỳ (divergence); biểu đồ vết và biểu đồ thứ hạng không có dấu hiệu bất thường. ESS cho biết lượng thông tin của các mẫu có tương quan tương đương với bao nhiêu mẫu độc lập.

Cả năm mô hình đều thoả mãn các tiêu chí trên (bảng 4.2). Biểu đồ vết của M5 (hình 4.3) cho thấy bốn chuỗi dao động trong cùng một vùng và không có xu hướng dịch chuyển rõ rệt theo vòng lặp. Các chẩn đoán này không cho thấy dấu hiệu chưa hội tụ. Chương trình cũng kiểm tra các ngưỡng đã đặt trước khi tổng hợp kết quả.



Hình 4.2: Biểu đồ vết của Metropolis–Hastings tự viết cho M1, bốn chuỗi.

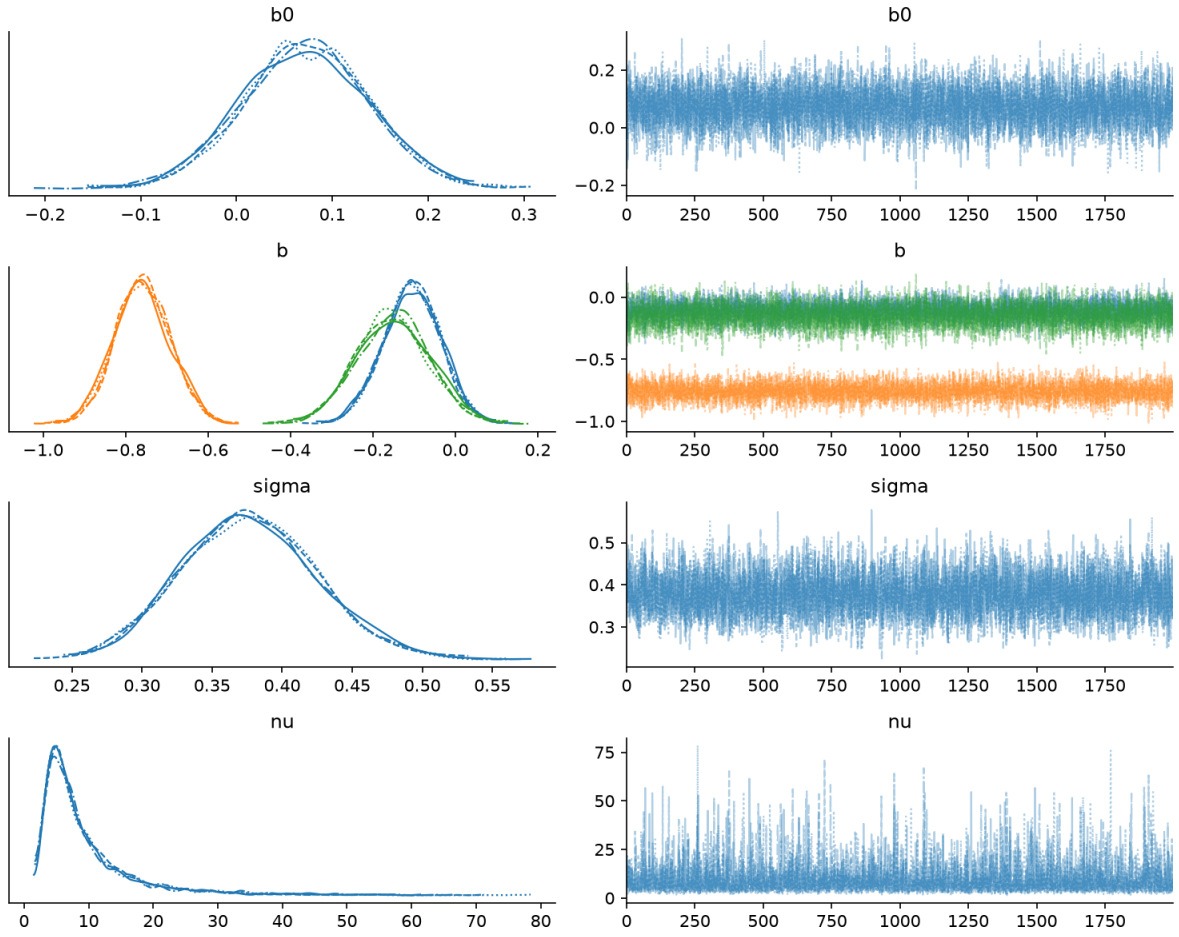
Bảng 4.2: Chẩn đoán hội tụ của năm mô hình; giá trị xấu nhất trên mọi tham số.

Mô hình	$\widehat{R}$ lớn nhất	ESS bulk nhỏ nhất	ESS tail nhỏ nhất	Số bước phân kỳ
M1	1,00	10 830	5 460	0
M2	1,00	6 013	5 295	0
M3	1,00	5 618	5 197	0
M4	1,00	5 116	5 091	0
M5	1,00	4 626	4 763	0

4.4 Bảng tóm tắt hậu nghiệm

Bảng 4.3 trình bày trung bình hậu nghiệm và khoảng mật độ hậu nghiệm cao nhất 95% (HDI 95%) của các hệ số. Các hệ số đều được báo cáo trên thang chuẩn hoá. Trong mô hình không có tương tác, hệ số công suất hoặc trọng lượng cho biết giá trị kỳ vọng của y thay đổi bao nhiêu khi biến tương ứng tăng một độ lệch chuẩn, với các biến còn lại giữ nguyên. Hệ số USA biểu diễn chênh lệch giữa xe Mỹ và xe nước ngoài. Riêng M3 có tương tác nên hệ số công suất ứng với nhóm xe nước ngoài, còn hệ số USA ứng với mức công suất trung bình của mẫu.

Trong M5, trung bình hậu nghiệm của bậc tự do ν là 9,4 (HDI 95%: $[1{,}8;\ 24{,}7]$). Tham số này cho phép mô



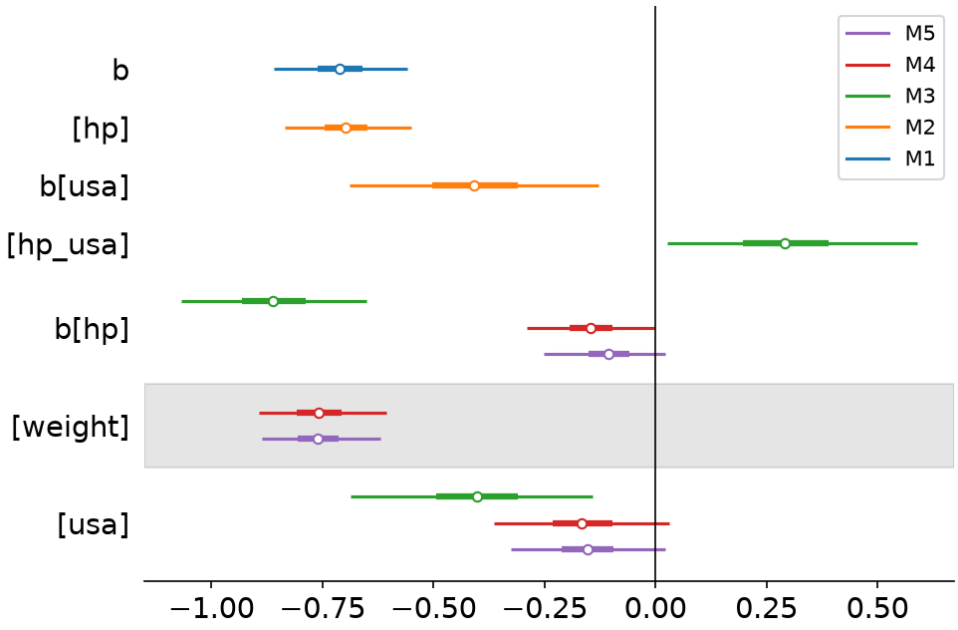
Hình 4.3: Biểu đồ vết của M5: mật độ hậu nghiệm theo chuỗi (trái) và giá trị qua các vòng lặp (phải).

Bảng 4.3: Trung bình hậu nghiệm và HDI 95% của các hệ số, thang chuẩn hoá. Cột σ là độ lệch chuẩn sai số với M1–M4 và tham số thang đo Student-t với M5.

Mô hình	β_{HP}	β_{USA}	$\beta_{\text{HP}\times\text{USA}}$	β_{Weight}	σ
M1	$-0{,}71$ [$-0{,}86$; $-0{,}56$]	–	–	–	0,72
M2	$-0{,}70$ [$-0{,}84$; $-0{,}55$]	$-0{,}41$ [$-0{,}69$; $-0{,}13$]	–	–	0,69
M3	$-0{,}86$ [$-1{,}07$; $-0{,}65$]	$-0{,}40$ [$-0{,}69$; $-0{,}14$]	0,29 [0,03; 0,59]	–	0,68
M4	$-0{,}15$ [$-0{,}29$; 0,00]	$-0{,}16$ [$-0{,}36$; 0,03]	–	$-0{,}76$ [$-0{,}89$; $-0{,}61$]	0,47
M5	$-0{,}11$ [$-0{,}25$; 0,02]	$-0{,}15$ [$-0{,}33$; 0,02]	–	$-0{,}76$ [$-0{,}89$; $-0{,}62$]	0,38

hình mô tả sai số có đuôi dày hơn phân phối chuẩn, dù mức độ dày của đuôi còn có độ bất định khá lớn.

Khi bổ sung trọng lượng ở M4 và M5, độ lớn của hệ số công suất giảm rõ rệt (hình 4.4). Đồng thời, độ lệch chuẩn sai số giảm từ 0,68 ở M3 xuống 0,47 ở M4. Kết quả này cho thấy cần xét trọng lượng khi diễn giải mối liên hệ giữa công suất và City: xe công suất lớn trong mẫu thường cũng nặng hơn. Tuy nhiên, sự thay đổi hệ số giữa các mô hình chưa cho phép kết luận về tác động nhân quả của từng biến. Cần lưu ý rằng σ ở M1–M4 là độ lệch chuẩn của sai số, còn ở M5 là tham số thang đo của phân phối Student-t, nên hai loại giá trị này không so sánh trực tiếp được (xem mục 5.5).



Hình 4.4: Hệ số hậu nghiệm của M1–M5 trên thang chuẩn hoá, trung bình và HDI 95%.

V. Đánh giá kết quả và trả lời câu hỏi

5.1 Kiểm tra dự đoán hậu nghiệm

Mục đích của kiểm tra dự đoán hậu nghiệm là xem dữ liệu sinh từ mô hình có những đặc điểm giống dữ liệu quan sát hay không. Với mỗi mô hình, nhóm sinh $8\,000$ bộ dữ liệu từ hậu nghiệm, chuyển về đơn vị MPG rồi so sánh phân phối với dữ liệu thực (hình 5.1). Với mỗi thống kê được xét, p-value Bayes ở đây là tỉ lệ bộ dữ liệu mô phỏng có thống kê lớn hơn hoặc bằng giá trị quan sát.

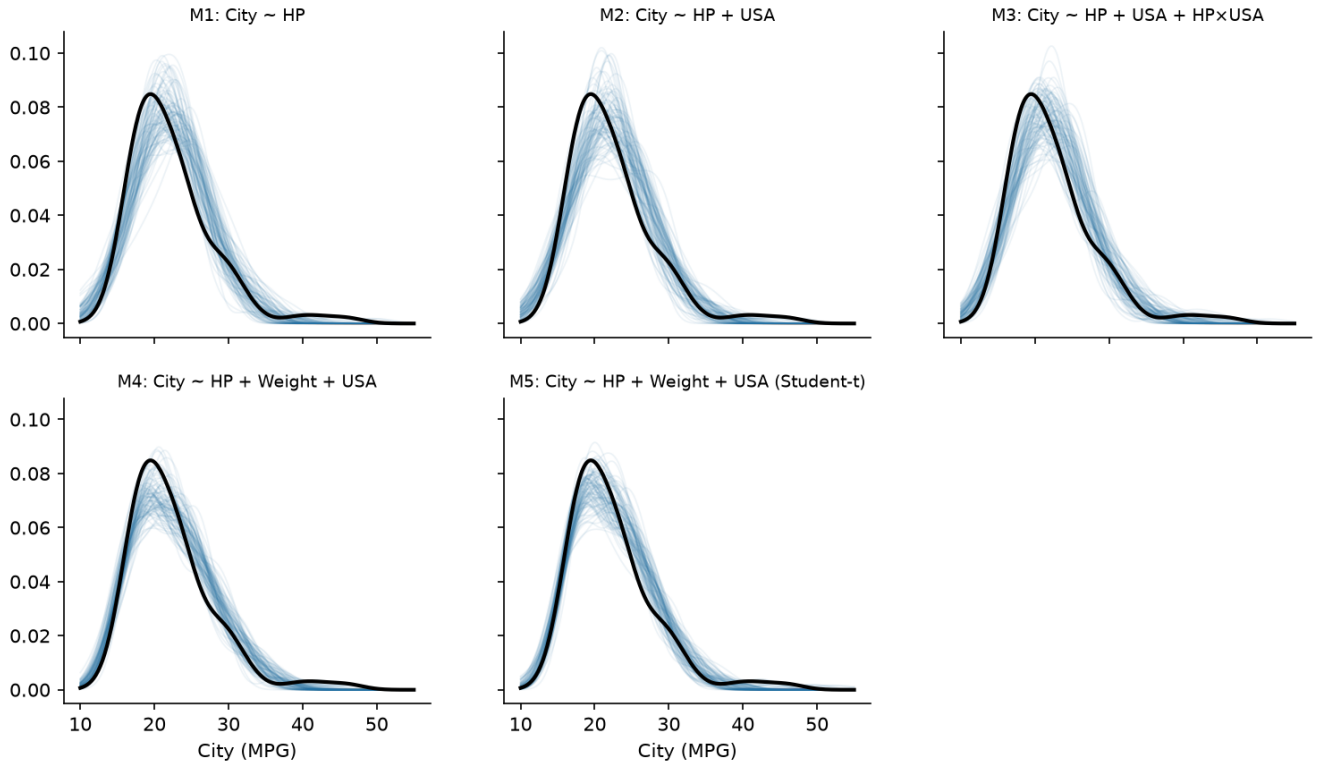
Giá trị trung bình City của mẫu không có biểu hiện bất thường so với các bộ dữ liệu mô phỏng: p-value nằm trong khoảng $0{,}38$–$0{,}47$. Tuy nhiên, M1–M4 còn mô tả hạn chế các giá trị ở hai đầu phân phối. Chẳng hạn, dữ liệu mô phỏng hiếm khi có xe đạt 46 MPG như Geo Metro; p-value của giá trị lớn nhất chỉ từ $0{,}006$ đến $0{,}024$. M5 cải thiện việc mô tả các giá trị cực trị, nhưng p-value của giá trị lớn nhất $(0{,}041)$ và nhỏ nhất $(0{,}044)$ vẫn thấp. Vì vậy, M5 phù hợp hơn về mặt này nhưng chưa mô tả đầy đủ hai đầu phân phối.

5.2 So sánh mô hình

Nhóm so sánh khả năng dự đoán bằng tổng kỳ vọng logarit mật độ dự đoán (ELPD); giá trị lớn hơn cho thấy khả năng dự đoán tốt hơn theo tiêu chí này. ELPD được ước lượng bằng PSIS-LOO, phương pháp xấp xỉ kiểm định chéo bỏ từng quan sát, và WAIC, tiêu chí thông tin dùng để đánh giá dự đoán Bayes [10], qua thư viện ArviZ [11].

Hai cách đánh giá cho cùng thứ hạng (bảng 5.1). M5 có ELPD cao nhất và được chọn làm mô hình cuối. Trọng số stacking, dùng để kết hợp các phân phối dự đoán, của M5 là $0{,}97$; trọng số này không phải xác suất mô hình đúng. So với M4, M5 cao hơn $4{,}45$ đơn vị ELPD, với sai số chuẩn của chênh lệch là $2{,}60$, tức khoảng $1{,}7$ lần sai số chuẩn. Đây là một lợi thế về dự đoán, nhưng mức chênh lệch còn khá bất định. Sự khác biệt rõ hơn nằm ở việc bổ sung trọng lượng: M4 và M5 cao hơn M1–M3 từ 34 đến 43 đơn vị ELPD, tương đương hơn bốn lần sai số chuẩn của chênh lệch.

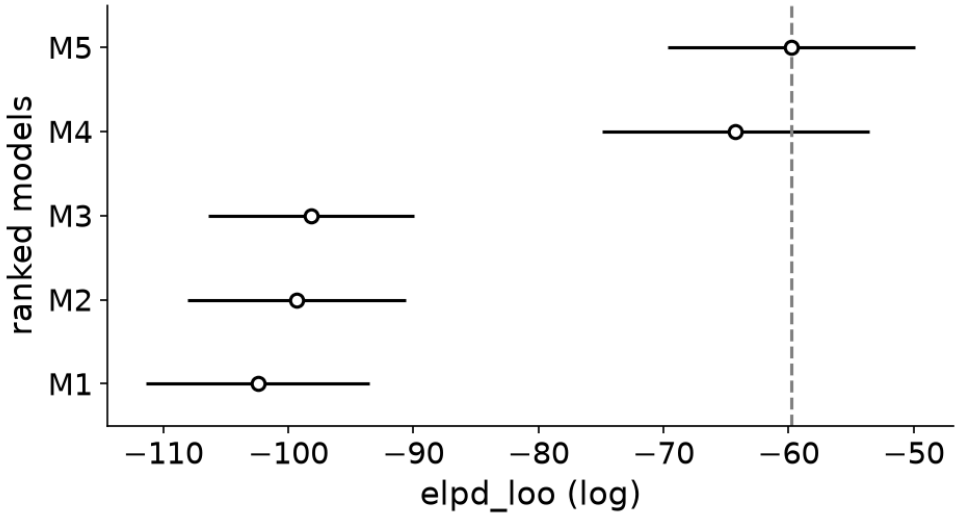
Không quan sát nào có chỉ số chẩn đoán Pareto k vượt $0{,}7$. Theo ngưỡng được sử dụng, chưa có dấu hiệu cho thấy phép xấp xỉ PSIS-LOO thiếu ổn định ở cả năm mô hình (hình 5.2).



Hình 5.1: Kiểm tra dự đoán hậu nghiệm: mật độ dữ liệu thật (đen) và 100 bộ dữ liệu sinh từ hậu nghiệm (xanh).

Bảng 5.1: So sánh mô hình bằng PSIS-LOO và WAIC; chênh lệch tính so với M5.

Mô hình	ELPD-LOO	p_{loo}	Chênh lệch	SE chênh lệch	ELPD-WAIC	Pareto $k > 0{,}5$
M5	$-59{,}8$	$6{,}4$	0	–	$-59{,}7$	0
M4	$-64{,}2$	$6{,}7$	$4{,}4$	$2{,}6$	$-64{,}2$	1
M3	$-98{,}2$	$6{,}0$	$38{,}4$	$8{,}4$	$-98{,}1$	0
M2	$-99{,}3$	$5{,}1$	$39{,}6$	$8{,}2$	$-99{,}3$	0
M1	$-102{,}4$	$4{,}1$	$42{,}6$	$7{,}8$	$-102{,}4$	0



Hình 5.2: ELPD-LOO của năm mô hình, kèm sai số chuẩn và sai số chuẩn của chênh lệch so với mô hình tốt nhất.

5.3 Trả lời Q1: quan hệ giữa các biến

Khi chỉ xét công suất, xe có công suất lớn hơn thường có City thấp hơn, tức là kém tiết kiệm nhiên liệu hơn. Tuy nhiên, khi so sánh các xe có cùng trọng lượng và xuất xứ, mối liên hệ này yếu đi rõ rệt. Để diễn giải trên đơn vị ban đầu, nhóm quy đổi hệ số thành phần trăm thay đổi của trung vị City. Với mô hình trên thang logarit, khi công suất tăng 10 hp, trung vị có điều kiện của City được nhân với $\exp(10\,\beta_{\text{HP}}\,s_\ell/s_{\text{HP}})$, với s_{HP} là độ lệch chuẩn của HP. Các tỉ lệ phần trăm dưới đây vì thế là mức thay đổi tương đối của trung vị City.

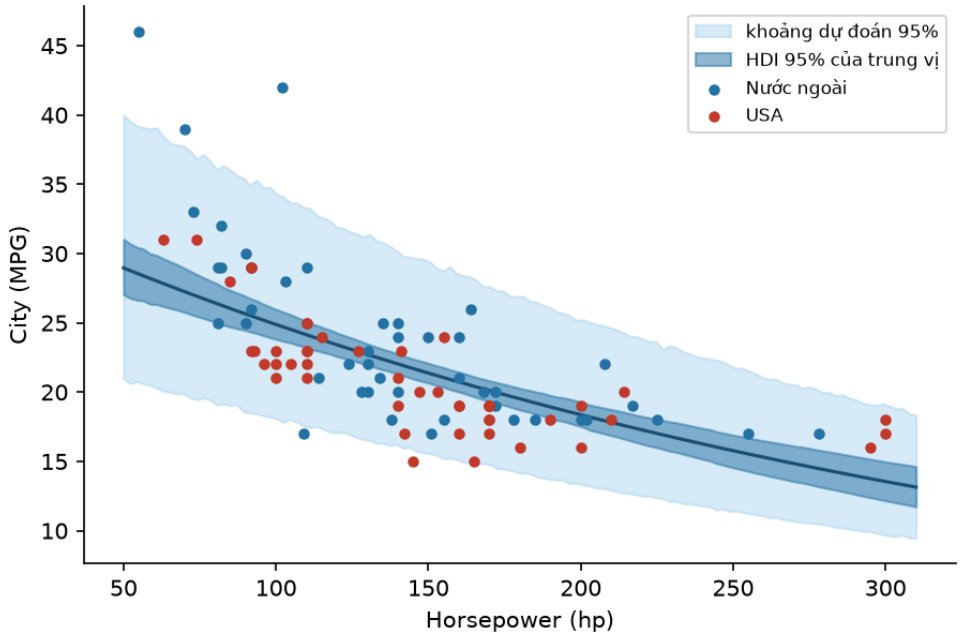
- Khi chỉ xét công suất (M1), mỗi 10 hp tăng thêm ứng với trung vị City giảm 3,0% (HDI 95% từ $-3{,}6\%$ đến $-2{,}4\%$). Chẳng hạn, khi công suất tăng từ 140 lên 150 hp, trung vị City giảm $0{,}66$ MPG, HDI 95% từ $-0{,}80$ đến $-0{,}52$ MPG (hình 5.3).
- Khi giữ trọng lượng và xuất xứ không đổi (M5), mỗi 10 hp tăng thêm ứng với mức thay đổi $-0{,}45\%$ (HDI 95% từ $-1{,}07\%$ đến $+0{,}10\%$). Xác suất hậu nghiệm để hệ số công suất âm là $0{,}94$, nhưng HDI 95% vẫn chứa 0.
- Khi giữ công suất và xuất xứ không đổi (M5), mỗi $100\,\text{kg}$ tăng thêm ứng với trung vị City giảm 6,2% (HDI 95% từ $-7{,}1\%$ đến $-5{,}0\%$).

Kết quả này phù hợp với các biểu đồ phân tán ở mục 2.6, trong đó City giảm phi tuyến theo cả HP, Weight và Engine Size, và tương quan với Weight mạnh hơn với HP. Do City và Open Road tương quan tới $0{,}94$, nhiều khả năng Open Road cũng có xu hướng tương tự. Tuy vậy, để có kết luận định lượng cho Open Road cần ước lượng một mô hình riêng cho biến này.

5.4 Trả lời Q2: xe Mỹ và xe nước ngoài

Nhóm so sánh hai nhóm xe ở cùng mức công suất, sau đó xét thêm trọng lượng để xem chênh lệch có thay đổi hay không. Trong M2, trung vị City của xe Mỹ thấp hơn xe nước ngoài khoảng 8,7% khi giữ công suất không đổi. Xác suất hậu nghiệm để hệ số USA dương, tức trung vị City của xe Mỹ cao hơn trong phép so sánh này, là $0{,}003$ (bảng 5.2).

Khi so sánh ở cùng công suất và trọng lượng trong M5, chênh lệch ước lượng còn 3,3% và HDI 95% của hệ số USA chứa 0. Như vậy, mức chênh lệch nhỏ hơn và chưa được xác định rõ theo khoảng hậu nghiệm này. Kết quả cho thấy việc xét thêm trọng lượng làm thay đổi đáng kể phép so sánh giữa hai nhóm; dữ liệu quan sát chưa cho phép khẳng định trọng lượng là nguyên nhân của chênh lệch.



Hình 5.3: M1: City theo HP, với HDI 95% của trung vị có điều kiện (xanh đậm) và khoảng dự đoán 95% (xanh nhạt).

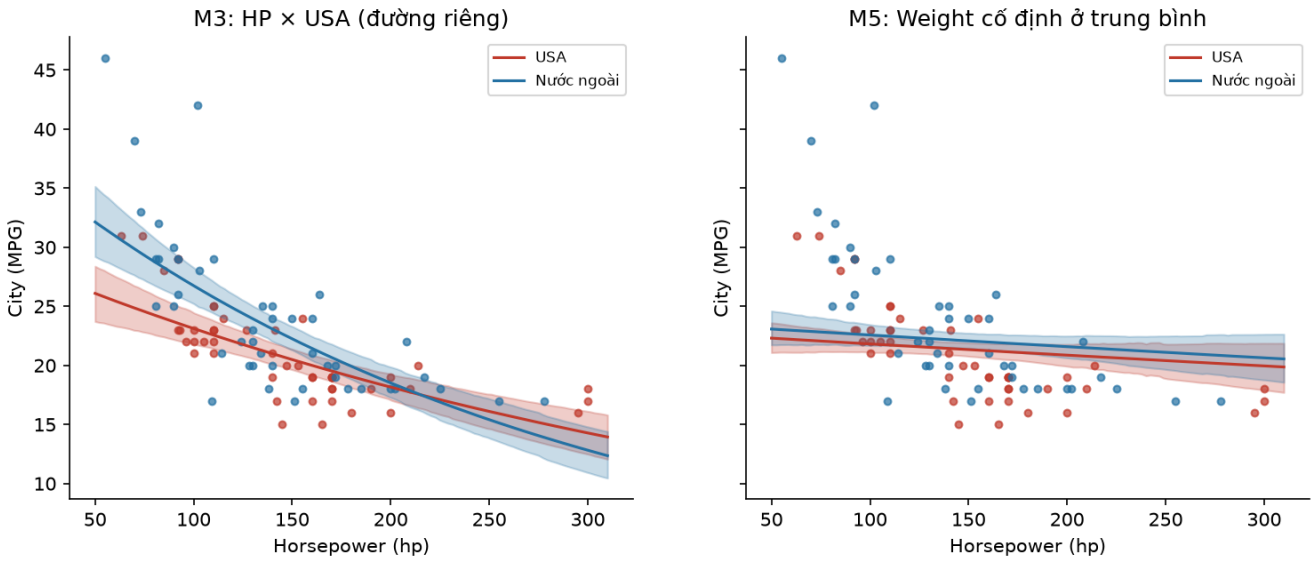
Bảng 5.2: Hệ số USA và chênh lệch trung vị City của xe Mỹ so với xe nước ngoài. Riêng M3, chênh lệch được tính tại công suất trung bình của mẫu.

Mô hình	β_{USA} [HDI 95%]	Chênh lệch City của xe Mỹ	$P(\beta_{\text{USA}} > 0 \mid y)$
M2: HP + USA	$-0{,}41$ [$-0{,}69$; $-0{,}13$]	$-8{,}7\%$	$0{,}003$
M3: có HP $\times$ USA	$-0{,}40$ [$-0{,}69$; $-0{,}14$]	$-8{,}6\%$	$0{,}003$
M5: có Weight	$-0{,}15$ [$-0{,}33$; $0{,}02$]	$-3{,}3\%$	$0{,}043$

Trong M3, hệ số tương tác HP $\times$ USA mang dấu dương, bằng $0{,}29$ (HDI 95%: $[0{,}03;\ 0{,}59]$), với xác suất dương là $0{,}98$. Kết quả ước lượng cho thấy xe nước ngoài có trung vị City cao hơn ở vùng công suất thấp, nhưng chênh lệch giảm dần khi công suất tăng. Hai đường hồi quy ước lượng giao nhau ở khoảng 200 hp (hình 5.4, trái). Tuy nhiên, như đã chỉ ra ở mục 3.7, kết quả này nhạy với lựa chọn tiên nghiệm, nên nhóm chỉ xem đây là một dấu hiệu cần kiểm chứng thêm. Hệ số USA của M3 tương ứng với mức công suất trung bình của mẫu, tại đó trung vị City của xe Mỹ thấp hơn khoảng 8,6%; không thể áp dụng con số này cho mọi mức công suất. Với M5, khi giữ trọng lượng ở mức trung bình, hai đường hồi quy gần nhau hơn (hình 5.4, phải).

5.5 Trả lời Q3: các điểm ngoại lai

Một xe được xem là khác biệt so với dự đoán hay không còn phụ thuộc vào các biến đã đưa vào mô hình. Nhóm dùng M4, có cùng bộ biến với M5 nhưng giả định sai số chuẩn, để xem xét phần dư và sau đó đối chiếu với M5 (bảng 5.3, hình 5.5). Phần dư chuẩn hoá được tính bằng hiệu giữa y_i và trung bình hậu nghiệm của μ_i, chia cho trung bình hậu nghiệm của σ. Chỉ số Pareto k được dùng để chẩn đoán độ ổn định của phép xấp xỉ PSIS-LOO



Hình 5.4: Đường hồi quy và HDI 95% cho xe Mỹ và xe nước ngoài: M3 với tương tác (trái) và M5 với Weight cố định ở mức trung bình (phải).

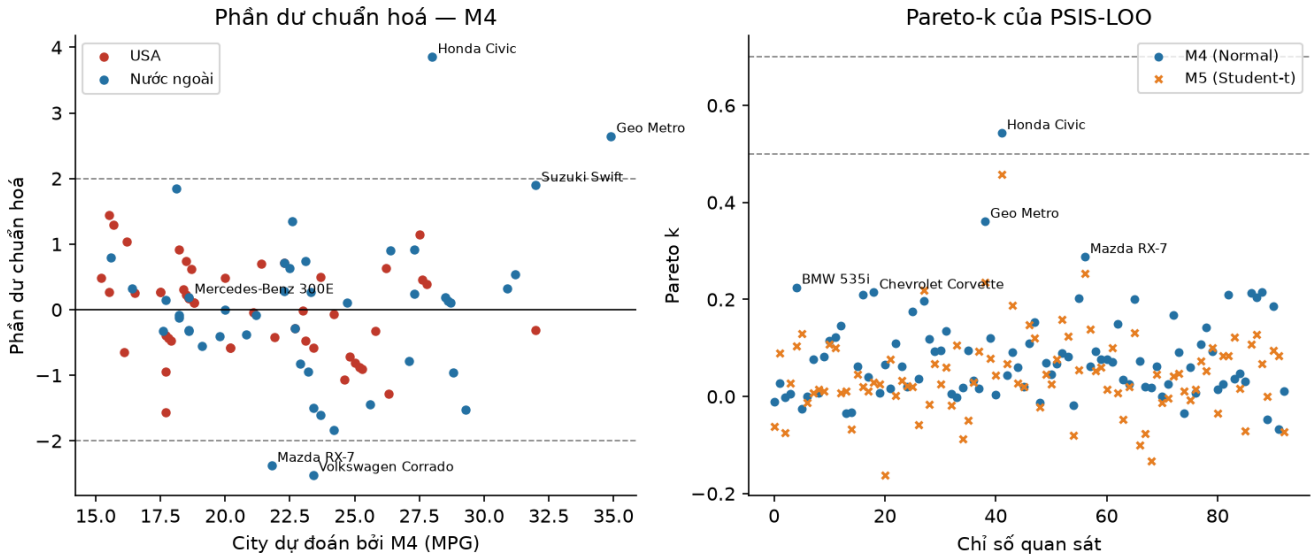
Bảng 5.3: Các xe cần xem xét khi phân tích ngoại lai; dự đoán và phần dư chuẩn hoá được tính theo M4.

Xe	City	Dự đoán	Phần dư	k	Giải thích
Honda Civic	42	28,0	3,86	0,54	Xe nhẹ (1 066 kg), có thể là phiên bản động cơ tiết kiệm nhiên liệu; ảnh hưởng lớn nhất
Geo Metro	46	34,9	2,65	0,36	Xe nhẹ nhất mẫu (769 kg), máy 1,0 L 55 hp, nằm ngoài vùng có nhiều dữ liệu
Suzuki Swift	39	32,0	1,90	0,21	Cùng loại xe cỡ nhỏ với Geo Metro, máy 1,3 L, 891 kg
Mazda RX-7	17	21,8	−2,37	0,29	Động cơ rotary 1,3 L nhưng 255 hp; thân nhẹ nên mô hình dự đoán cao hơn
Volkswagen Corrado	18	23,4	−2,52	0,19	Xe thể thao, máy 2,8 L 178 hp trên thân 1 275 kg
Ford Aerostar	15	17,7	−1,57	0,10	Xe van nặng; phần dư không còn lớn khi mô hình xét thêm trọng lượng
Mercedes-Benz 300E	19	18,6	0,19	0,09	Ngoại lai về giá (Max Price 80, cao nhất), không phải về nhiên liệu

khi bỏ từng quan sát. Chỉ số lớn có thể gợi ý quan sát cần được xem xét thêm; đây không phải thước đo trực tiếp của độ lớn phần dư.

Nhóm xe van có City từ 15 đến 18 MPG và có phần dư lớn khi mô hình chỉ xét công suất. Khi bổ sung trọng lượng, phần dư chuẩn hoá của chúng chỉ còn từ $-1{,}6$ đến $+0{,}3$. Như vậy, mô hình có trọng lượng mô tả tốt hơn chỉ số City thấp của nhóm xe này. Ba xe cỡ nhỏ Honda Civic, Geo Metro và Suzuki Swift tiết kiệm hơn mức dự đoán của mô hình log-tuyến tính, ngược lại Mazda RX-7 và Volkswagen Corrado tốn nhiên liệu hơn dự đoán. Riêng lời giải thích về phiên bản động cơ của Honda Civic chỉ là giả thuyết, vì dữ liệu không ghi rõ phiên bản.

Khi chuyển từ M4 sang M5, Pareto k lớn nhất giảm từ $0{,}54$ xuống $0{,}46$, còn β_{HP} giảm về độ lớn từ $-0{,}15$ xuống



Hình 5.5: Phần dư chuẩn hoá theo giá trị dự đoán của M4 (trái) và Pareto k của từng quan sát với M4 và M5 (phải).

$-0{,}11$ và HDI 95% lúc này chứa 0. Hệ số của Weight vẫn giữ ở mức $-0{,}76$, cho thấy ước lượng về mối liên hệ giữa trọng lượng và City ít thay đổi khi chuyển từ giả định sai số chuẩn sang Student-t.

Tham số σ của M5 bằng $0{,}38$, nhỏ hơn mức $0{,}47$ của M4, nhưng hai giá trị này không so sánh trực tiếp được. Với phân phối Student-t, σ là tham số thang đo, còn độ lệch chuẩn của sai số bằng $\sigma\sqrt{\nu/(\nu-2)}$ khi $\nu > 2$; khi $\nu \leq 2$, phương sai không hữu hạn (chỉ $0{,}3\%$ mẫu hậu nghiệm rơi vào trường hợp này). Quy về cùng thước đo, độ lệch chuẩn sai số của M5 có trung vị hậu nghiệm khoảng $0{,}45$, gần với M4. Vì vậy, không nên diễn giải việc σ nhỏ hơn là mức biến động tổng thể của sai số giảm tương ứng. Phân phối Student-t cho phép phần trung tâm tập trung hơn và phần đuôi dày hơn, nhờ đó mô tả được cả những xe có độ lệch lớn so với dự đoán.

5.6 Trả lời Q4: dự đoán cho xe 300 hp

Để trả lời câu hỏi dự đoán, nhóm phân biệt hai trường hợp: chỉ biết công suất và biết thêm trọng lượng, xuất xứ. Khi chỉ biết công suất là 300 hp, nhóm dùng M1 vì mô hình này không đòi hỏi thông tin về các biến còn lại. Ước lượng trung vị City là $13{,}6$ MPG, với khoảng dự đoán 95% từ $9{,}7$ đến $18{,}8$ MPG.

Với M5, cần chỉ rõ cả trọng lượng và xuất xứ của xe. Nhóm xét một xe Mỹ có công suất 300 hp và trọng lượng $1\,681$ kg, là trọng lượng trung bình của ba xe trong mẫu có công suất từ 295 hp trở lên. Khi đó, ước lượng trung vị City là $16{,}6$ MPG và khoảng dự đoán 95% là $13{,}4$–$20{,}6$ MPG (bảng 5.4). Đây là dự đoán cho cấu hình đã nêu; thay đổi trọng lượng hoặc xuất xứ sẽ làm kết quả thay đổi.

Các kết quả cần được phân biệt ở hai mức. Với mỗi bộ tham số hậu nghiệm, trung vị City của các xe có cùng

Bảng 5.4: Dự đoán City cho xe 300 hp. Riêng M5, trọng lượng được đặt ở 1 681 kg; cột ước lượng trung vị là trung bình hậu nghiệm của m.

Mô hình	Xuất xứ	Ước lượng trung vị City [HDI 95%]	Khoảng dự đoán 95%
M1: chỉ HP	bất kỳ	13,6 [12,2; 15,0]	9,7–18,8
M3	Mỹ	14,3 [12,5; 16,1]	10,3–19,6
M3	nước ngoài	12,9 [10,9; 14,8]	9,2–17,9
M5	Mỹ	16,6 [15,4; 18,0]	13,4–20,6
M5	nước ngoài	17,2 [15,9; 18,5]	13,8–21,3

Bảng 5.5: Dự đoán của M5 cho ba xe thật có từ 295 hp trở lên.

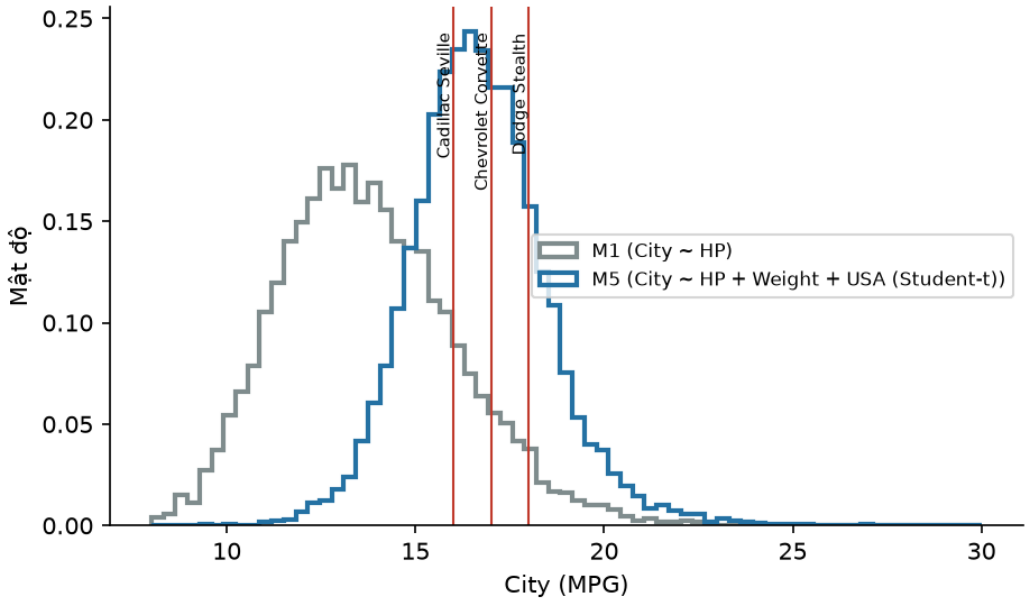
Xe	HP	Weight (kg)	City thật	Trung vị dự đoán	Khoảng dự đoán 95%
Cadillac Seville	295	1 785	16	15,6	12,6–19,2
Chevrolet Corvette	300	1 533	17	18,3	14,6–22,7
Dodge Stealth	300	1 726	18	16,1	13,0–20,0

đặc điểm là $m = \exp(\bar{\ell} + s_\ell \mu)$, do μ nằm trên thang đã chuẩn hoá. Cột "Ước lượng trung vị" trong bảng 5.4 báo cáo trung bình hậu nghiệm của m, kèm HDI 95% thể hiện sự bất định khi ước lượng trung vị này. Khoảng dự đoán 95% còn tính thêm sự khác biệt giữa các xe có cùng đặc điểm, nên rộng hơn. Với M5, kỳ vọng City theo mô hình không hữu hạn do phép biến đổi mũ của phân phối Student-t; vì vậy nhóm dùng trung vị để mô tả mức City điển hình.

Cả ba xe có công suất gần 300 hp trong mẫu đều là xe Mỹ. Khi dùng thông số riêng của từng xe, khoảng dự đoán của M5 đều chứa giá trị thực (bảng 5.5). Tuy vậy, ba xe này đã nằm trong dữ liệu dùng để ước lượng mô hình, nên đây là kiểm tra trên dữ liệu đã dùng để ước lượng, chưa phải đánh giá dự đoán cho xe mới. Ước lượng trung vị từ M1 ở mức 300 hp (13,6 MPG) thấp hơn City quan sát của cả ba xe (16–18 MPG). Điều này cho thấy hạn chế của việc chỉ dùng công suất để mô tả các xe ở vùng công suất cao (hình 5.6). Đồng thời, 300 hp là giá trị lớn nhất trong mẫu và chỉ có ít xe gần mức này, nên cần thận trọng khi diễn giải kết quả dự đoán.

5.7 Hạn chế

Báo cáo còn một số hạn chế. Thứ nhất, mẫu chỉ có 93 xe, trong đó chỉ ba xe có công suất trên 280 hp, nên dự đoán ở vùng biên có độ bất định lớn. Thứ hai, dữ liệu được thu thập năm 1993, khi công nghệ động cơ còn khác xa hiện nay, nên không thể áp dụng trực tiếp kết quả cho xe ngày nay. Thứ ba, các quan hệ tìm được chỉ là tương quan, không phải quan hệ nhân quả, và dự đoán ngoài khoảng 55–300 hp hoặc 769–1 862 kg không đáng tin cậy. Cuối cùng, phần kiểm tra dự đoán trực tiếp ở Q4 chỉ dùng các xe có sẵn trong mẫu. PSIS-LOO đã cung cấp một đánh giá bằng kiểm định chéo, nhưng nhóm chưa kiểm tra dự đoán trên một bộ dữ liệu độc lập.



Hình 5.6: Phân phối dự đoán hậu nghiệm cho một xe Mỹ 300 hp theo M1 và M5; đường đỏ là City của ba xe thật gần 300 hp.

VI. Kết luận

Trong mẫu 93 xe năm 1993, trọng lượng có mối liên hệ rõ nhất với chỉ số MPG trong thành phố trong số các biến đã xét. Nhóm chọn M5, mô hình sử dụng công suất, trọng lượng và xuất xứ để giải thích $\log(\text{City})$ đã chuẩn hoá, với sai số Student-t. Các chẩn đoán không cho thấy dấu hiệu chưa hội tụ. M5 xếp hạng cao nhất theo PSIS-LOO và WAIC, dù lợi thế so với M4 còn khá bất định và việc mô tả các giá trị cực trị vẫn có hạn chế. Các kết quả chính như sau.

Q1, quan hệ giữa các biến. Khi chỉ xét công suất trong M1, mỗi 10 hp tăng thêm ứng với trung vị City giảm 3,0%. Khi giữ trọng lượng và xuất xứ không đổi trong M5, mức thay đổi chỉ còn $-0{,}45\%$ và HDI 95% chứa 0. Trong khi đó, ở cùng công suất và xuất xứ, mỗi 100 kg tăng thêm ứng với trung vị City giảm 6,2%. City và Open Road có tương quan $0{,}94$, nhưng cần mô hình riêng để có kết luận định lượng cho Open Road.

Q2, xe Mỹ và xe nước ngoài. Theo M2, ở cùng mức công suất, trung vị City của xe Mỹ thấp hơn khoảng 8,7%; xác suất hậu nghiệm để hệ số USA dương là $0{,}003$. Trong M3 có tương tác, chênh lệch thay đổi theo công suất và bằng khoảng 8,6% tại công suất trung bình của mẫu. Khi xét cùng công suất và trọng lượng trong M5, chênh lệch còn 3,3% và HDI 95% của hệ số USA chứa 0. Kết quả cho thấy cần xét trọng lượng khi so sánh hai nhóm, nhưng chưa cho phép kết luận về quan hệ nhân quả.

Q3, điểm ngoại lai. Honda Civic, Geo Metro và Suzuki Swift có City cao hơn dự đoán, còn Mazda RX-7 và Volkswagen Corrado có City thấp hơn dự đoán. Phần dư của nhóm xe van giảm rõ rệt khi mô hình xét thêm trọng lượng. Khi chuyển từ sai số chuẩn sang Student-t, hệ số trọng lượng ít thay đổi, còn độ lớn của hệ số công suất giảm và HDI 95% của hệ số này chứa 0.

Q4, xe 300 hp. Nếu chỉ biết công suất (M1), ước lượng trung vị City là $13{,}6$ MPG, với khoảng dự đoán 95% là $9{,}7$–$18{,}8$ MPG. Nếu biết thêm đó là xe Mỹ nặng $1\,681$ kg (M5), ước lượng trung vị là $16{,}6$ MPG và khoảng dự đoán 95% là $13{,}4$–$20{,}6$ MPG. Khi dùng thông số riêng của ba xe gần 300 hp trong mẫu, khoảng dự đoán của M5 đều chứa giá trị quan sát. Do các xe này đã được dùng để ước lượng mô hình, kết quả trên chưa thay thế được đánh giá bằng dữ liệu độc lập.

Hướng phát triển. Một hướng mở rộng là xây dựng mô hình phân cấp theo loại xe (Type), trong đó các loại xe có hệ số chặn riêng nhưng cùng được mô tả bởi một phân phối chung. Cách này cho phép xét thêm khác biệt giữa các loại xe. Ngoài ra, có thể đánh giá việc bổ sung dung tích động cơ (Engine Size), hệ dẫn động (Drive train), khả năng chọn hộp số tay (Manual), hoặc thử biến phản hồi là số gallon trên mỗi dặm ($1/\text{City}$) và so sánh khả năng dự đoán trên cùng thang đo.

A. Mã nguồn và dữ liệu

Toàn bộ phân tích được tập hợp trong notebook `bayes_cars_1993.ipynb`, ghép từ năm module trong thư mục `analysis/`. Với Python 3.12, PyMC 5.28 và ArviZ 0.23 (seed 2026), notebook chạy hết trong khoảng 8 phút. Phân công từng module được ghi ở bảng A.1.

Dữ liệu sau khi làm sạch được lưu tại `outputs/data_clean.csv`, bảng hậu nghiệm đầy đủ của các mô hình tại `outputs/tables/tab_4_4_posterior.csv`, còn các hình nằm trong `outputs/figures/`. Hàm khai báo chung cho năm mô hình trong PyMC được trình bày dưới đây.

```
def build_model(d, sc, terms, prior="weak", likelihood="normal"):
    X = design(d, sc, terms)          # standardised HP, Weight; USA as 0/1
    y = sc.y(d["city"])               # standardised log(City)
    coords = {"term": terms, "obs": d["name"].to_numpy()}
    with pm.Model(coords=coords) as model:
        Xd = pm.Data("X", X, dims=("obs", "term"))
        b0 = pm.Normal("b0", 0, PRIOR_SD[prior])
        b = pm.Normal("b", 0, PRIOR_SD[prior], dims="term")
        sigma = pm.HalfNormal("sigma", 1)
        mu = pm.Deterministic("mu", b0 + pm.math.dot(Xd, b), dims="obs")
        if likelihood == "student":
            nu = pm.Gamma("nu", 2, 0.1)
            pm.StudentT("y", nu=nu, mu=mu, sigma=sigma, observed=y, dims="obs")
        else:
            pm.Normal("y", mu=mu, sigma=sigma, observed=y, dims="obs")
    return model
```

Bảng A.1: Các module trong notebook chung.

Module	Phụ trách	Mục trong báo cáo
`02_data_eda.py`	TV2	Chương II, mục 3.3
`03_models.py`	TV3	Mục 3.4–3.7
`04_sampling.py`	TV4	Mục 4.2–4.4
`01_conjugate.py`	TV1	Mục 4.1
`05_evaluation.py`	TV5	Chương V

B. Khai báo sử dụng AI

Trong quá trình thực hiện, nhóm có sử dụng trợ lý AI **Claude** của Anthropic vào các việc sau:

- hỗ trợ viết, chú thích và sửa lỗi code Python (PyMC, ArviZ) trong thư mục `analysis/`;
- hỗ trợ soạn, sửa văn bản và trình bày LaTeX của báo cáo;
- rà soát cách diễn giải thống kê, ví dụ phân biệt trung vị với trung bình trên thang log, ý nghĩa tham số thang đo của Student-t và tránh diễn giải nhân quả.

Nhóm cũng sử dụng ChatGPT (Codex) của OpenAI để rà soát văn phong, làm rõ các điều kiện so sánh và chỉnh sửa cách diễn giải kết quả trong báo cáo.

Mọi con số trong báo cáo đều lấy từ kết quả chạy code của nhóm (`outputs/`), không lấy từ câu trả lời của AI. Nhóm đã đối chiếu các nhận định với kết quả tính toán và tài liệu tham khảo, và chịu trách nhiệm về toàn bộ nội dung bài.

Tài liệu tham khảo

[1] Andrew Gelman et al. *Bayesian Data Analysis*. 3rd ed. CRC Press, 2013.

[2] Richard McElreath. *Statistical Rethinking: A Bayesian Course with Examples in R and Stan*. 2nd ed. CRC Press, 2020.

[3] Consumer Reports. *The 1993 Cars – Annual Auto Issue*. 1993.

[4] PACE Publications. *PACE New Car & Truck 1993 Buying Guide*. 1993.

[5] Robin H. Lock. "1993 New Car Data". In: *Journal of Statistics Education* 1.1 (1993).

[6] W. N. Venables and B. D. Ripley. *Cars93: Data from 93 Cars on Sale in the USA in 1993 (R package MASS)*. Tài liệu bộ dữ liệu trong gói MASS, đi kèm sách Modern Applied Statistics with S. 2002. URL: https://stat.ethz.ch/R-manual/R-devel/library/MASS/html/Cars93.html.

[7] Matthew D. Hoffman and Andrew Gelman. "The No-U-Turn Sampler: Adaptively Setting Path Lengths in Hamiltonian Monte Carlo". In: *Journal of Machine Learning Research* 15 (2014), pp. 1593–1623.

[8] Oriol Abril-Pla et al. "PyMC: A Modern and Comprehensive Probabilistic Programming Framework in Python". In: *PeerJ Computer Science* 9 (2023), e1516.

[9] Aki Vehtari et al. "Rank-Normalization, Folding, and Localization: An Improved $\widehat{R}$ for Assessing Convergence of MCMC". In: *Bayesian Analysis* 16.2 (2021), pp. 667–718.

[10] Aki Vehtari, Andrew Gelman, and Jonah Gabry. "Practical Bayesian Model Evaluation Using Leave-One-Out Cross-Validation and WAIC". In: *Statistics and Computing* 27 (2017), pp. 1413–1432.

[11] Ravin Kumar et al. "ArviZ: A Unified Library for Exploratory Analysis of Bayesian Models in Python". In: *Journal of Open Source Software* 4.33 (2019), p. 1143.